Лекция 7. Метод опорных векторов

Метод опорных векторов Support Vector Machine (SVM) основан на концепции гиперплоскостей, которые определяют границы гиперповерхностей, разделяющих набор объектов различных классов [7]. Схематический пример показан на рис.4.1.1, в котором объекты принадлежат 2 классам – кружочкам зеленого цвета и красного. Разделительная линия – образ гиперплоскости определяет границу, справа от которой все объекты зеленные, а слева – красные. Любой новый объект, например белый кружок, попадающий вправо, классифицируется как зеленый; если попадет влево – то классифицируется как красный.

Вышеупомянутое является классическим примером линейного классификатора, то есть классификатора, который разделяет набор объектов на их соответствующие группы (в данном случае зеленые и красные кружочки) с помощью прямой линии.

Однако большинство задач классификации не так просты, и часто требуются более сложные структуры, чтобы сделать оптимальное разделение, то есть правильно классифицировать новые объекты на основе имеющихся данных. Эта ситуация изображена на рис.4.1.2.

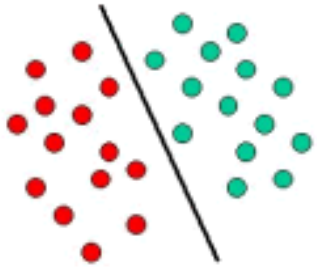

Рис.4.1.1

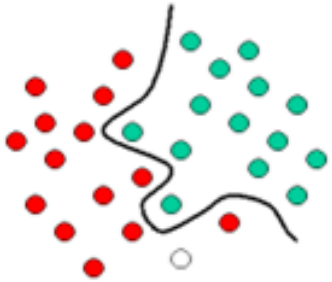

Рис.4.1.2

По сравнению с предыдущей схемой ясно, что для полного разделения зеленых и красных объектов потребуется кривая, которая представляет собою более сложную линию, чем прямая. Задачи классификации, основанные на рисовании разделительных линий для различения объектов, принадлежащих к разным классам, известны как классификаторы гиперплоскости, одним из которых является метод опорных векторов – SVM. На рис.4.1.3 показана основная идея метода SVM. Здесь мы видим исходные объекты (левая часть схемы), отображаемые, то есть переупорядоченные (правая часть схемы), с использованием набора математических функций, называемых преобразованием ядра. После применения преобразования ядра, переупорядоченные объекты линейно разделимы и, таким образом, вместо построения сложной кривой все, что нам нужно сделать, это найти оптимальную прямую линию, которая может разделять зеленые и красные объекты.

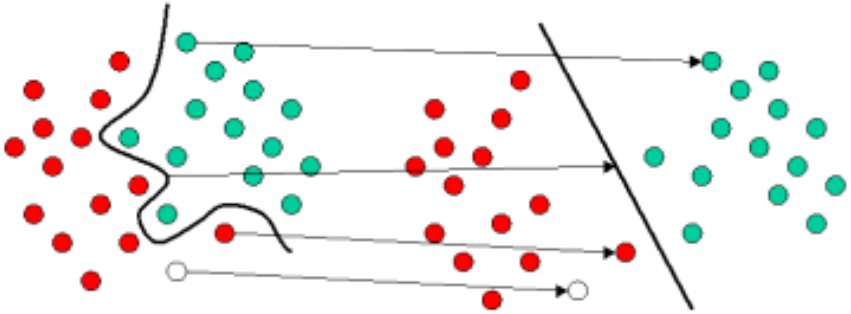

Рис.4.1.3

В пакете Statistica предусмотрены такие функции преобразования ядра как линейная, полиномиальная, экспоненциальная (функция радиального базиса RBF), сигмоида. Сами функции и их параметры в модуле могут задаваться пользователем.

SVM – это, прежде всего, классификационный метод, решающий задачи классификации путем построения гиперплоскостей в многомерном пространстве, которые разделяют объекты произвольной природы относительно заданных классов. Но SVM также решает задачи регрессии и может обрабатывать одновременно несколько непрерывных и категориальных переменных. Для категориальных переменных создается фиктивная переменная со значениями 0 или 1. Например, категориальная зависимая переменная, состоящая из трех классов, например (A, B, C), может быть представлена набором из трех фиктивных переменных: A (1, 0, 0), B (0, 1, 0), C (0, 0, 1).

Для построения оптимальной гиперплоскости SVM применяют алгоритм итеративного обучения, который минимизирует функцию ошибки. По виду функции ошибок модели SVM можно разделить на четыре отдельные группы: классификация SVM типа 1 (C-SVM); классификация SVM типа 2 (nu-SVM); регрессия SVM типа 1 (регрессия epsilon-SVM); регрессия SVM типа 2 (регрессия nu-SVM). Перейдем к практической реализации модуля, воспользовавшись тем же файлом исходных данных 153 образцов белых и красных вин.

В меню на Data Mining выберем команду Machine Learning, откроется окно с 3 методами машинного обучения (рис.4.1.4), выберем интересующий нас модуль Support Vector Machine, диалоговое окно которого на вкладке Quick приведено на рис.4.1.5.

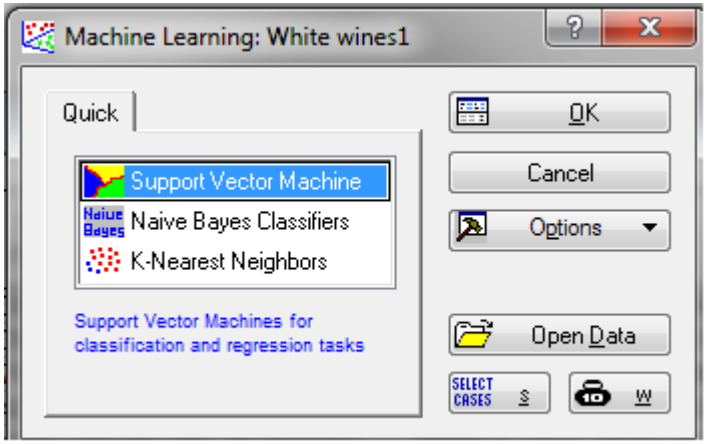

Рис.4.1.4

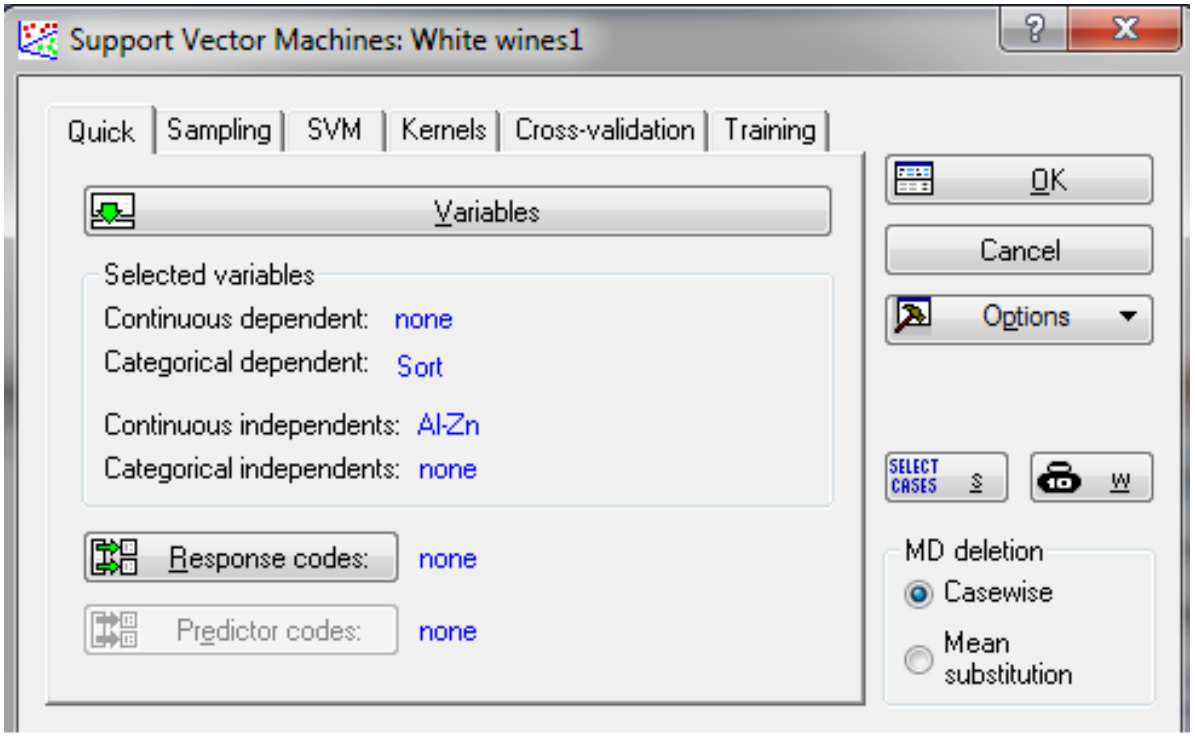

Рис.4.1.5

Также как и рассмотренные ранее модули классификации, методы машинного обучения предназначены для решения 2 задач – построения модели определения принадлежности объекта к некоторому заданному классу, и построения регрессионной модели для прогнозирования значения непрерывного отклика. Поэтому, зависимая переменная (dependent) может быть в модуле непрерывной (continues) и категориальной (categorical). Предикторы моделей могут быть также непрерывными и категориальными.

Так как мы продолжаем решать ту же задачу классификации, то щелкнув по кнопке Variables, в полях открывшегося диалога обозначим переменные в соответствие с рис.4.1.6.

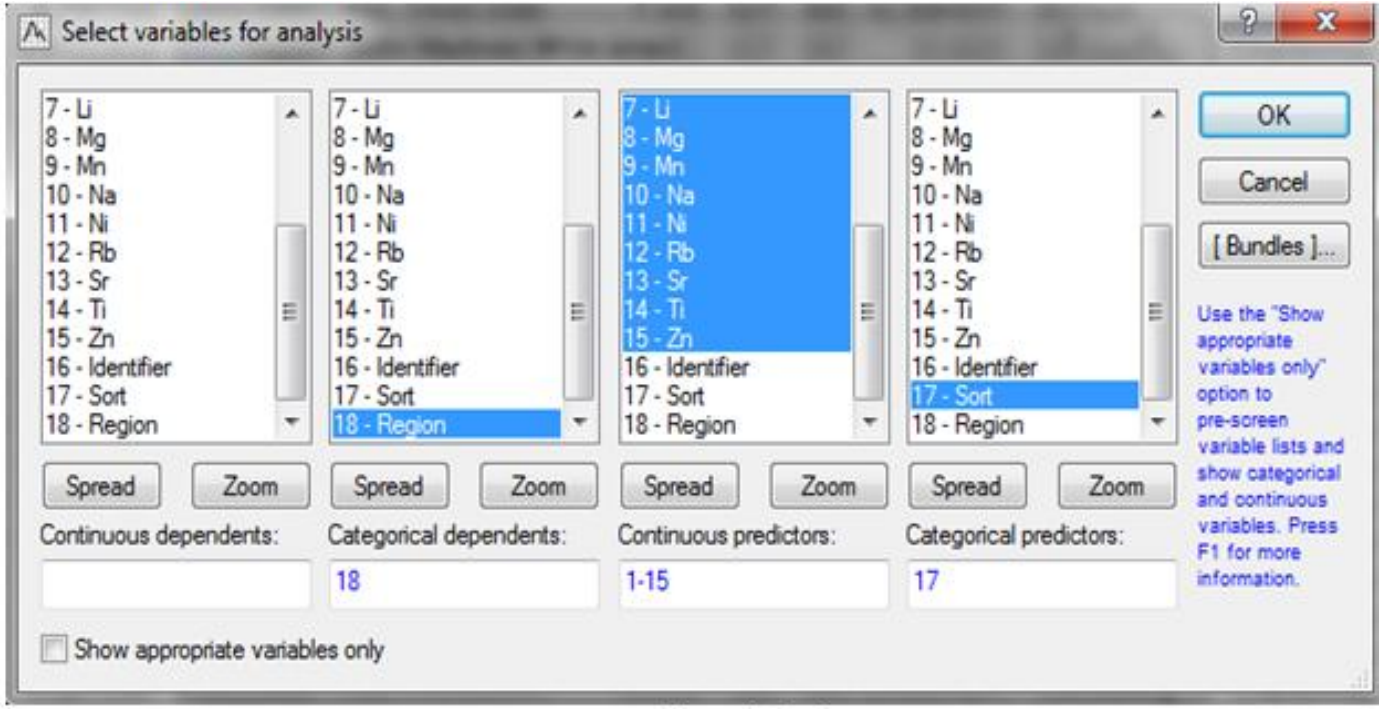

Рис.4.1.6

В одноименной рамке вкладки Sampling (выбор образцов) предусмотрены различные варианты разделения данных на обучающую и тестовую выборки (рис.4.1.7).

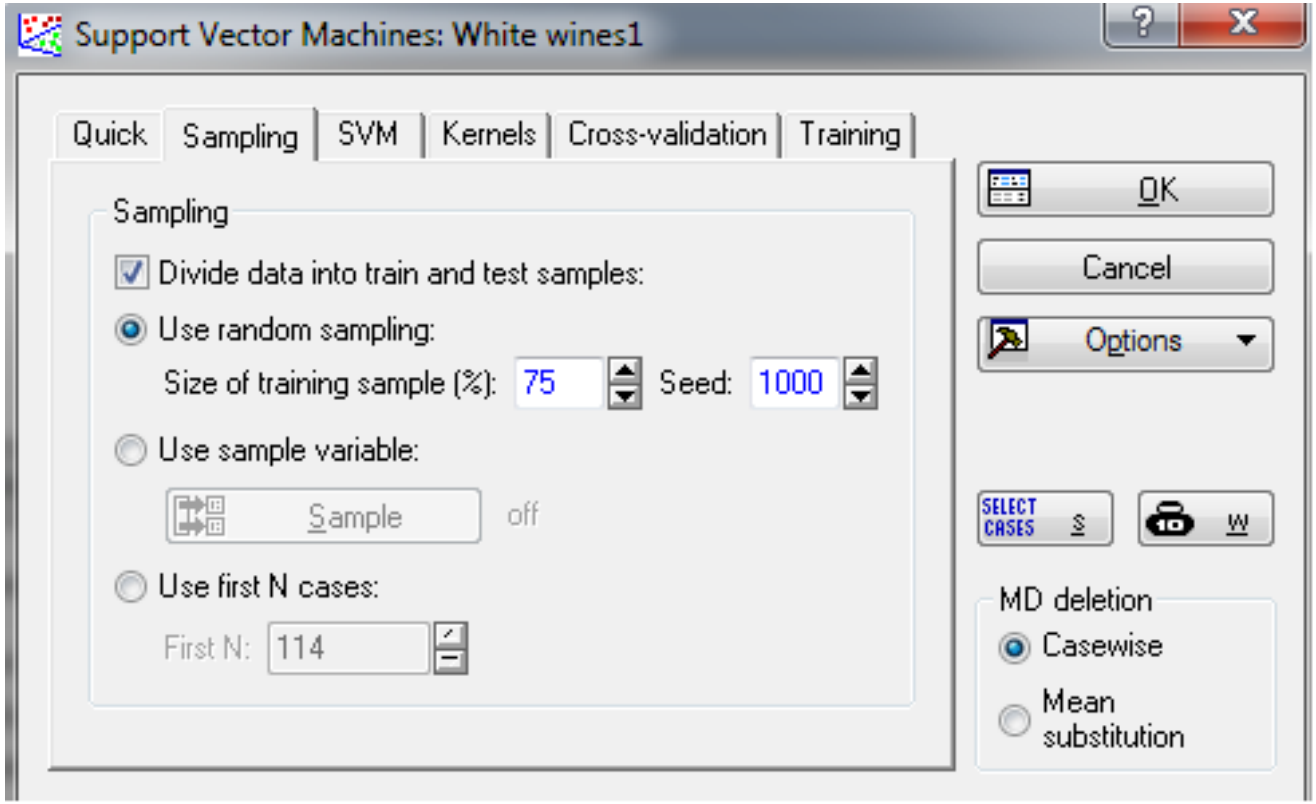

Рис.4.1.7

Как и в предыдущих модулях, обучающая выборка будет использоваться для построения модели SVM, в то время как на тестовой выборке, как независимого набора данных, будет осуществлена проверка производительности модели после завершения обучения. Если установить флажок на Divide data into train and test samples, то будет активна одна из 3 предусмотренных опций назначения тестовой выборки.

Опция Use random sampling предполагает генерацию тестовой выборки случайным образом при помощи датчика случайных чисел, начальное значение которого можно ввести/изменить в поле Seed. По умолчанию исходная выборка делится на тестовую и обучающую выборку в соотношении 1(25%) к 3(75%).

Если выбрана опция Use sample variable, то пользователь может использовать переменную идентификатор, которая определяет принадлежность объектов к тестовой и обучающей выборке. В наших исходных данных эта переменная называется Identifier.

Если выбрать опцию Use first N cases (выбрать первые N наблюдений), то программа первые N наблюдений исходной выборки использует как обучающуюся выборку, а оставшиеся наблюдения – как тестовые. Использовать эту опцию целесообразно, если у вас есть веские основания полагать, что первые N наблюдений в наборе данных составляют хорошую обучающую выборку, т.е. они хорошо представляют исходный набор данных.

Вкладка SVM (рис.4.1.8) предназначена для выбора типа функции ошибок SVM. Если в диалоге на рис.4.1.8 пользователь выбрал категориальную зависимую переменную, то в рамке SVM Type будут активны опции Classification SVM, при выборе непрерывной зависимой переменной – Regression SVM. При выборе типов 1, или 2 функции ошибок, будут активны поля для назначения их параметров – Capacity, Epsilon, Nu.

На вкладке Kernels (ядра) (рис.4.1.9) пользователь может выбрать функции преобразования ядра. В зависимости от выбора одной из 4 функций будут активны те, или иные параметры – Degree (степень) для Polynomial; Gamma для Polynomial, RBF, and Sigmoid; Coefficient для Polynomial, Sigmoid.

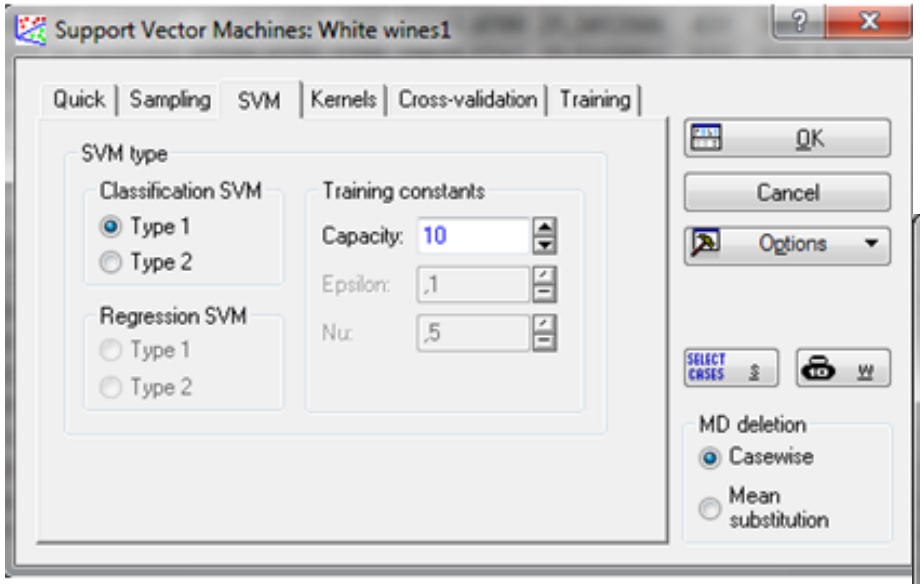

Рис.4.1.8

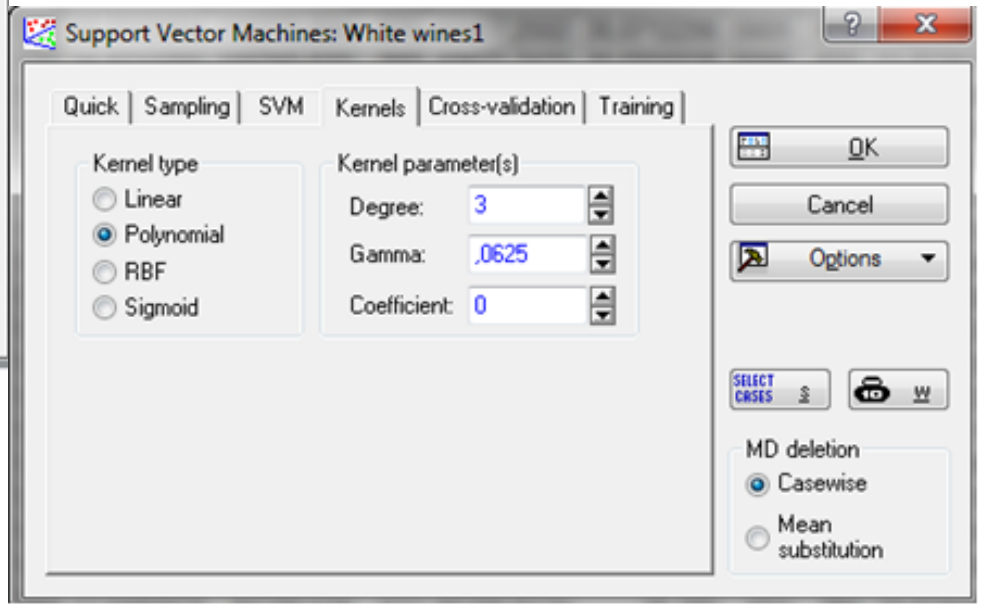

Рис.4.1.9

Для построения модели классификации при помощи V-кратной кросс-проверки, следует перейти на вкладку Cross-validation (рис.4.1.10). В целом идея кросс-проверка та же, что и в ранее изученных модулях, в частности она подробно описана в §2.1. Естественно диалоговое окно адаптировано к методу SVM. Для включения этой процедуры следует установить флажок на опции Apply v-fold cross-validation. При этом, опции по назначению параметров Capacity, Epsilon, Nu на вкладке SVM (рис.4.1.8) будут недоступны, так как они будут автоматически вычислены при проведении кросс-проверки. В рамке Grid search (поиск по сетке) заданы по умолчанию диапазоны их изменения и величина шага – Increment. Поля параметров будут активны в зависимости от того, какой тип функции ошибок SVM выбран – Type 1, или Type 2.

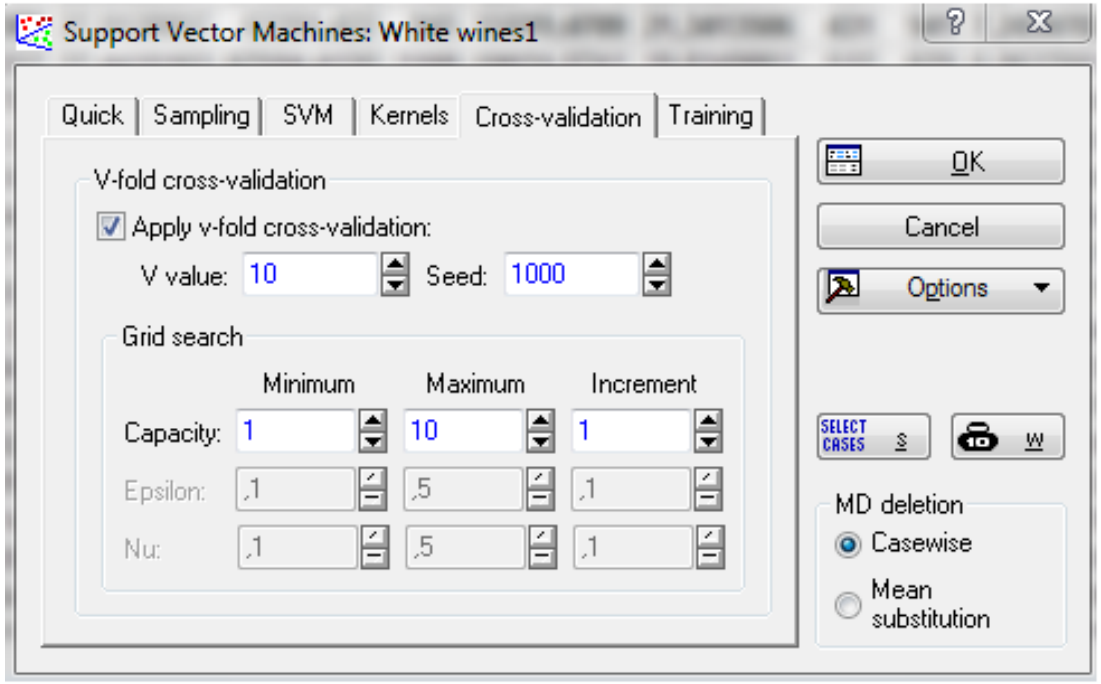

Рис.4.1.10

Вкладка Training (обучение) на рис.4.1.11 предназначена для доступа к параметрам, которые влияют на процесс обучения, например, на окончательную модель SVM. Комбинация параметров Maximum number of iterations (максимальное количество итераций) и Stop at error (остановить при ошибке) позволяет построить хорошо обученную модель SVM за время, определяемое максимальным количеством итераций или точностью – в зависимости от того, что будет достигнуто раньше. Обучение модели SVM – это итерационная процедура, которая может быть достигнута с использованием процесса, известного как минимизация функции ошибок. Чем больше число этих итераций, тем больше обучается SVM и, как правило, тем лучше она может предсказать обучающую выборку. Понятно, что максимальное количество итераций будет определять верхнюю границу количества итераций, которые будет проходить SVM. Если ошибка обучающей выборки падает ниже заданного значения, модель SVM считается достаточно хорошо обученной, и обучение прекращается независимо от того, будет ли достигнуто максимальное количество итераций.

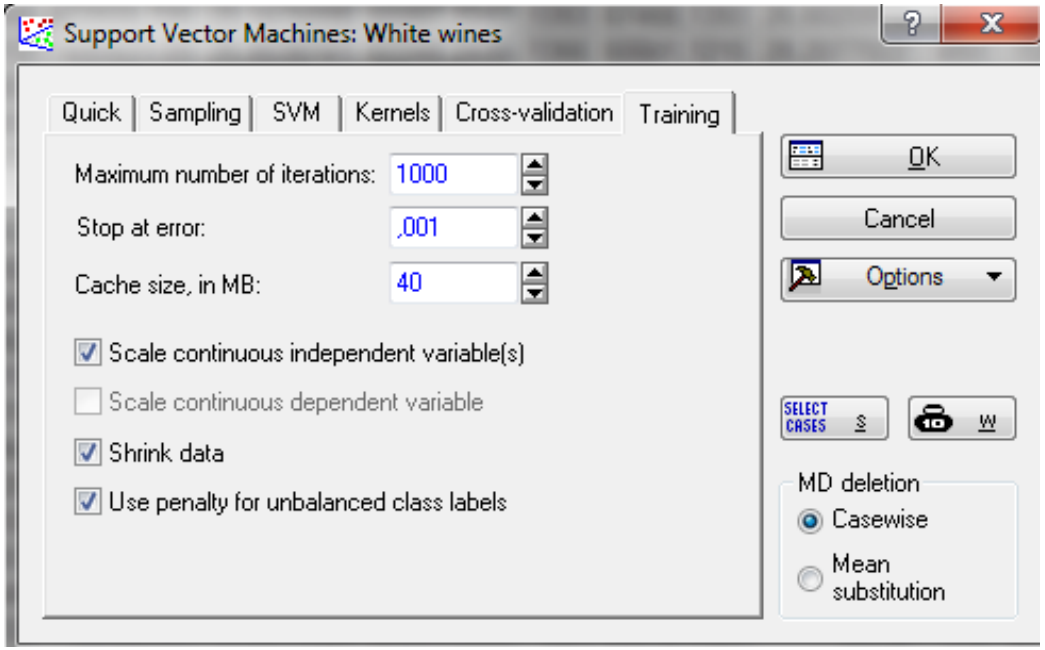

Рис.4.11

Опция Cache size, in MB определяет размер кэш-памяти (кэш – это память с большей скоростью доступа). В зависимости от ресурсов вычислительной системы целесообразно установить для этого параметра максимально возможное значение, что помогает сократить время вычислений за счет кэширования определенных количеств оптимизации, которые были рассчитаны и использованы.

Опция Scale continuous нормирует непрерывные входные переменные в диапазоне [0,1]. Эта опция особенно полезна, когда непрерывный входной диапазон велик, так как генерирование большого количества опорных векторов может привести к переобучению. Если мы решаем задачу регрессии, то следует установить флажок на Scale continuous dependent variable. Такая установка позволит нормировать непрерывную зависимую переменную.

Опция Shrink data (сжать данные) сжимает данные, что в свою очередь позволит сэкономить время на оптимизацию.

Опция Use penalty for unbalanced class labels (используйте штраф за несбалансированные метки класса) применима только к задачам классификации. Иногда может случиться так, что категориальная зависимая переменная содержит несбалансированное количество классов. Пример: категориальная переменная с 30 случаями и тремя классами A, B и C с частотами 10, 19, 1. Ясно, что в таких случаях, как этот, модель SVM будет иметь тенденцию ошибочно классифицировать C как A или B. Чтобы противодействовать этому дисбалансу, STATISTICA SVM позволяет связать значение штрафа с каждой категорией класса. Чем больше штраф для категории класса, тем сильнее не рекомендуется SVM связывать новый случай данных с этим классом. Если этот флажок установлен, и пользователь нажимает кнопку OK, отображается диалоговое окно выбора штрафа, в котором пользователь может назначить штрафы категориям классов.

Приемлемая модель классификации была нами построена при следующих установках модуля:

– опции вкладки Sampling назначены по умолчанию;

– на вкладке SVM выбрано Type 1;

– на вкладке Kernels выбрана опция RBF;

– на вкладке Cross-validation установлен флажок на Apply v-fold cross-validation, остальные опции по умолчанию;

– на вкладке Training установлены флажки на Scale continuous и Use penalty for unbalanced class labels, остальные опции по умолчанию.

Мы применили опцию для назначения штрафа ввиду того, что частоты распределения образцов по регионам распределены далеко не равномерно (табл.4.1.1).

Если в диалоговом окне на рис.4.1.11 щелкнуть по кнопке ОК, появится окно (рис.4.1.12) с частотами распределения образцов по регионам в обучающей выборке и величины штрафов по умолчанию.

Таблица 4.1.1. Распределение частот образцов по регионам

Группа	Frequency table: Region (White wines1)			
	Frequency	Cumulative Frequency	Percent	Cumulative Percent
Taman	73	73	47,71242	47,7124
Anapa	18	91	11,76471	59,4771
South foothill	30	121	19,60784	79,0850
Black Sea	32	153	20,91503	100,0000
Пропущ.	0	153	0,00000	100,0000

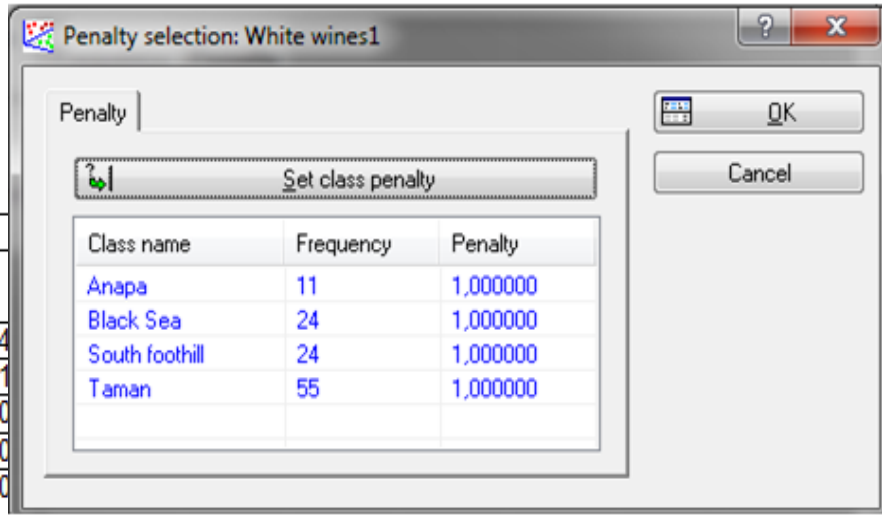

Рис.4.1.12

После нажатия кнопки Set class penalty появится окно, в которое и внесем штрафы в соответствии с рис.4.1.13. После очередного щелчка по ОК в окне на рис.4.1.13 появится окно с итоговыми результатами модуля SVM (рис.4.1.14). В информационной части окна приведены названия зависимой и независимых переменных, размеры обучающей и тестовой выборок, тип модели (1) с параметром (capacity = 10), функция преобразования ядра (RBF) вместе с параметрами (gamma =0,063), количество построенных опорных векторов всего (78) и по каждому классу (региону). Также отображены точности кросс-проверки (91,228%), модели на обучающей (97,368%) и тестовой выборке (97,436%), а также общая точность (97,386%).

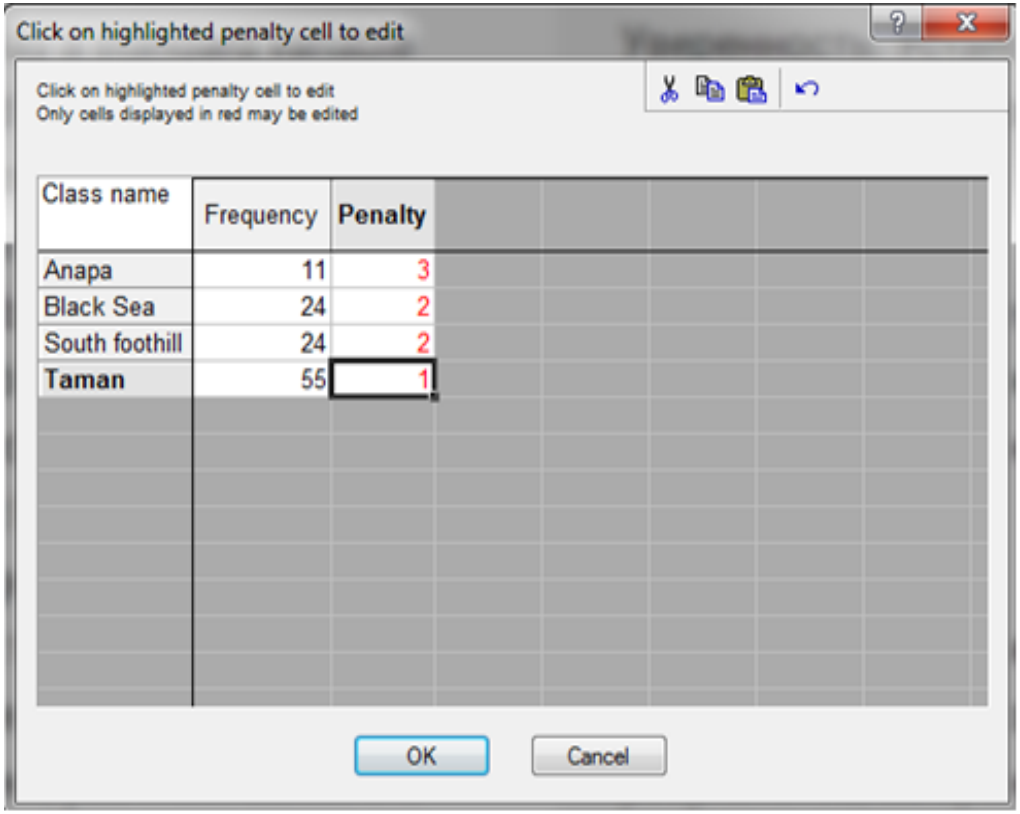

Рис.4.1.13

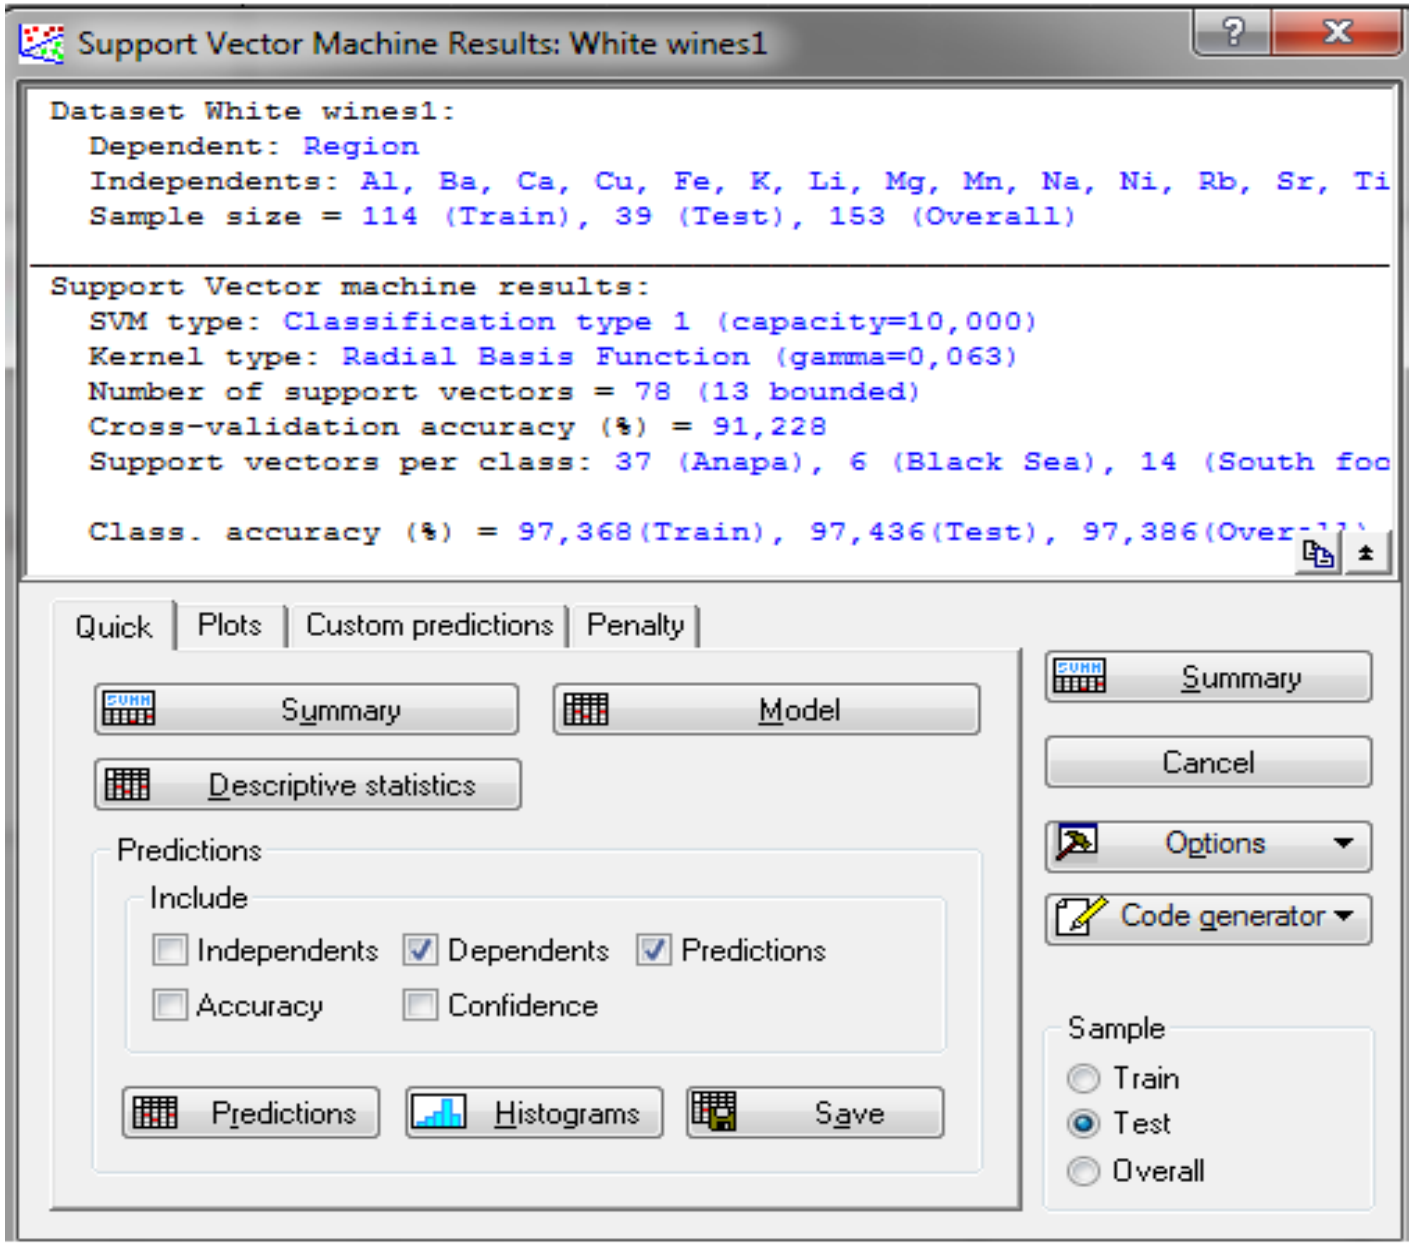
Support Vector Machine Results: White wines1
Dataset White wines1:
Dependent: Region
Independents: Al, Ba, Ca, Cu, Fe, K, Li, Mg, Mn, Na, Ni, Rb, Sr, Ti
Sample size = 114 (Train), 39 (Test), 153 (Overall)
Support Vector machine results:
SVM type: Classification type 1 (capacity=10,000)
Kernel type: Radial Basis Function (gamma=0,063)
Number of support vectors = 78 (13 bounded)
Cross-validation accuracy (%) = 91,228
Support vectors per class: 37 (Anapa), 6 (Black Sea), 14 (South foo
Class. accuracy (%) = 97,368(Train), 97,436(Test), 97,386(Over
Quick
Plots
Custom predictions
Penalty
Summary
Model
Descriptive statistics
Predictions
Include
Independents
Dependents
Predictions
Accuracy
Confidence
Predictions
Histograms
Save
Summary
Cancel
Options
Code generator
Sample
Train
Test
Overall

Рис.4.1.14

Поскольку был использован механизм кросс-проверки, то в информационной части следует обратить внимание на параметр типа классификации, поиск которого выполнялся. Если он достиг одной из границ, то можно попытаться улучшить прогностические свойства модели, расширив диапазон значений в окне вкладки Cross-validation (рис.4.1.7). В частности в информационной части окна результатов параметр Capacity=10, т.е. достиг правой границы. Поэтому можно попытаться улучшить модель классификации, увеличив правую границу диапазона, также на вкладке Training увеличив количество итераций.

При нажатии на кнопку Summary, программа отобразит табл.4.1.2, в которой указаны некоторые параметры построения модели и статистика по опорным векторам, продублированные в информационной части окна.

Если нажать на кнопку Model, появятся две электронные таблицы, содержащие коэффициенты модели (табл.4.1.3) и опорные вектора. Опорные вектора (78) представлены их координатами, приведенными в строках таблицы. Система координат (21) состоит из 3 весов (Weights1, Weights2, Weights3), названий 15 металлов и 3 сортов вин. Из-за большого размера таблицу не приводим.

Таблица 4.1.2. Параметры модели

Model specifications	Model summary (Support Vector Machine), Region (White wines1)
	Value
Number of independents	16
SVM type	Classification type 1
Kernel type	Radial Basis Function
Number of SVs	78 (13 bounded)
Number of SVs (Anapa)	37
Number of SVs (Black Sea)	6
Number of SVs (South foothill)	14
Number of SVs (Taman)	21

Таблица 4.1.3. Коэффициенты модели

Decision Constant	SVM model specifications (decision constants), (White wines1) SVM: Classification type 1 (C=10,000000) Kernel: Radial Basis Function (gamma=0,062500)
	Value
1	-0,75457
2	-2,22563
3	-0,86070
4	-1,01565
5	0,56120
6	3,31543

Для ознакомления с результатами классификации (прогноза для задач регрессии) в обучающей, тестовой и всей выборке (в рамке Sample следует последовательно выделить опции Train, Test, Overal) надо воспользоваться кнопкой Descriptive statistics.

Появятся табл.4.1.4-4.1.8 в которых отображены результаты классификации и количество ошибочных классификации.

Так, из табл.4.1.4 видно, что все образцы Анапской, Южно-предгороной и Таманской зон тестовой выборки построенной моделью метода SVM верно классифицированы. Но 1 образец из 8 классифицирован некорректно, т.е. ошибочно. При этом процент правильно и неправильно классифицированных образцов составил соответственно 87,5% и 12,5%.

Для того, чтобы определить характер ошибочной классификации, следует обратиться к табл.4.1.5 из которой мы видим, что 1 образец Черноморской зоны ошибочно программой отнесен к Южно-предгорной зоне.

Таблица 4.1.4. Результаты классификации для тестовой выборки

Class Name	Classification summary (Support Vector Machine), Region, Test sample (White wines1) SVM: Classification type 1 (C=10,000), Kernel: Radial Basis Function (gamma=0,063) Number of support vectors= 78 (13 bounded)				
	Total	Correct	Incorrect	Correct(%)	Incorrect(%)
Anapa	7	7	0	100,0000	0,00000
Black Sea	8	7	1	87,5000	12,50000
South foothill	6	6	0	100,0000	0,00000
Taman	18	18	0	100,0000	0,00000

Таблица 4.1.5. Ошибочные классификации для тестовой выборки

Class Observed	Confusion matrix (Support Vector Machine), Region, Test sample (White wines1) SVM: Classification type 1 (C=10,000), Kernel: Radial Basis Function (gamma=0,063), Number of support vectors= 78 (13 bounded) Observed (rows) x Predicted (columns)			
	Anapa	Black Sea	South foothill	Taman
Anapa	7	0	0	0
Black Sea	0	7	1	0
South foothill	0	0	6	0
Taman	0	0	0	18

Из табл.4.1.6-4.1.7 следует, что в обучающей выборке 3 некорректные классификации – 2 образца из Черноморской зоны ошибочно отнесены к Южно-предгорной зоне и 1 образец Таманской зоны ошибочно отнесен к Черноморской зоне.

Таблица 4.1.6. Результаты классификации для обучающей выборки

Class Name	Classification summary (Support Vector Machine), Region, Train sample (White wines1) SVM: Classification type 1 (C=10,000), Kernel: Radial Basis Function (gamma=0,063) Number of support vectors= 78 (13 bounded)				
	Total	Correct	Incorrect	Correct(%)	Incorrect(%)
Anapa	11	11	0	100,0000	0,000000
Black Sea	24	22	2	91,6667	8,333333
South foothill	24	24	0	100,0000	0,000000
Taman	55	54	1	98,1818	1,818182

Таблица 4.1.7. Ошибочные классификации для обучающей выборки

Class Observed	Confusion matrix (Support Vector Machine), Region, Train sample (White wines1) SVM: Classification type 1 (C=10,000), Kernel: Radial Basis Function (gamma=0,063), Number of support vectors= 78 (13 bounded) Observed (rows) x Predicted (columns)			
	Anapa	Black Sea	South foothill	Taman
Anapa	11	0	0	0
Black Sea	0	22	2	0
South foothill	0	0	24	0
Taman	0	1	0	54

По желанию пользователя при помощи рамки Include можно увеличить информативность таблицы и гистограмм добавив следующие параметры:

Independents – значения всех независимых переменных (предикторов) модели;

Dependents – значения зависимой категориальной переменной, т.е. отклика;

Residuals (or Accuracy) – остатки для задачи регрессии, точность (correct, incorrect) для задач классификации;

Confidence – уровни (вероятности) достоверности классификации по каждому классу;

Кнопка Save позволит пользователю сохранить интересующие его результаты построения модели классификации методом SVM.

Как итог можно говорить об успешном решении задачи классификации, так как на всех 3 выборках – тестовой, обучающей и всей выборке достигнута точность больше 97%, т.е. близкая к 1. Об успешности классификации также свидетельствует тот факт, что точность классификации на тестовой выборке (0,97436) все же несколько выше точности классификации на обучающей выборке (0,97368).

Несомненно, большое количество параметров, определяющих структуру модели, позволяет улучшить прогностические свойства построенной модели. Так, если в диалоге на рис.4.1.9 выбрать функцию преобразования ядра RBF, параметру Gamma назначить значение большее 1, то количество ошибочных классификаций в тестовой и обучающей выборке составит 0!

Для того чтобы в последующем использовать модель классификации, разработанную методом SVM, следует сохранить код программы в выбранной пользователем среде программирования (рис.4.1.15).

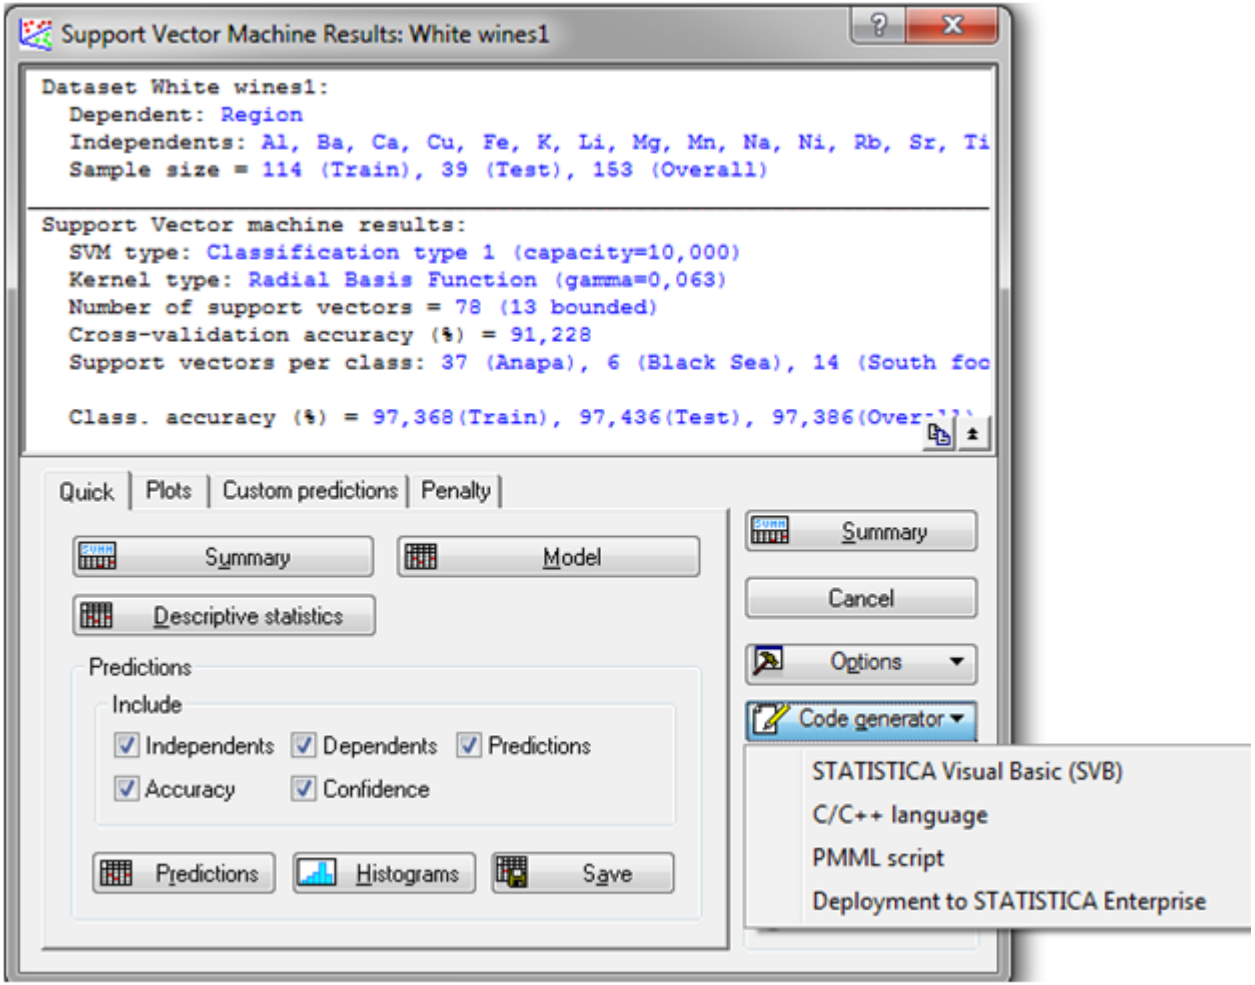

Рис.4.1.15

На вкладке Plots (рис.4.1.16) можно получить доступ к параметрам построения различных сводных 2D- и 3D-графиков, которые помогут в исследовании и интерпретации результатов взаимосвязей, как между непрерывными предикторами, так и категориальными. Так, в частности, 2D-диаграммы рассеяния и 3D-поверхности непрерывных предикторов в сравнении с предсказанными и наблюдаемыми значениями полезны для полного понимания подобранной модели. При помощи кнопки Histogram of X для переменной указанной в поле X-axis можно построить гистограмму. Если воспользоваться кнопкой Graphs of X, Y, то для переменных указанных в полях X-axis и Y-axis программа построит 2D-диаграмму рассеяния. Если в 3 полях X-axis, Y-axis, Z-axis выбраны переменные, то будет построена 3D-поверхность, характеризующая форму взаимосвязи между указанными предикторами. Если установлен флажок на Include case names, то на графиках программа укажет названия объектов, в нашем случае – номера образцов вин.

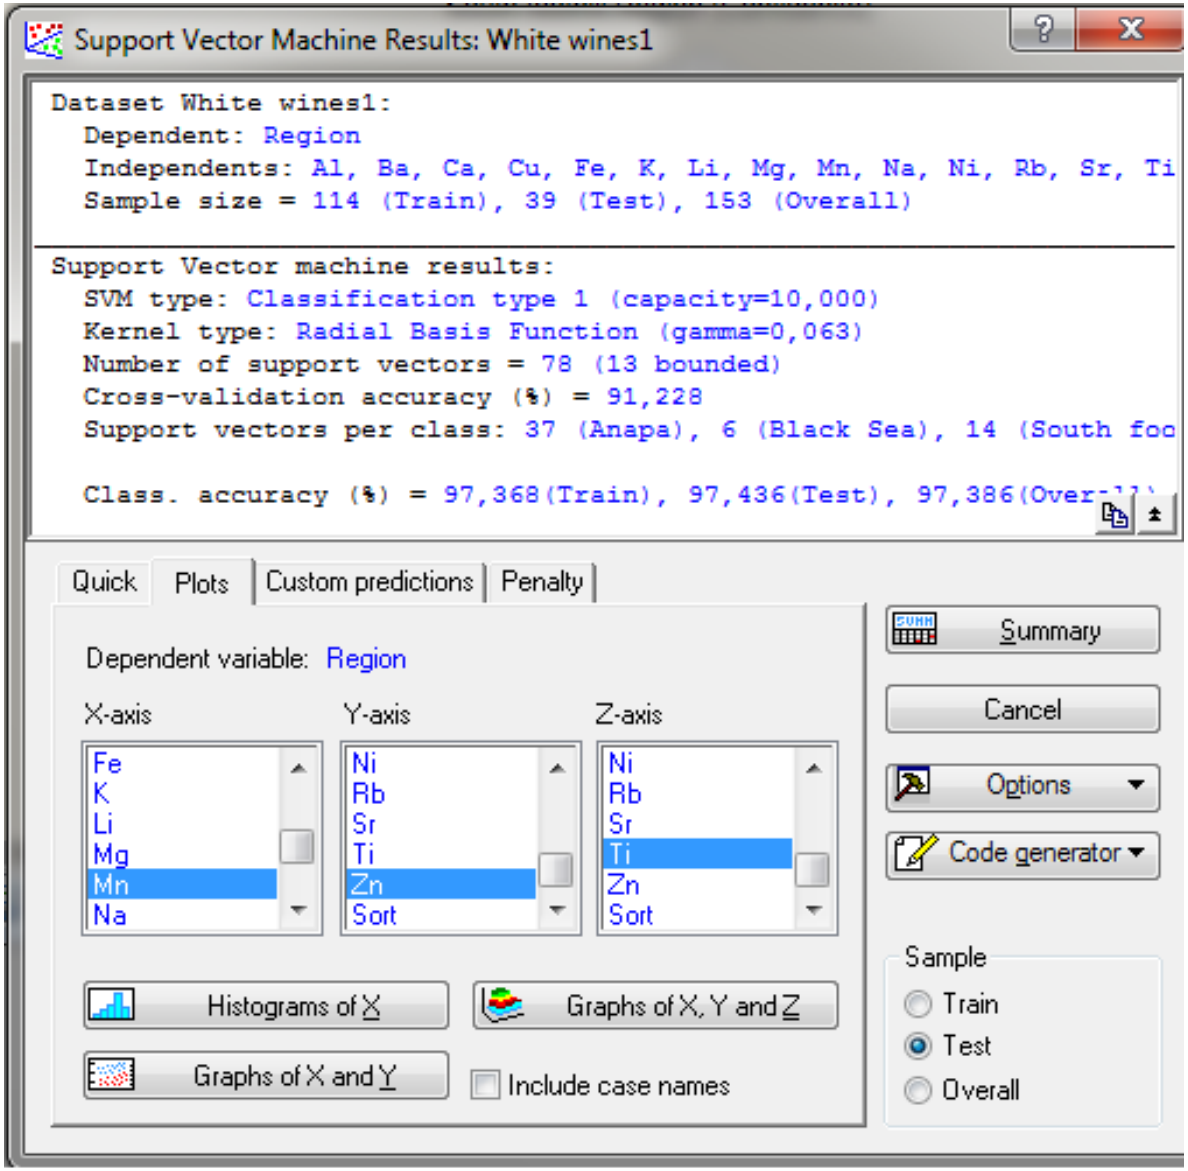
Support Vector Machine Results: White wines1
Dataset White wines1:
Dependent: Region
Independents: Al, Ba, Ca, Cu, Fe, K, Li, Mg, Mn, Na, Ni, Rb, Sr, Ti
Sample size = 114 (Train), 39 (Test), 153 (Overall)
Support Vector machine results:
SVM type: Classification type 1 (capacity=10,000)
Kernel type: Radial Basis Function (gamma=0,063)
Number of support vectors = 78 (13 bounded)
Cross-validation accuracy (%) = 91,228
Support vectors per class: 37 (Anapa), 6 (Black Sea), 14 (South foo
Class. accuracy (%) = 97,368(Train), 97,436(Test), 97,386(Over-
Quick
Plots
Custom predictions
Penalty
Dependent variable: Region
X-axis
Y-axis
Z-axis
Fe
K
Li
Mg
Mn
Na
Ni
Rb
Sr
Ti
Zn
Sort
Ni
Rb
Sr
Ti
Zn
Sort
Histograms of X
Graphs of X, Y and Z
Graphs of X and Y
Include case names
Summary
Cancel
Options
Code generator
Sample
Train
Test
Overall

Рис.4.1.16

Как пример, на рис.4.1.17 и 4.1.18 изображены 3D и 2D графики, визуализирующие характер взаимосвязей между непрерывными предикторами – концентрациями металлов Mn, Zn, Ti для тестовой выборки. Очевидно, что наибольший интерес графические возможности модуля представляют при решении задач регрессии.

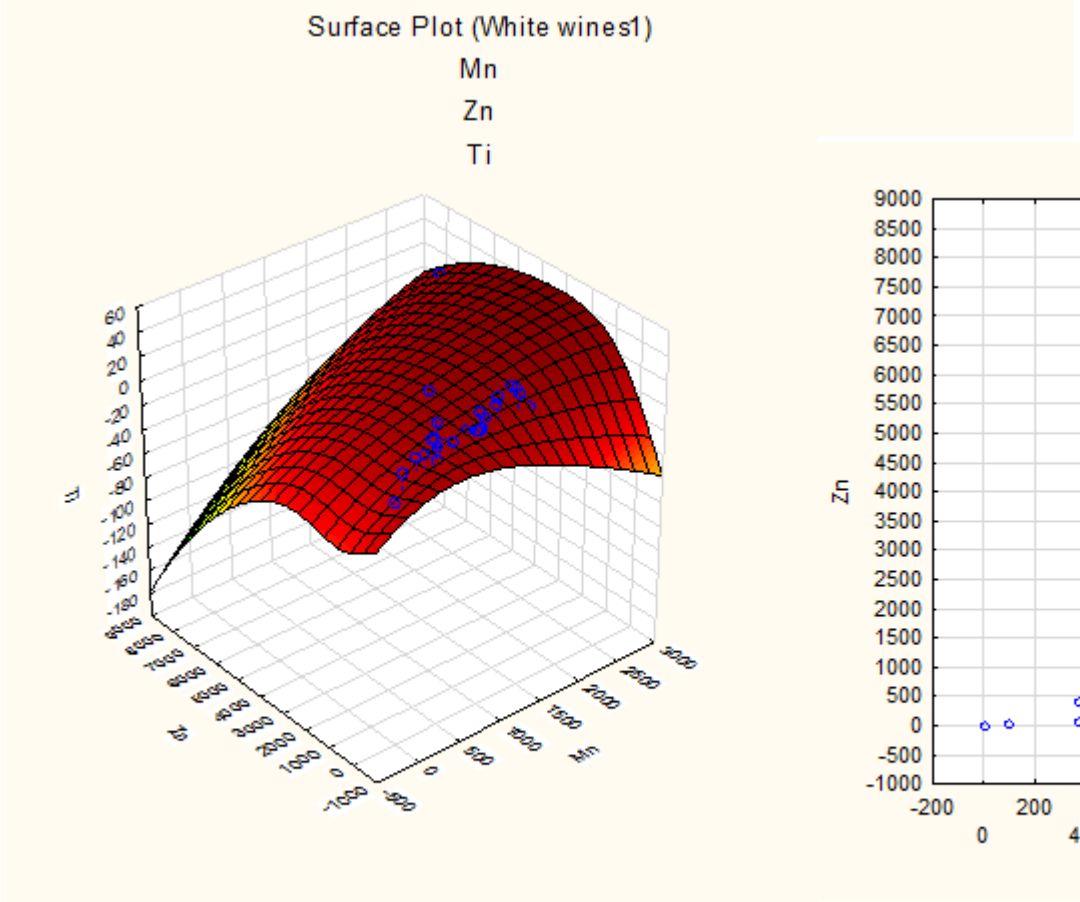

Рис.4.1.17

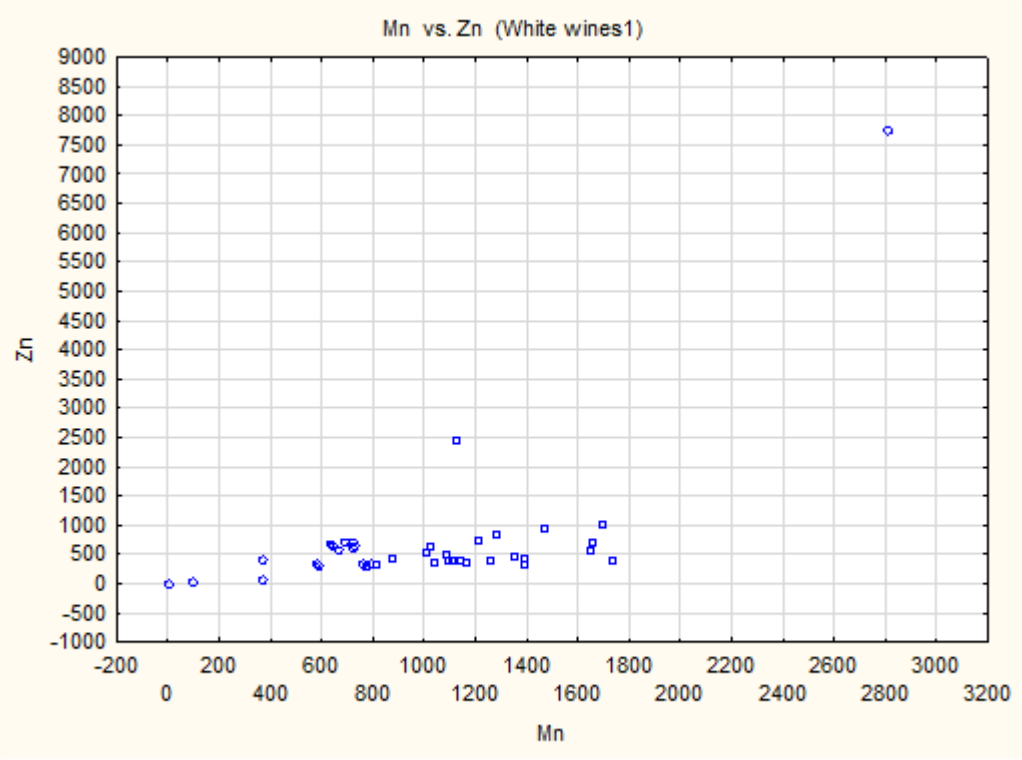

Рис.4.1.18

На вкладке Custom predictions (Пользовательские прогнозы) можно получить доступ к калькулятору метода SVM (рис.4.1.19). Необходимость в таких исследованиях вызвана тем, что часто бывают актуальными ответы на вопрос, как изменится прогноз, если в значения предикторов будут внесены определенные изменения, либо нужно решить задачу классификации региона произрастания винограда по известным значением предикторов.

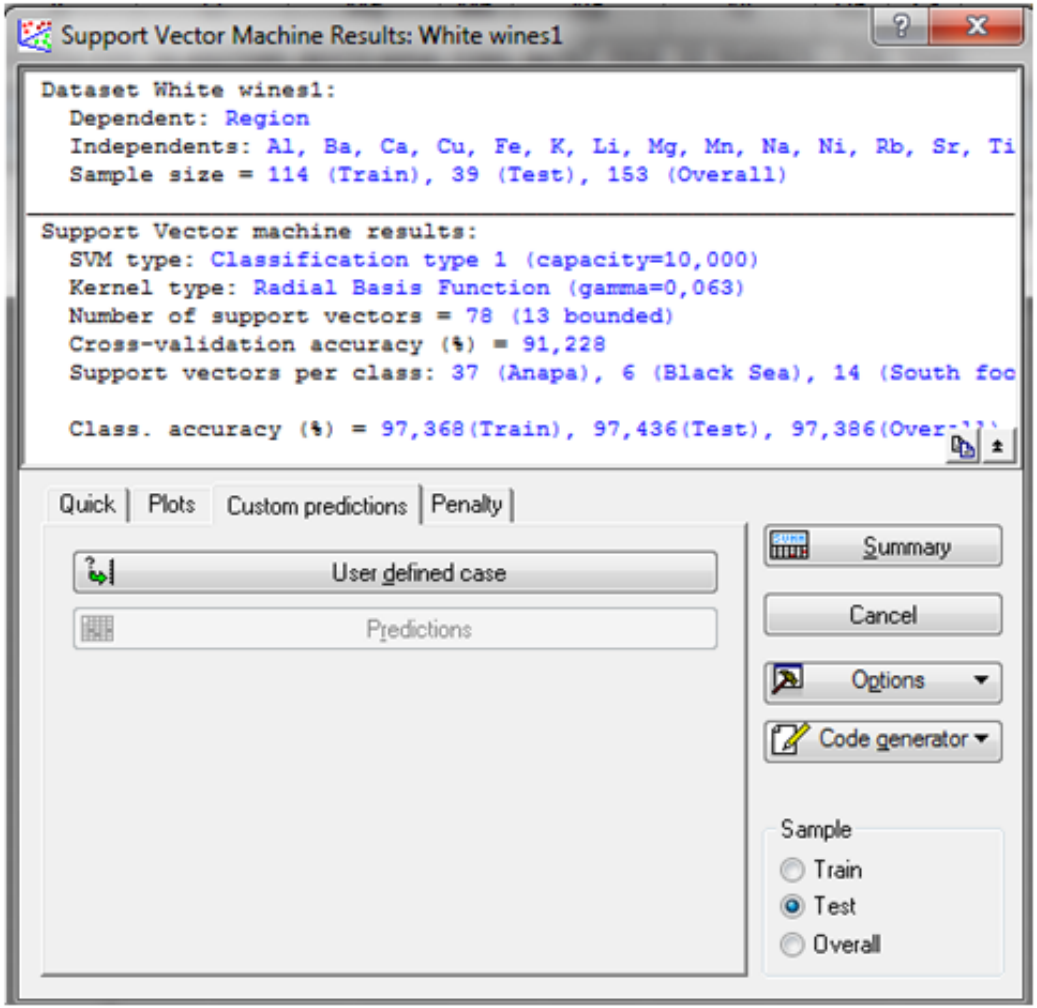

Рис.4.1.19

Если нажать на кнопку User defined case, то откроется окно, в поля, которого следует внести значения непрерывных и категориальных предикторов, которые были заявлены при построении модели.

Например, так как это сделано в окне на рис.4.1.20. Если в данном окне щелкнуть по кнопке OK, активной станет кнопка Predictions (рис.4.1.19), нажатие на которую инициирует появление табл.4.1.10 с результатом проведенных программой вычислений. В таблице программой отображены введенные пользователем значения предикторов и в последней строке – результат прогноза, в соответствии с которым образец вина следует отнести к Таманской зоне.

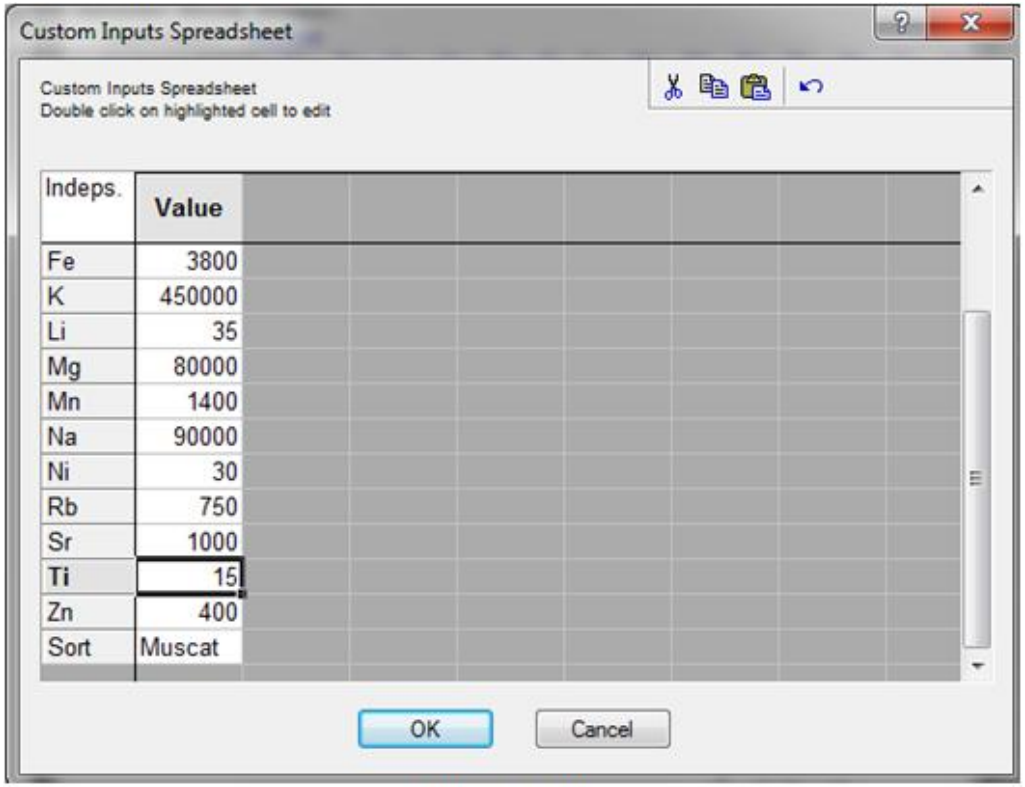

Рис.4.1.20

Таблица 4.1.10. Результаты прогноза

Independent and dependent variables	Custom predictions (White wines1)
	Value
Al	1300,000000
Ba	200,000000
Ca	100000,000000
Cu	80,000000
Fe	3800,000000
K	44000,000000
Li	35,000000
Mg	80000,000000
Mn	1400,000000
Na	90000,000000
Ni	32,000000
Rb	700,000000
Sr	1000,000000
Ti	15,000000
Zn	400,000000
Sort	Muscat
Region	Taman

Если в диалоге на рис.4.1.7 выбрать опцию Use sample variable, указать переменную идентификатор на вкладке Cross-validation выбрать кросс-проверку, остальные установки оставить по умолчанию, то окно результатов примет вид на рис.4.1.21. Как видно, печальные результаты классификации на тестовой выборке. Задание – улучшить результаты классификации!

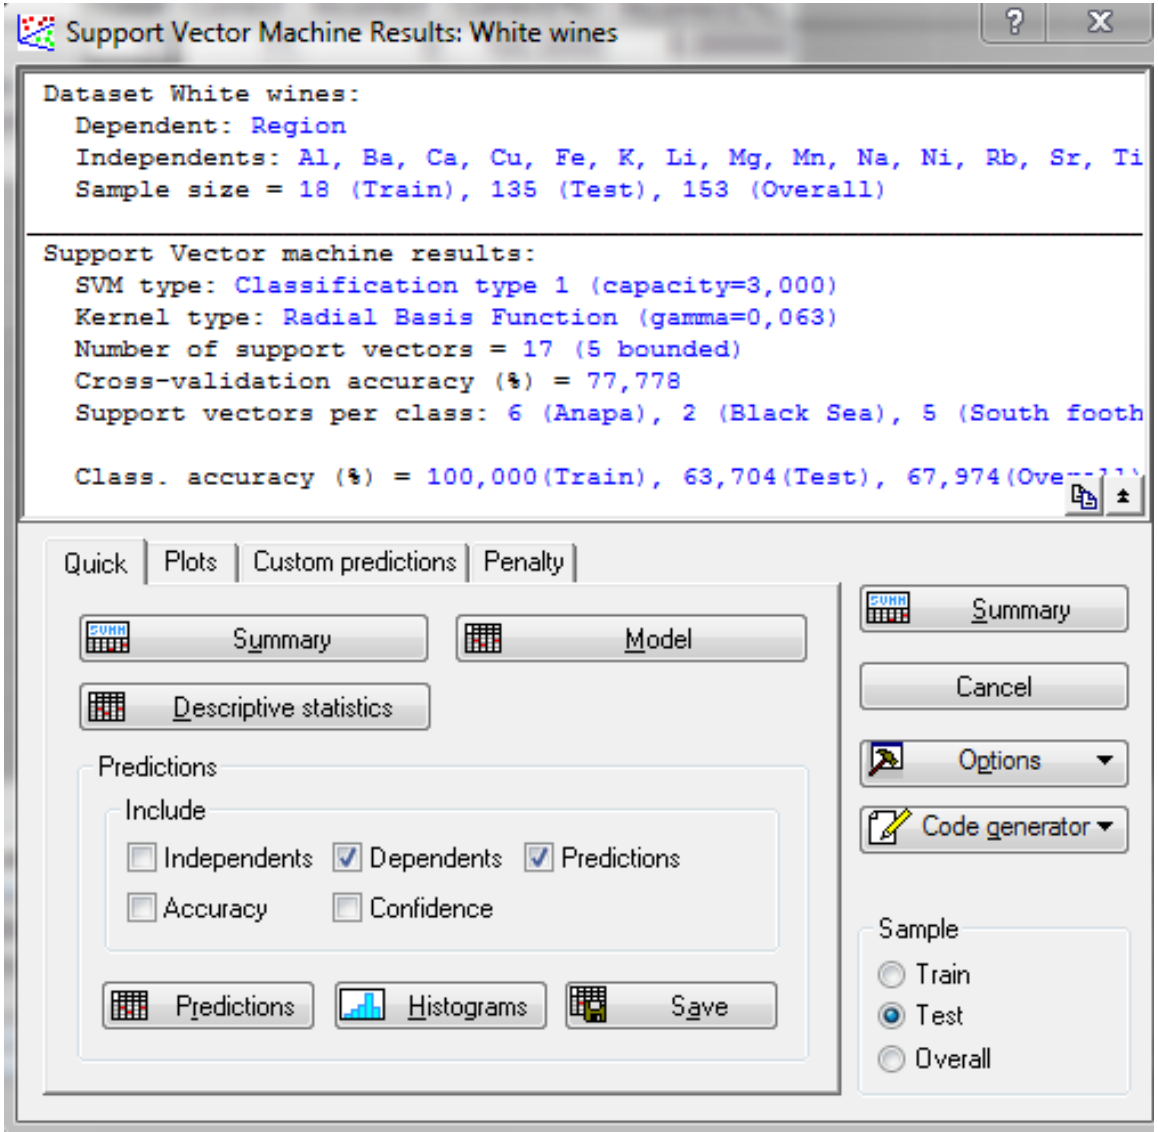

Рис.4.1.21