Лекция 8. Метод k-ближайших соседей

Чтобы понять суть метода k-nearest neighbor (k-ближайших соседей) рассмотрим задачу классификации объекта, воспользовавшись диаграммой на рис.4.2.1 [7]. Объекты представляют собою точки на плоскости, которые принадлежат 2 классам: класс 1, точки помеченные знаком «+»; класс 2 – точки помеченные знаком «–». Объект, который следует классифицировать, это точка, обозначенная красным кружком. Наша задача – классифицировать точку запроса на основе выбранного количества ее ближайших соседей. Другими словами, нас интересует, каким образом классифицировать точку запроса, как знак плюс или минус.

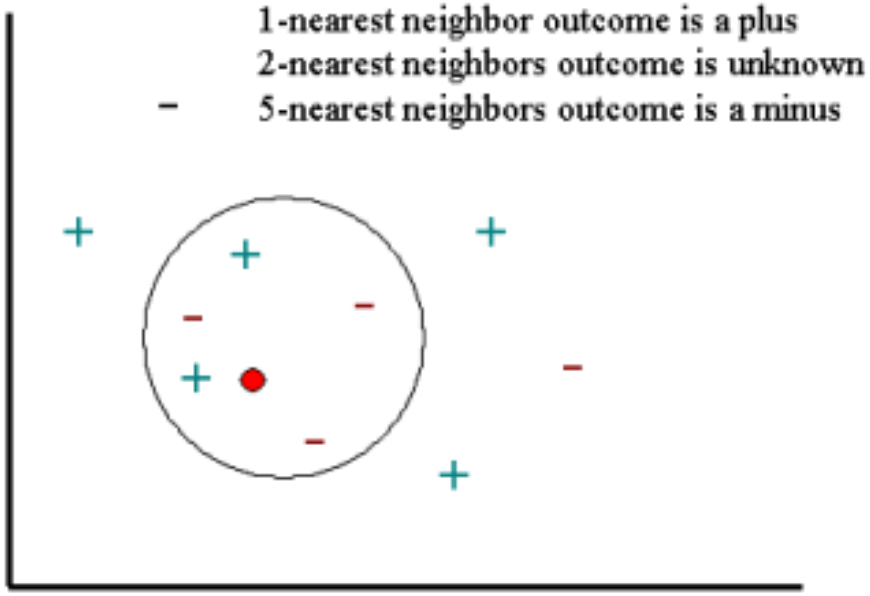

Рис.4.2.1

Сначала посмотрим, каков будет результат применения метода k-nearest neighbor (KNN), если k=1, т.е., на основе 1-ближайшего соседа. Понятно, что в этом случае KNN будет прогнозировать принадлежность точки к классу «+», поскольку ближайшая точка имеет знак плюс. Теперь увеличим количество ближайших соседей до 2. На этот раз KNN не сможет классифицировать результат точки запроса, так как вторая ближайшая точка имеет знак минус, и поэтому знаки плюс и минус набирают одинаковое количество голосов. Для следующего шага, увеличим количество ближайших соседей до 5. Это определит на плоскости область, очерченную окружностью. Поскольку имеется 2 и 3 знака плюс и минус, соответственно, в этом круге KNN присвоит результат точке запроса знак минус, т.е. определит ее принадлежность к классу «–».

Обобщим концепцию k-ближайших соседей, включив в нее задачу регрессии, проблемы которой связаны с предсказанием результата зависимой переменной с учетом набора независимых переменных. Рассмотрим схему, показанную на рис.4.2.2, где набор точек (зеленые квадратики) начерчен исходя из взаимосвязи между независимой переменной X и зависимой переменной Y (красная кривая). Применим метод k-ближайших соседей, чтобы предсказать результат X – точку запроса с учетом обучающей выборки, т.е. зеленых квадратиков.

Для начала рассмотрим случай, если k=1, т.е., на основе 1-ближайшего соседа. В этом случае мы ищем в обучающей выборке квадратик, который ближе всего к точке запроса X на оси OX между 3 и 4. Но в этом случае, ближайшая точка к X будет X_4. Но ординатой, соответствующей X_4, является Y_4. Таким образом, для 1-ближайшего соседа мы можем написать прогнозное значение: $Y = Y_4$.

Если k=2, метод определит первые две ближайшие точки к X, которые будут X_3, X_4, которым соответствуют значения на оси ординат Y_3 и Y_4. Тогда, воспользовавшись их средним значением, можно написать: $Y = (Y_3 + Y_4)/2$. Очевидно, что приведенное рассуждение может быть обобщенно до произвольного числа ближайших соседей k.

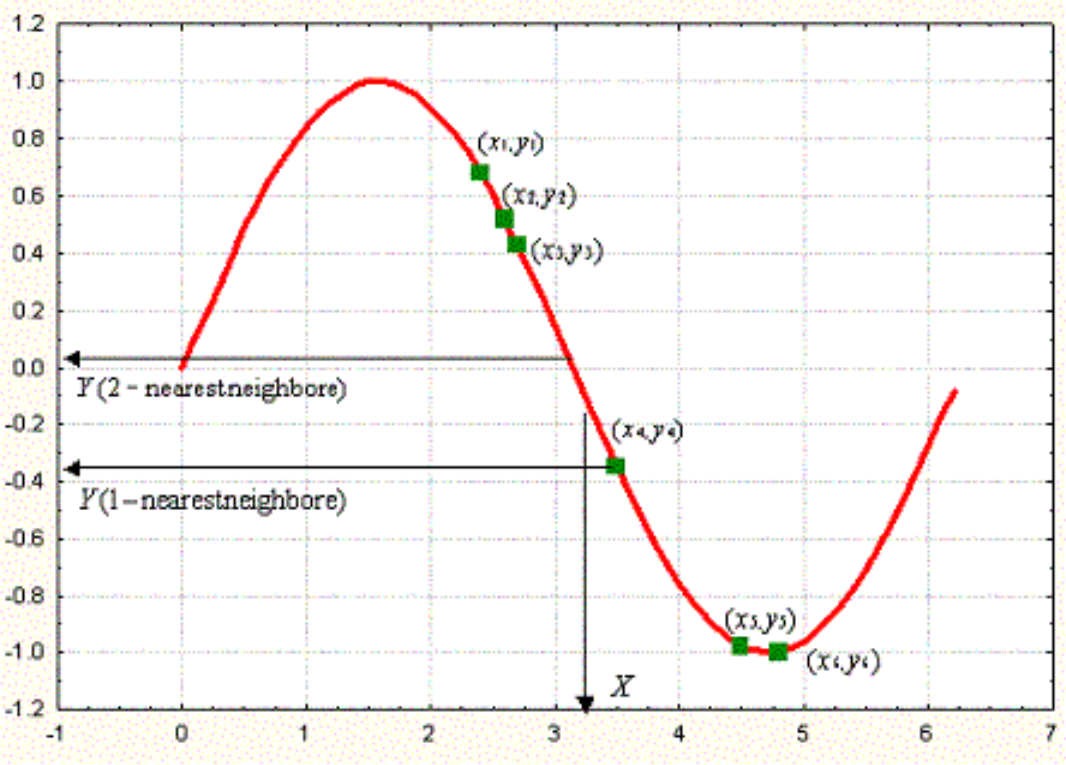

Рис.4.2.2

Таким образом, метод KNN также как и метод SVN может работать как с непрерывной (задача регрессии), так и с категориальной зависимой переменной (задача классификации). Перейдем к практической реализации метода k-ближайших соседей.

В окне методов машинного обучения выберем интересующий нас модуль K-nearest neighbor. Вкладка Quick модуля приведена на рис.4.2.3. Окно ввода переменных для анализа подобно окну метода SVM, поэтому ввод переменных организуем в соответствии с приведенным рисунком окна. Вкладка Sampling также идентична вкладке SVM, поэтому установки вкладки примем по умолчанию.

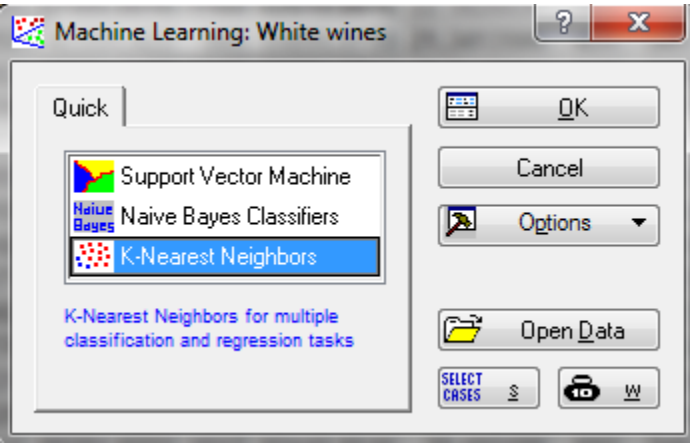

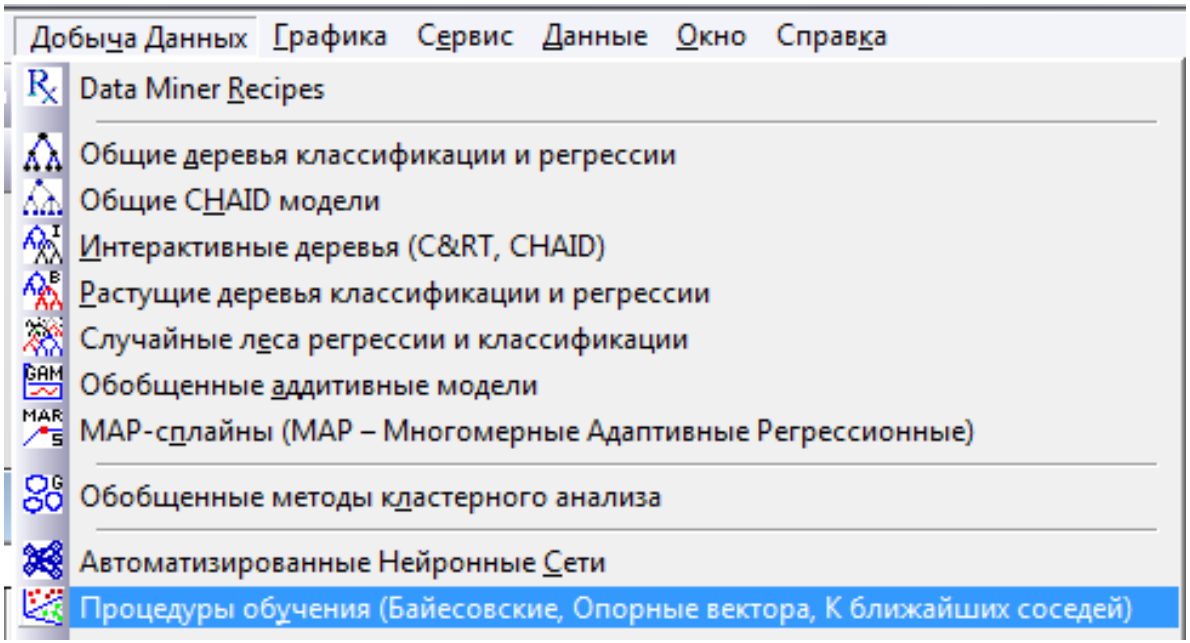

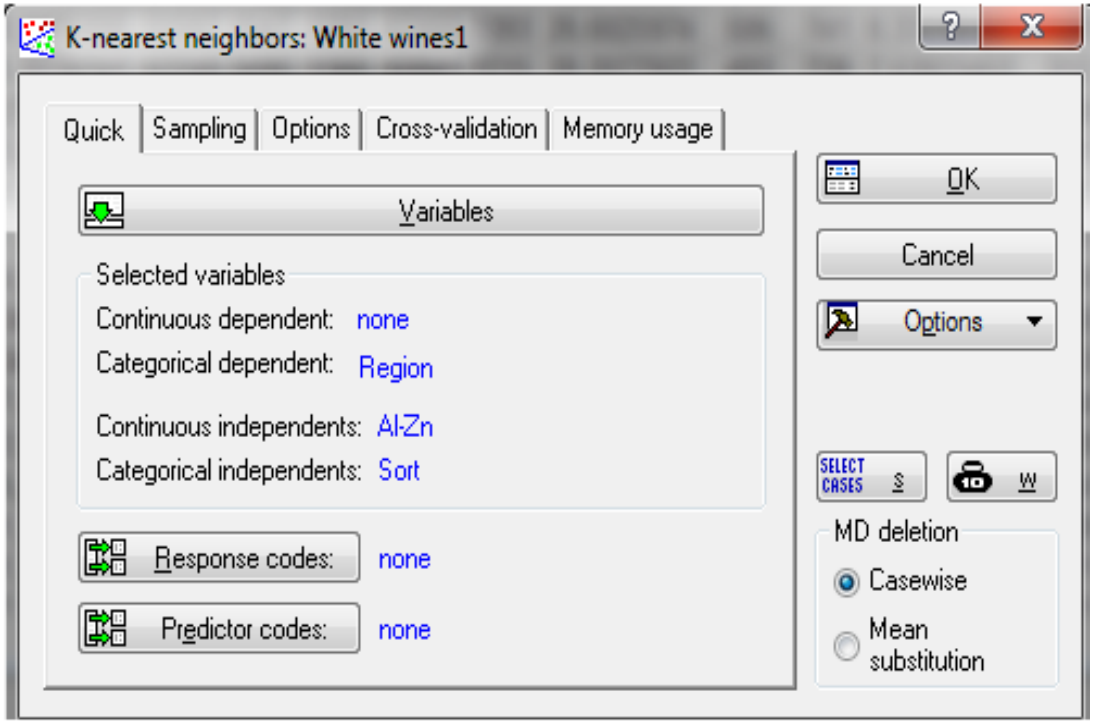
K-nearest neighbors: White wines1
Quick
Sampling
Options
Cross-validation
Memory usage
Variables
Selected variables
Continuous dependent: none
Categorical dependent: Region
Continuous independents: Al-Zn
Categorical independents: Sort
Response codes: none
Predictor codes: none
OK
Cancel
Options
SELECT CASES
MD deletion
Casewise
Mean substitution

Рис.4.2.3

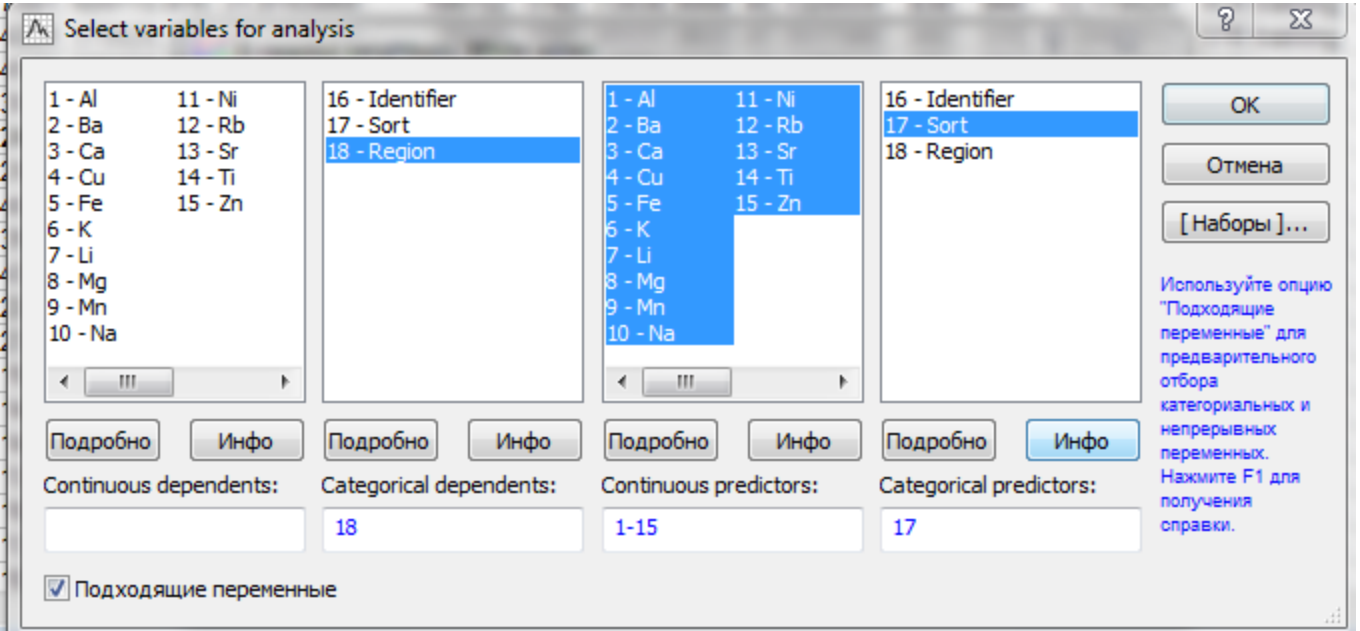
Select variables for analysis
1 - Al
2 - Ba
3 - Ca
4 - Cu
5 - Fe
6 - K
7 - Li
8 - Mg
9 - Mn
10 - Na
11 - Ni
12 - Rb
13 - Sr
14 - Ti
15 - Zn
16 - Identifier
17 - Sort
18 - Region
OK
Отмена
[Наборы]...
Используйте опцию "Подходящие переменные" для предварительного отбора категориальных и непрерывных переменных. Нажмите F1 для получения справки.
Подробно
Инфо
Continuous dependents:
Categorical dependents: 18
Continuous predictors: 1-15
Categorical predictors: 17
Подходящие переменные

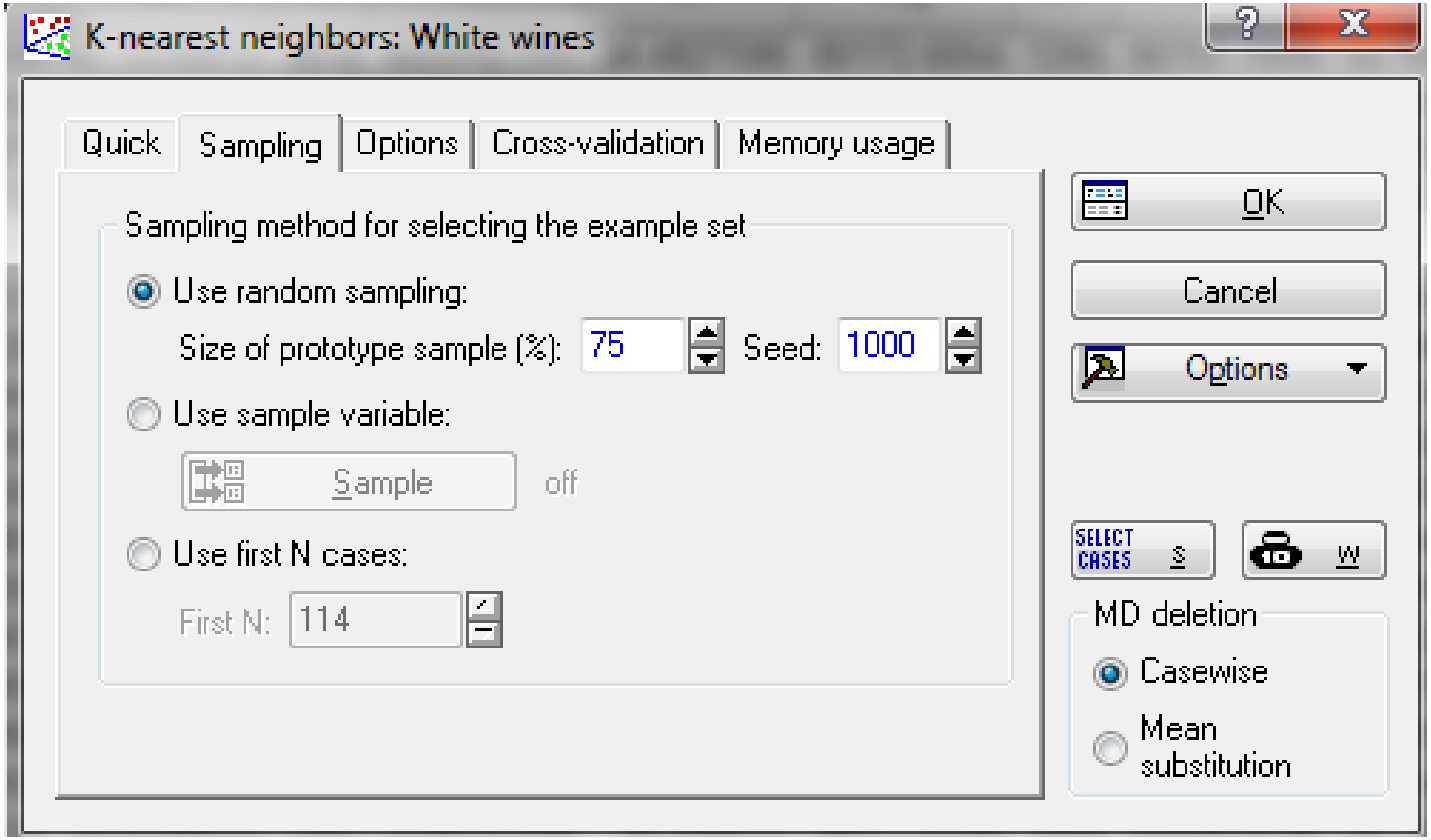
K-nearest neighbors: White wines
Quick
Sampling
Options
Cross-validation
Memory usage
Sampling method for selecting the example set
Use random sampling:
Size of prototype sample (%):
75
Seed:
1000
Use sample variable:
Sample
off
Use first N cases:
First N:
114
OK
Cancel
Options
SELECT CASES
S
W
MD deletion
Casewise
Mean substitution

На вкладке Options (рис.4.2.4) пользователь может выбрать количество ближайших соседей и одну из 5 метрик многомерных пространств, которые были описаны в модуле Generalized EM and k-Means Cluster Analysis. Как уже было замечено в главе 3, если переменные, описывающие объекты, измерены в разных единицах, или величины разных порядков, то для устранения влияния способа масштабирования переменных на результаты анализа рекомендуется стандартизовать переменные. Для этого достаточно установить флажок напротив опции Standardize distances. Если мы считаем целесообразным дать больший вес соседям, находящимся ближе к точке запроса, то следует установить флажок на Distance weighted.

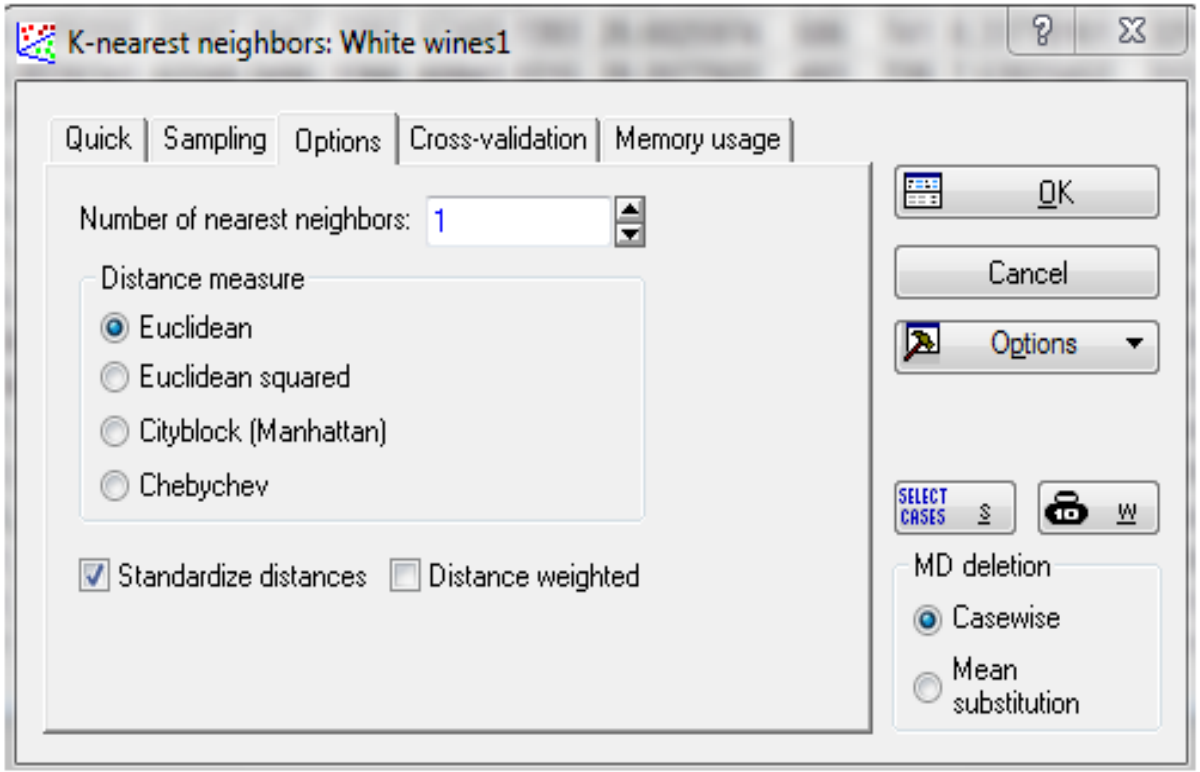

Рис.4.2.4

Вкладку Cross-validation (рис.4.2.5) мы неоднократно описывали в предыдущих разделах при описании деревьев решений, кластерного анализа, метода опорных векторов. Подчеркнем еще раз, что, если например параметр v=10, то это означает, что мы 10 раз случайным образом делим всю выборку на 10 частей, из которых 9 частей используем как обучающую выборку, а 10-ю часть, т.е. 1/10 всей выборки используем как тестовую. Находим среднюю точность по всем 10 итерациям. Применительно к методу KNN эту процедуру мы повторяем для всех значений k, задаваемых в рамке Search range for nearest neighbors (диапазон поиска ближайших соседей). По умолчанию он принят от 1 до 5, включая минимальное и максимальное значение.

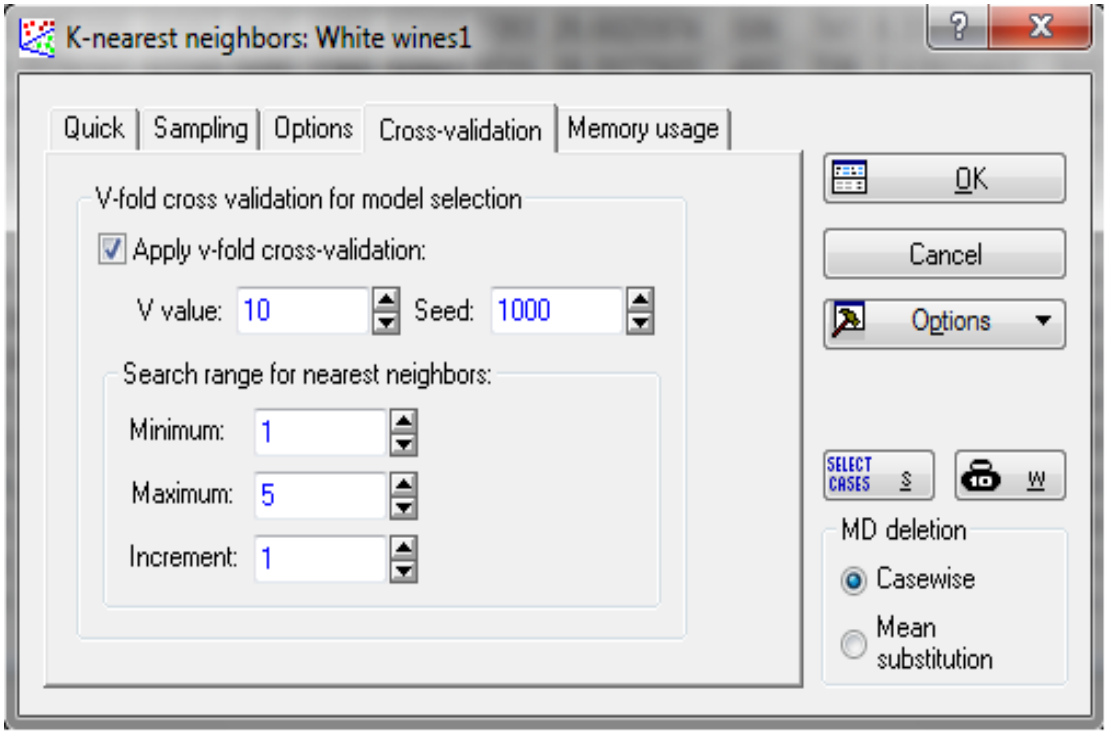

Рис.4.2.5

На вкладке Memory usage (использование памяти) пользователь получает доступ к возможности ограничить ресурсы памяти вычислительного устройства, которые могут быть затребованы методом KNN. Проблема в том, что в некоторых случаях, могут потребоваться значительные ресурсы памяти вычислительного устройства. Если установлен флажок на опции Maximum data size (максимальный размер данных в МБ), то ограничен объем физической памяти по умолчанию величиной 30 МБ, который может затребовать метод. При необходимости и в зависимости от ресурсов компьютера пользователь может изменить указанное значение.

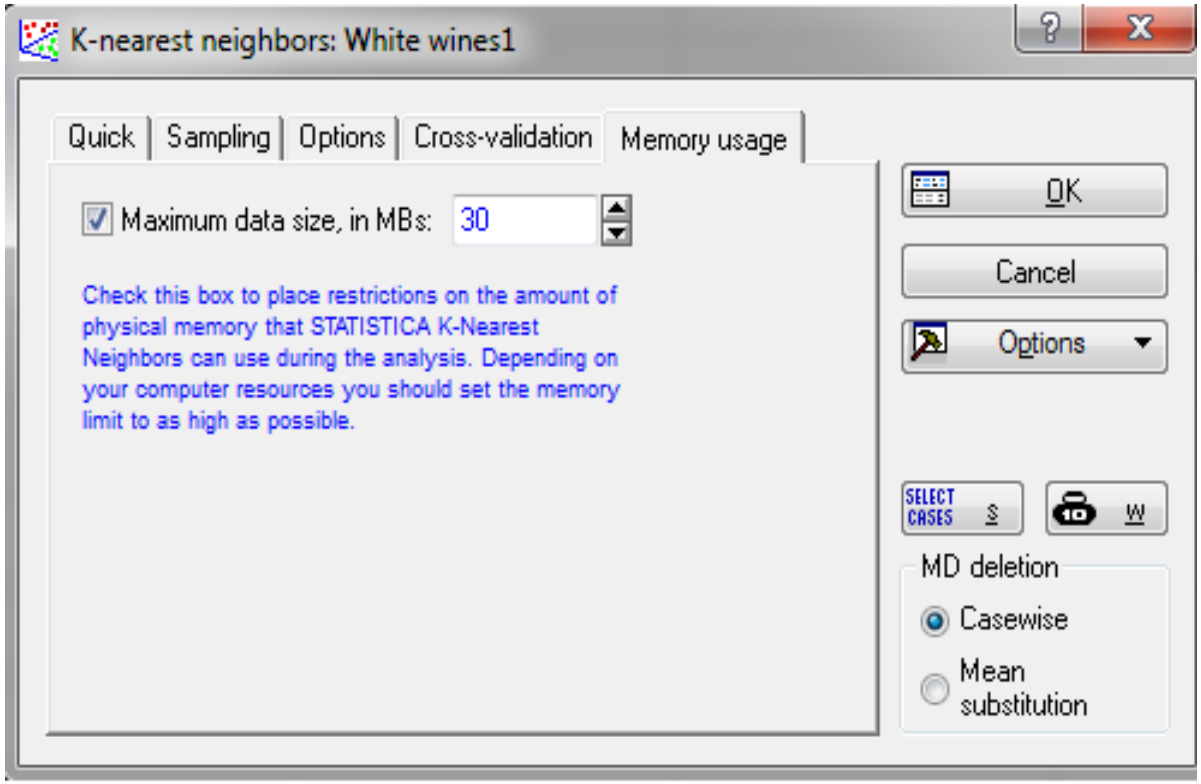

Рис.4.2.6

После нажатия на ОК в правом углу окна на рис.4.2.6 появится диалоговое окно результатов построения модели (рис.4.2.7). Легко заметить, что структура окна полностью идентична окну результатов модуля SVM, естественно, некоторые отличия присутствуют в информационной части окна. В частности из первой части окна следует, что данные разбиты на тестовую и обучающую выборку в количестве соответственно 39 и 114 образцов.

Во второй части окна – KNN results сообщается, что наилучшая классификация достигнута при числе ближайших соседей равном 1, в качестве метрики использовано евклидово расстояние, проведено нормирование данных, усреднение – равномерное, точность достигнутая кросс-проверкой 76,31579.

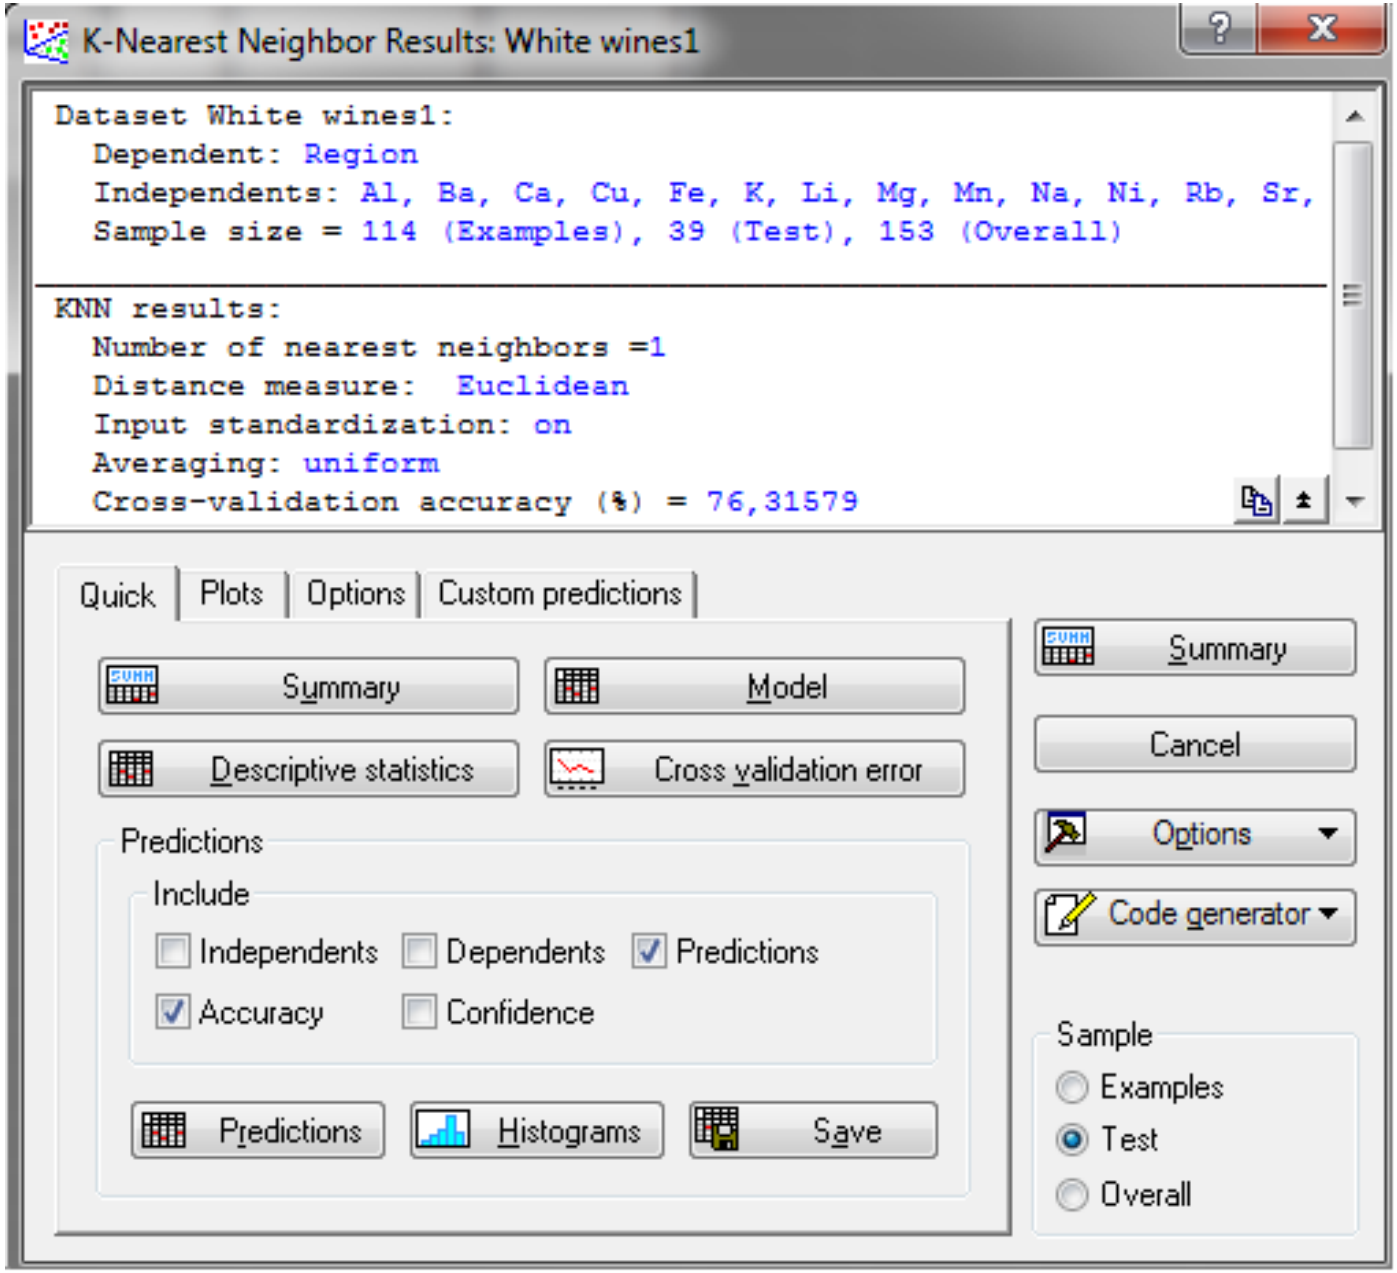
K-Nearest Neighbor Results: White wines1
Dataset White wines1:
Dependent: Region
Independents: Al, Ba, Ca, Cu, Fe, K, Li, Mg, Mn, Na, Ni, Rb, Sr,
Sample size = 114 (Examples), 39 (Test), 153 (Overall)
KNN results:
Number of nearest neighbors =1
Distance measure: Euclidean
Input standardization: on
Averaging: uniform
Cross-validation accuracy (%) = 76,31579
Quick
Plots
Options
Custom predictions
Summary
Model
Descriptive statistics
Cross validation error
Predictions
Include
Independents
Dependents
Predictions
Accuracy
Confidence
Predictions
Histograms
Save
Summary
Cancel
Options
Code generator
Sample
Examples
Test
Overall

Рис.4.2.7

При нажатии на кнопку Summary, программа отобразит табл.4.2.1, в которой приведены некоторые параметры построения модели, продублированные в информационной части окна.

Таблица 4.2.1. Итоговые параметры построения модели

	Model summary (K-Nearest Neighbors), (White wines1)
	Value
Number of independents	16
Number of dependent variables	1
Number of nearest neighbors	1
Input standardization	on
Averaging	uniform

Если нажать на кнопку Descriptive Statistics то появятся табл.4.2.2-4.2.3 со статистикой результатов классификации тестовой выборки, из которых следует, что отсутствуют ошибочные классификации – для всех 39 образцов вин из тестовой выборки принадлежность к регионам определена верно.

Таблица 4.2.2. Результаты классификации тестовой выборки

Class Name	Classification summary (K-Nearest Neighbors), Region, Test sample (White wines1) Nearest neighbors = 1, Distance: Euclidean, Standardization: on, Averaging: uniform				
	Total	Correct	Incorrect	Correct(%)	Incorrect(%)
Taman	7	7	0	100,0000	0,00
Anapa	8	8	0	100,0000	0,00
South foothill	6	6	0	100,0000	0,00
Black Sea	18	18	0	100,0000	0,00

Таблица 4.2.3. Ошибки классификации тестовой выборки

Class Predicted	Confusion matrix (K-Nearest Neighbors), Region, Test sample (White wines1) Nearest neighbors = 1, Distance: Euclidean, Standardization: on, Averaging: uniform Observed (rows) x Predicted (columns)			
	Taman	Anapa	South foothill	Black Sea
Taman	7	0	0	0
Anapa	0	8	0	0
South foothill	0	0	6	0
Black Sea	0	0	0	18

Если нажать на кнопку Prediction, то программа выведет информацию по классификации отдельно по каждому объекту тестовой выборки. Информация будет представлена в соответствии с опциями, выделенными в рамке Include, например, как это представлено на рисунке

Predictions (K-Nearest Neighbors), Test sample (White wines)
Nearest neighbors = 1, Distance: Euclidean, Standardization: on, Averaging: uniform

Case Name	**Region Dependent**	Region Predicted	Region Accuracy	Anapa Confidence	Black Sea Confidence	South foothill Confidence	Taman Confidence
1	Taman	Taman	Correct	0,000000	0,000000	0,000000	1,000000
2	Taman	Taman	Correct	0,000000	0,000000	0,000000	1,000000
4	Taman	Taman	Correct	0,000000	0,000000	0,000000	1,000000
9	Taman	Taman	Correct	0,000000	0,000000	0,000000	1,000000
16	Taman	Taman	Correct	0,000000	0,000000	0,000000	1,000000
21	Taman	Taman	Correct	0,000000	0,000000	0,000000	1,000000
22	Taman	Taman	Correct	0,000000	0,000000	0,000000	1,000000
27	Anapa	Anapa	Correct	1,000000	0,000000	0,000000	0,000000
31	Anapa	Anapa	Correct	1,000000	0,000000	0,000000	0,000000
35	Anapa	Anapa	Correct	1,000000	0,000000	0,000000	0,000000
36	Anapa	Anapa	Correct	1,000000	0,000000	0,000000	0,000000
42	South foothill	South foothill	Correct	0,000000	0,000000	1,000000	0,000000
43	Black Sea	Black Sea	Correct	0,000000	1,000000	0,000000	0,000000
46	Black Sea	Black Sea	Correct	0,000000	1,000000	0,000000	0,000000
54	Taman	Taman	Correct	0,000000	0,000000	0,000000	1,000000
55	Taman	Taman	Correct	0,000000	0,000000	0,000000	1,000000
79	South foothill	South foothill	Correct	0,000000	0,000000	1,000000	0,000000
80	Black Sea	Black Sea	Correct	0,000000	1,000000	0,000000	0,000000
84	Black Sea	Black Sea	Correct	0,000000	1,000000	0,000000	0,000000
88	Black Sea	Black Sea	Correct	0,000000	1,000000	0,000000	0,000000
89	Black Sea	Black Sea	Correct	0,000000	1,000000	0,000000	0,000000
91	Black Sea	Black Sea	Correct	0,000000	1,000000	0,000000	0,000000
100	Taman	Taman	Correct	0,000000	0,000000	0,000000	1,000000

После нажатия на кнопку Cross validation error, программа построит график (рис.4.2.8) изменения средней точности классификации, достигнутой кросс-проверкой при изменении значений количества ближайших соседей k в диапазоне (1 – 5), указанном в окне на рис.4.2.5. Из графика видно, что наибольшая точность достигнута для k=1.

Результаты классификации обучающей выборки (example), всей выборки (overall) программой не показываются. Функциональное назначение остальных кнопок и опций окна полностью идентичны одноименному окну метода SVM. Вкладки Plots, Custom predictions также идентичны одноименным вкладкам, описанным в модуле метода SVM.

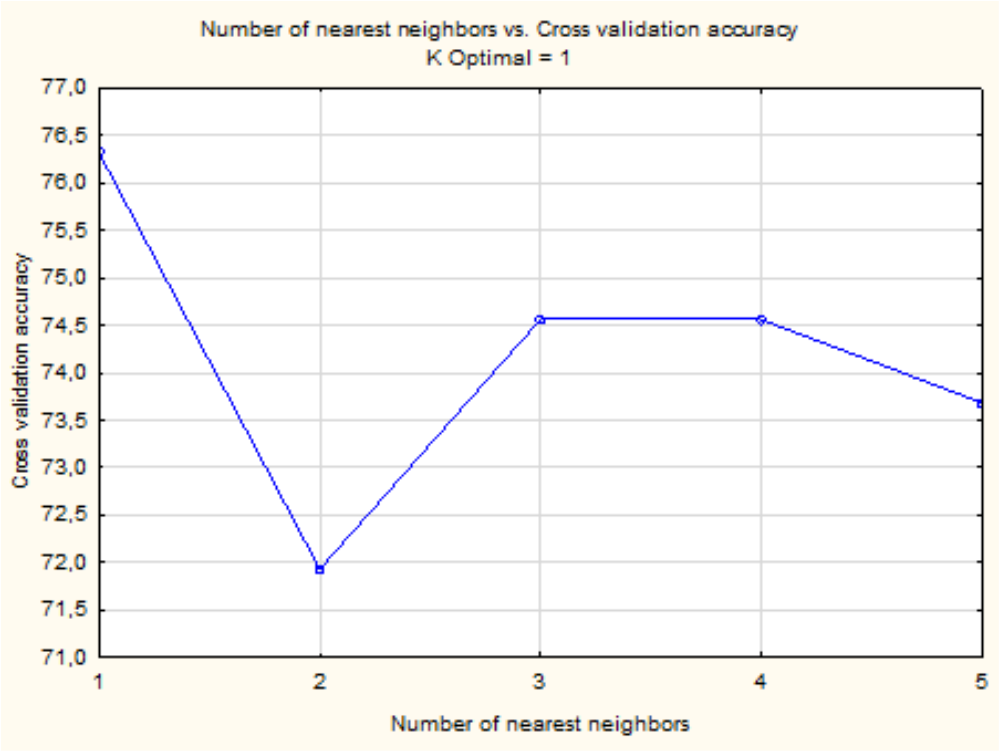

Рис.4.2.8

Если выбрать способ 2 разделения на обучающую и тестовую выборку, т.е. при помощи переменной идентификатора, остальные параметры задать по умолчанию, задать кросс-проверку, то программа выберет оптимальное число ближайших соседей равное 5.

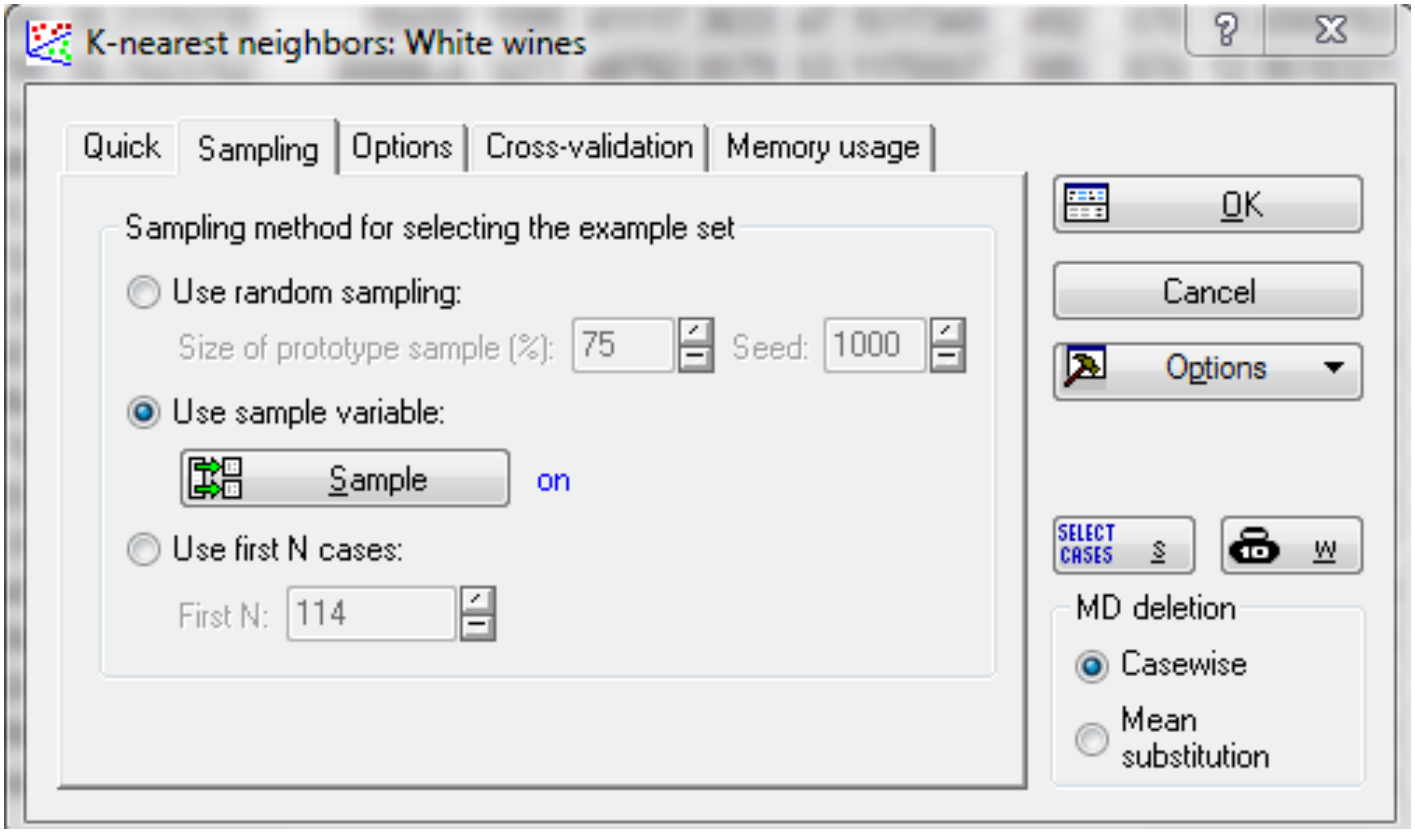

Как видно количество ошибок на тестовой выборке равно 2, задание добиться классификации с точностью 100%

Class Name	Classification summary (K-Nearest Neighbors), Region, Test sample (White wines) Nearest neighbors = 5, Distance: Euclidean, Standardization: on, Averaging: uniform				
	Total	Correct	Incorrect	Correct(%)	Incorrect(%)
Taman	1	1	0	100,0000	0,00000
Anapa	4	4	0	100,0000	0,00000
South foothill	7	5	2	71,4286	28,57143
Black Sea	6	6	0	100,0000	0,00000

Class Predicted	Confusion matrix (K-Nearest Neighbors), Region, Test sample (White wines) Nearest neighbors = 5, Distance: Euclidean, Standardization: on, Averaging: uniform Observed (rows) x Predicted (columns)			
	Taman	Anapa	South foothill	Black Sea
Taman	1	0	2	0
Anapa	0	4	0	0
South foothill	0	0	5	0
Black Sea	0	0	0	6