Лекция 10. ANS. Классификация

За последние десятилетия значительно возрос интерес к нейронным сетям (neural networks, NN). Причем по мере развития информационных технологий и расширения сферы их применения интерес к нейросетевым технология только усиливается. Все началось с успешного применения этого метода обработки данных в широком спектре таких областей, как финансы, медицина, инженерия, геология и др. Огромный успех NN можно объяснить их мощностью, универсальностью и простотой использования. Нейронные сети – это совокупность методов моделирования чрезвычайно сложных функций и нелинейных взаимосвязей данных [7].

Способность учиться на данных – обучающих выборках является одной из функций NN, которая позволяет пользователю моделировать данные и устанавливать точные правила, регулирующие базовые отношения между их различными атрибутами. Учитывая тот факт, что алгоритмы обучения могут автоматически изучать структуру данных, казалось бы, пользователю достаточно подготовить репрезентативные данные. Но, на самом деле это не так – хотя пользователю действительно нужны некоторые эвристические знания о том, как выбирать и готовить данные, он должен уметь подобрать соответствующую нейронную сеть и, главное правильно интерпретировать результаты. Поэтому, в большинстве случаев, уровень знаний пользователя, необходимый для успешного применения NN, намного ниже, чем необходимый. Это объясняется тем, что в большинстве традиционных статистических инструментов и методов, алгоритмы нейронной сети скрыты за хорошо спроектированными и интеллектуальными компьютерными программами, которые проводят пользователя от начала до конца всего за несколько кликов.

Использование NN весьма и весьма широкое, охватывает различные области как научной, так и практической деятельности человека. Объяснение этому феномену простое – NN обладают замечательной способностью извлекать знания, правила и тенденции из сложных, зашумленных и неточных данных. Эти знания представляют собою определенные закономерности, тенденции, которые описываются сложными математическими функциями. Как правило, такие закономерности сложно, а зачастую и невозможно смоделировать с использованием аналитических или параметрических методов.

Другая примечательная возможность NN – с высокой достоверностью **предсказывать данные**, которые не были частью обучающей выборки. Учитывая приведенные характеристики NN и их широкую применимость, NN подходят для решения реальных проблем в исследованиях и науке, бизнесе, промышленности, сельском хозяйстве, медицине и т.д. Как пример, короткий перечень некоторых областей, в которых нейронные сети были успешно применены в обработке сигналов, контроле над процессом, робототехнике, классификации, распознавании образов, анализе изображений и речи, медицинской диагностике и др.

Нейронные сети интуитивно привлекательны и понимаемы человеком, поскольку многие из их принципов основаны на грубых и низкоуровневых моделях биологических систем обработки нейронной информации. Нейронные сети возникли в результате исследований в области искусственного интеллекта, в основном вдохновленных попытками имитировать отказоустойчивость и «способность к обучению» биологических нейронных систем путем моделирования низкоуровневой структуры мозга. Мозг в основном состоит из очень большого числа (примерно десяти миллиардов) нейронов, тесно связанных между собой несколькими тысячами соединений, приходящими на нейрон. Каждый нейрон представляет собой специализированную клетку, которая может создавать, распространять и получать электрохимические сигналы. Как и любая биологическая клетка, нейрон имеет тело, ветвящуюся входную структуру, называемую **дендритами**, и ветвящуюся выходную структуру, известную как **аксон**.

Аксоны одной клетки соединяются с дендритами другой через синапс. Когда нейрон активируется, он посылает электрохимический сигнал по аксону. Этот сигнал проходит через синапсы к тысячам и более других нейронов, которые, в свою очередь, могут активироваться, тем самым распространяя сигнал по всей нервной сети – биологическому мозгу. Чтобы нейроны постоянно не транслировали сигналы, они срабатывают, только если общий сигнал, полученный телом клетки от дендритов, превышает определенный уровень, известный как порог. **Следует заметить, что отдельный нейрон сам по себе не выполняет никакой значимой отдельной задачи, но когда объединяются усилия большого их количества – ансамбля взаимосвязанных нейронов, результаты становятся весьма значительными, поскольку они могут выполнять различные и чрезвычайно сложные когнитивные задачи, такие как обучение и мыслительная деятельность.** При этом примечательно то, что мозг выполняет сложные задачи с помощью очень большого количества чрезвычайно простых «процессоров». По этому принципу построены и искусственные нейронные сети – они могут достигать некоторых замечательных результатов, используя весьма простую базовую математическую модель, схема которой изображена на рис.5.1.1.

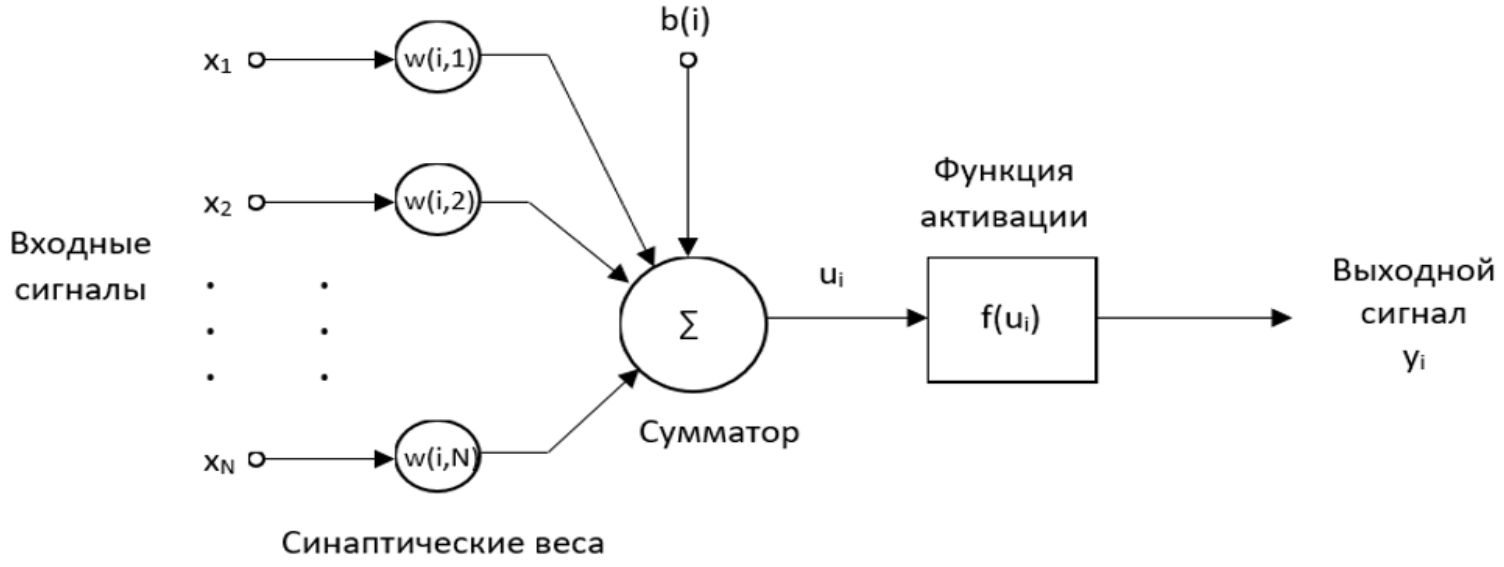

Рис.5.1.1.

Из представленной схемы одиночной нейронной системы следует, что входы X_d отправляют сигналы нейрону, после чего получается взвешенная сумма сигналов, которая затем преобразуется с использованием математической функции f. На схеме представлена простейшая форма искусственных нейронных сетей с одним нейроном с несколькими входами и одним (для простоты) выходом. Источники сигналов, поступающих на входы, называются входными переменными X_d или просто входами. Данные, формирующиеся на выходе нейронных сетей, называются результатами расчетов. Мы использовали эту простую модель для объяснения некоторых основных функций и принципов нейронных сетей, а также для описания отдельного нейрона.

Однако, как упоминалось ранее, отдельный нейрон не может выполнять значимую задачу самостоятельно. Вместо этого для достижения какой-либо конкретной цели необходимо множество взаимосвязанных нейронов, что требует применение большего количества архитектур нейронных сетей, используемых в практических приложениях. Обучение NN – процесс оптимизации весов, в котором минимизируется ошибка предсказания, и сеть достигает требуемого уровня точности.

Функцию f называют функцией активации. Используется несколько видов функции активации: линейная, ступенчатая, сигмоидная, тангенциальная, выпрямительная (рис.5.1.2 – 5.1.7).

Линейная функция

$f(x)=ax$

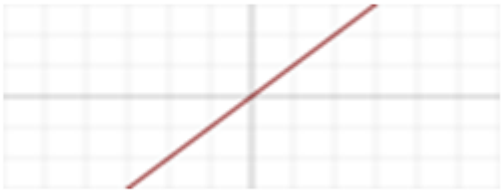

Рис.5.1.2

Ступенчатая функция

$$f(x) = \begin{cases} 0 & \text{for} \quad x < 0 \\ 1 & \text{for} \quad x \geq 0 \end{cases}$$

Рис.5.1.3

Сигмоида

$$f(x) = \frac{1}{1+e^{-x}}$$

Рис.5.1.4

Функция гиперболического тангенса

$$f(x) = \tanh(x) = \frac{2}{1+e^{-2x}} - 1$$

Рис.5.1.5

Функция линейного выпрямителя

$$f(x) = \begin{cases} 0 & \text{for} \quad x < 0 \\ x & \text{for} \quad x \geq 0 \end{cases}$$

Рис.5.1.6

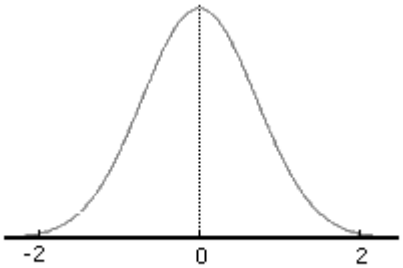

Рис.5.1.7

Радиально-базисная функция характеризуется тем, что она монотонно убывает с удалением от центральной точки. Типичный пример такой функции – функция Гаусса, имеющая следующее аналитическое представление:

$$h(x) = \exp(-(x-c)^2/r^2)$$

Для случая c = 0 и r = 1 график функции изображен на рис.5.1.7

Нейронные сети отличаются не только функцией активации, но и своей архитектурой. Наиболее популярные из них – многослойный персептрон (MLP), сеть радиально-базисных функций (RBF), сверточная нейронная сеть (CNN), рекурсивная нейронная сеть (RvNN), рекуррентная нейронная сеть (RNN), сеть с долгой краткосрочной памятью (LSTM) и др. Архитектура сети определяет область их применения. Так MLP применяют в задачах распознавания речи и машинном переводе, классификации, регрессии, прогнозировании временных рядов. RNN используют в распознании рукописного текста или речи, RvNN – при обучении последовательных структур и деревьев в задачах обработки естественного языка, LSTM – в крупномасштабном акустическом моделировании, CNN показывают хорошие результаты в приложениях к картинкам, тексту и речи и т.д. Сети радиальных базисных функций имеют множество применений, в том числе функции приближения, прогнозирования временных рядов, классификации и системы управления. В модуле STATISTICA Automated Neural Networks реализованы сети MLP и RBF.

Перейдем к практической реализации метода. Выберем модуль Automated Neural Networks в меню Data Mining в окне, изображенном на рис.2.1.2. Стартовое окно модуля SANN (STATISTICA Automated Neural Networks) содержит одну вкладку New Analysis / Deployment (новый анализ / Развертывание) (рис.5.1.8). Альтернативная часть вкладки Deployment, предусматривающая развертывание моделей из предыдущих анализов, актуальна, если ранее уже были созданы автоматизированные нейронные сети, сохраненные в файлах в формате PMML. Можно выбрать несколько моделей, если они были созданы с использованием одного и того же типа анализа (например, регрессии, классификации, кластеризации и т.д.). При этом модели нейронных сетей, сохраненные в файлах PMML, должны иметь одинаковое количество входных переменных с соответствующими именами и порядком. Все категориальные переменные должны иметь одинаковое количество категорий и быть представлены в одном порядке.

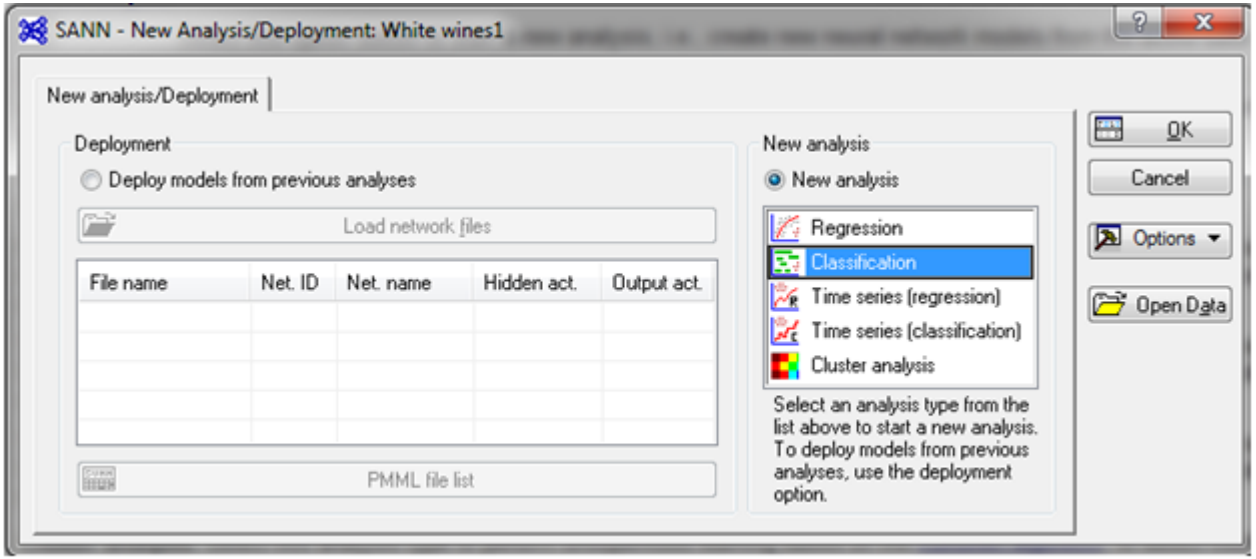

Рис.5.1.8

Для развертывания сетей следует выделить опцию Deployment и нажать на кнопку Load network files (Загрузите сетевые файлы). Появится диалоговое окно Open, которое используется для поиска ранее сохраненных сетевых файлов. Опции для сохранения сетей доступны в диалоговых окнах SANN - Results, SANN - Custom Neural Network, SANN - Automated Network Search (ANS), and SANN - Subsampling. Под кнопкой Load network files находится окно со списком моделей сетей, которые были успешно загружены и проанализированы автоматизированными нейронными сетями STATISTICA. Этот список включает последовательный идентификатор сети, названия моделей и типы функций активации, как для скрытых, так и для выходных устройств.

Кнопка PMML file list (список файлов PMML) инициирует выгрузку текущей электронной таблицы PMML. Таблица включает список всех сетевых файлов PMML, которые пытались загрузить в последний раз, включая те, которые не удалось успешно проанализировать. Просматривая эту электронную таблицу, пользователь можете определить, какие файлы не удалось загрузить.

Основная часть вкладки New Analysis предназначена для начала нового анализа, т. е. создания новой модели нейронной сети из активного набора данных. Пользователь может выбрать тип анализа, который предполагается выполнить. Выбор типа анализа ограничивает типы переменных, которые можно назначить входными – независимым и зависимым переменными, чтобы соответствовать указанному типу анализа.

Regression. Регрессионный анализ обычно связан с прогнозированием одной или нескольких непрерывных зависимых переменных по значениям предикторных независимых переменных из набора входных данных. Этот тип анализа имеет место только, если зависимые переменные имеют непрерывный характер.

Classification. Классификационный анализ определяет принадлежность объекта к тому, или иному классу из набора входных переменных значениями категориальной зависимой переменной (отклика). Для классификационного анализа можно указать только одну зависимую категориальную переменную.

Time series (*regression*). Временной ряд (регрессия) имеет место быть, если зависимые переменные являются непрерывными по своей природе и зависят от временной компоненты. Решается задача прогнозирования значения непрерывного отклика на будущий момент времени.

Time series (*classification*). Временной ряд (классификация) предполагает, что отклик носит категориальный характер и включает в себя временную компоненту. Решается задача прогнозирования значения категориального отклика на будущий момент времени.

Cluster analysis. Кластерный анализ выполняет обучение без учителя на основе алгоритма Кохонена для обнаружения групп однородности – кластеров в наборе данных.

Рассмотрим практическую реализацию модуля, решая ту же задачу классификации, что и ранее рассмотренными методами. Для этого выделим опцию New Analysis, выберем тип анализа Classification и щелкнем по OK, откроется диалоговое окно SANN - Data selection (рис.5.1.9).

Традиционно на вкладке Quick при помощи кнопки Variable можно задать переменные для анализа. Нажмем на кнопку Variables, и в открывшемся окне (рис.5.1.10) высветим в соответствии с предназначением полей имена зависимых и независимых переменных.

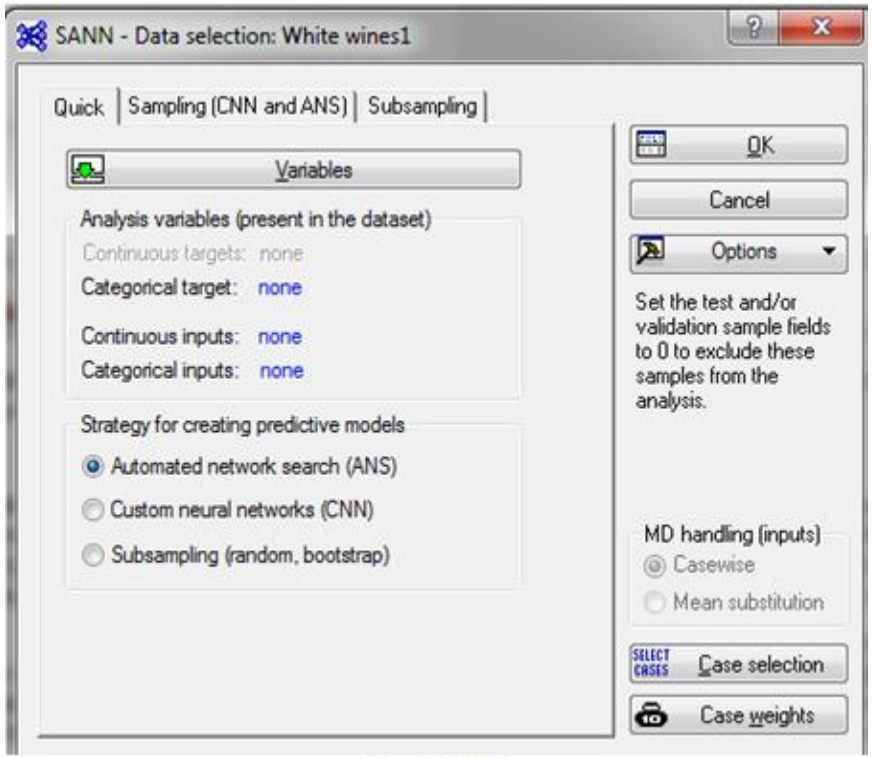

Рис.5.1.9

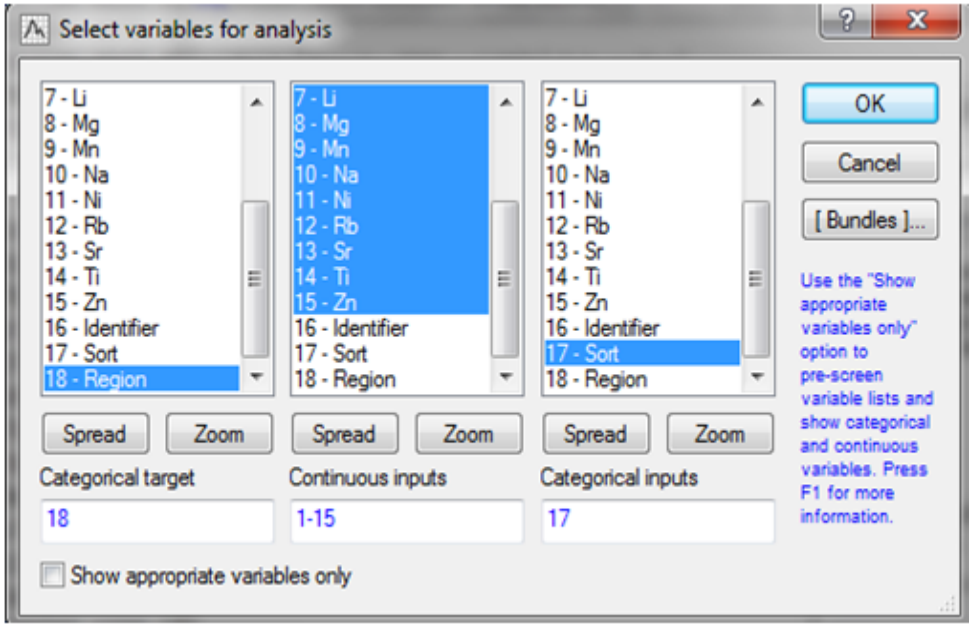

Рис.5.1.10

Естественно структура рамки Analysis variable зависит от выбранного пользователем типа анализа. В рамке Strategy for creating predictive models (Стратегия создания прогнозных моделей) можно выбрать различные стратегии создания нейронных сетей:

1. Automated network search (ANS) (Автоматический сетевой поиск) можно использовать для создания нейронных сетей с различными настройками и конфигурациями выбранными программой автоматически при минимальных усилиях со стороны пользователя. ANS проектирует ряд сетей для решения задачи, а затем выбирает те сети, которые лучше всего представляют отношения между входными и зависимыми переменными. Заметим, что стратегия ANS недоступна для кластерного анализа. ANS также не применяется при развертывании (Deployment) моделей, поскольку в этом случае не требуется обучение нейронных сетей.

2. Custom neural networks (CNN) (Пользовательские нейронные сети) в отличие от ANS позволяют пользователю выбирать индивидуальные сетевые архитектуры и алгоритмы обучения в соответствии с заданными спецификациями. Так, например, можно использовать CNN для обучения нескольких моделей нейронных сетей с одинаковыми проектными спецификациями, но с **разной** случайной инициализацией весов. В результате каждая сеть найдет одно из возможных решений, предлагаемых нейронными сетями той же архитектуры и конфигурации.

Если в диалоге на рис. 5.1.9 выбрать опцию Custom neural networks (CNN) и щелкнуть по ОК откроется окно на вкладке Quick, изображенное на рис.5.1.11. Пользователю будет предоставлена возможность самостоятельно выбрать следующие спецификации сетей – **тип сети** (MLP, RBF); **функцию ошибки** (Error function – сумма квадратов, Cross entropy – кросс-энтропия); **функцию активации нейронов скрытого слоя** (Activation function hidden units); **функцию активации нейронов выходного слоя** (Output units**), количество обученных сетей** (Network to train) и **число скрытых слоев** – нейронов (No. of neurons). Опция **Output units** не активна при выборе функции ошибки **Cross entropy**.

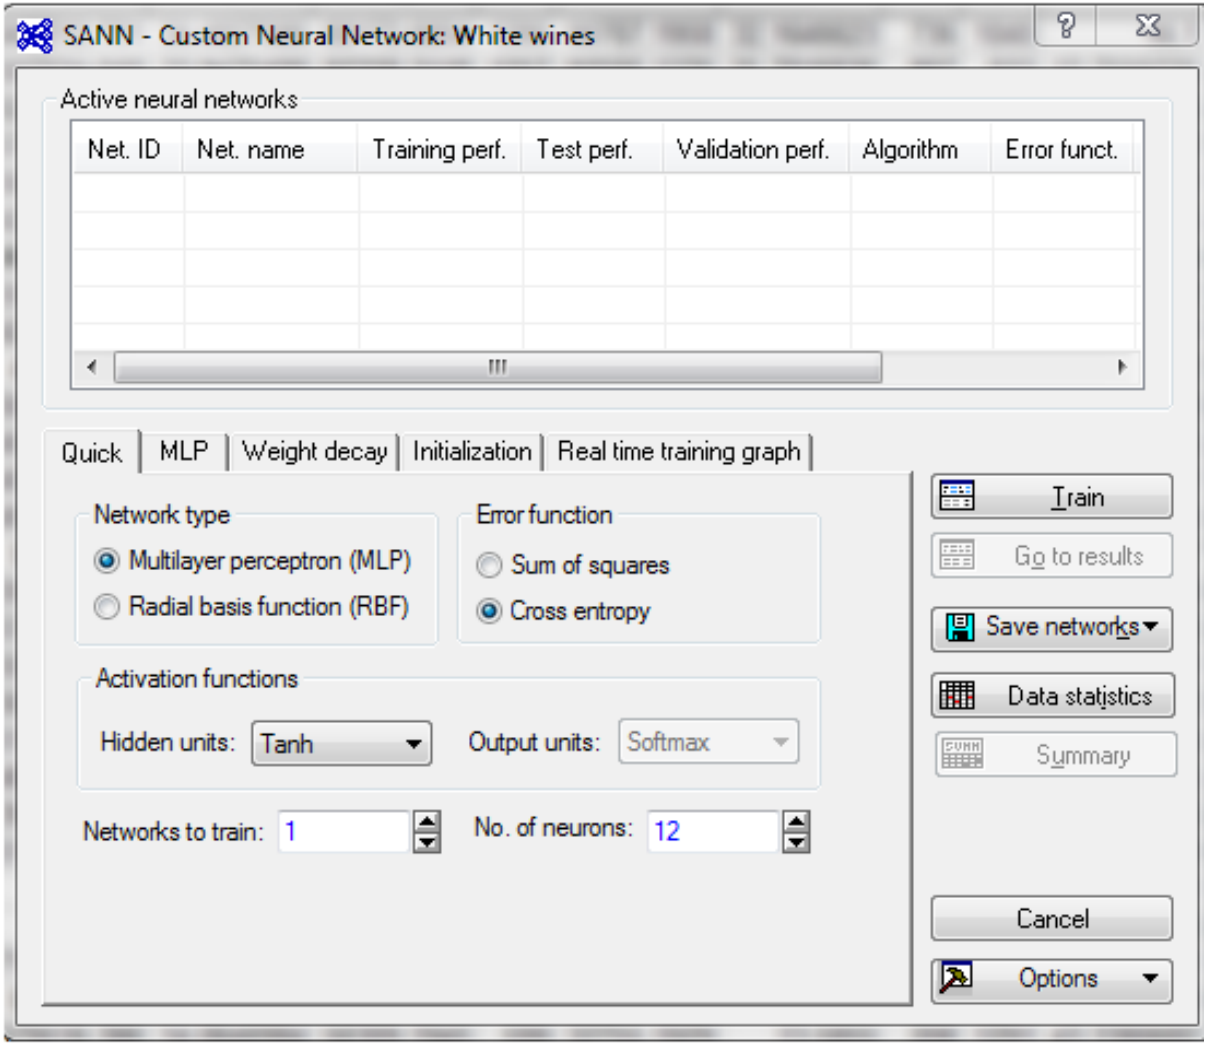
SANN - Custom Neural Network: White wines
Active neural networks
Net. ID
Net. name
Training perf.
Test perf.
Validation perf.
Algorithm
Error funct.
Quick
MLP
Weight decay
Initialization
Real time training graph
Network type
Multilayer perceptron (MLP)
Radial basis function (RBF)
Error function
Sum of squares
Cross entropy
Activation functions
Hidden units:
Tanh
Output units:
Softmax
Networks to train:
1
No. of neurons:
12
Train
Go to results
Save networks
Data statistics
Summary
Cancel
Options

Рис.5.1.11

3. Subsampling (random, bootstrap) использует одну из стратегий субдискретизации – случайную (random), или бутстрапную (bootstrap). Данный инструментарий позволяет построить нейронные сети на основе нескольких подвыборок исходного набора данных. Отличие этих двух стратегий в том, что при первой (random) генерируется случайным образом несколько подвыборок исходного набора данных без возвращения; при второй (bootstrap) – с возвращением. Параметры для стратегии субдискретизации доступны, если в диалоге на рис. 5.1.9 выбрать одноименную опцию. При этом станет активной вкладка Subsampling (рис.5.1.13). На этой вкладке можно определить доли (%) обучающей (train), контрольной (validation) и тестовой (test) выборок, а также количество подвыборок (Number of subsamples) – по умолчанию 2 и начальные условия для датчика случайных чисел (Seed for Subsampling). Опции окна не меняются, если изменить стратегию субдискретизации, например с случайной на бутстрапную. Если щелкнуть по ОК откроется на вкладке Quick окно (рис.5.1.12), сходное по предоставленным пользователю возможностям выбора спецификаций сети с окном на рис.5.1.11. Лишь отсутствует опция Network to train, т.е. возможность выбора числа обученных сетей, которое определяется выбором числа подвыборок – по умолчанию 2 на вкладке Subsampling (рис.5.1.13).

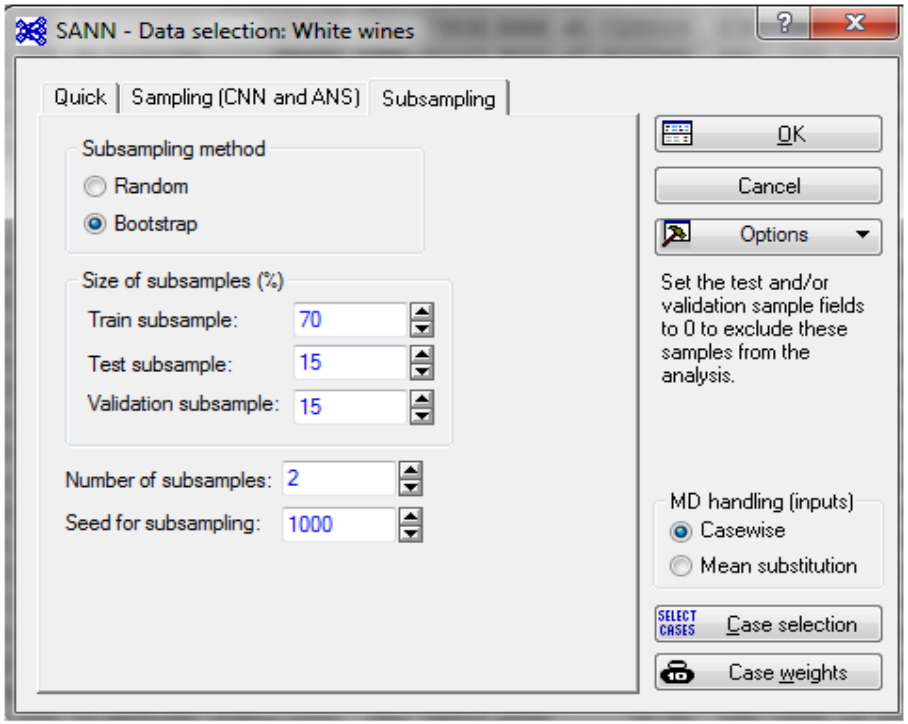

Рис.5.1.13

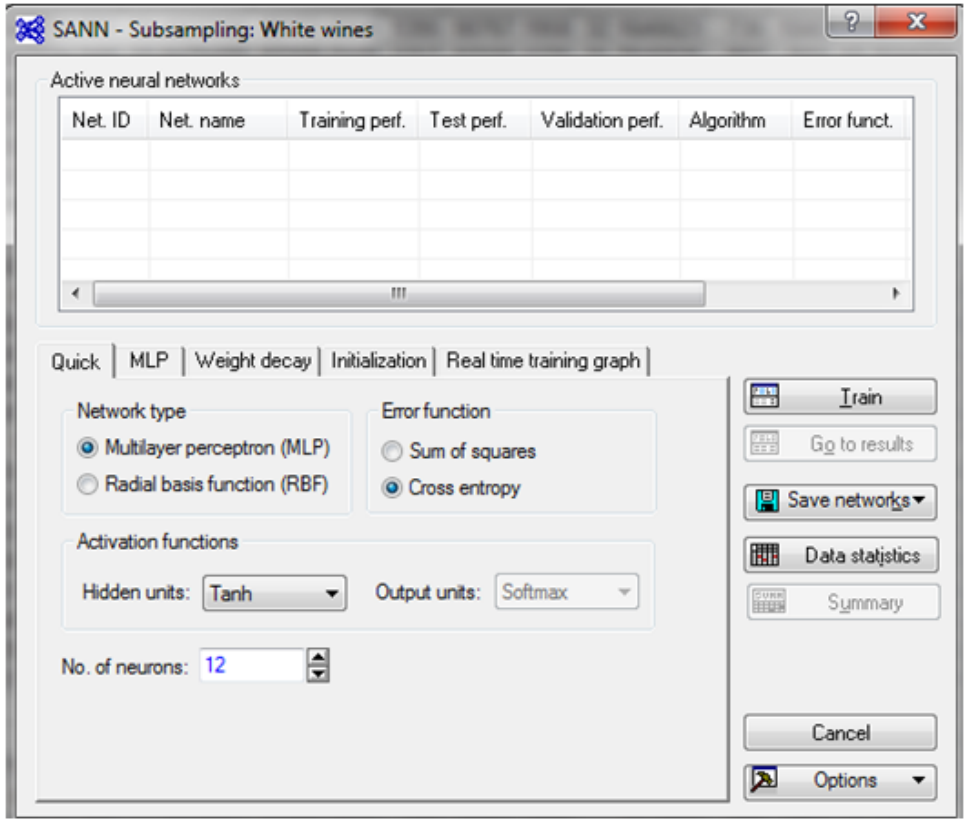

Рис.5.1.12

Вернемся к диалогу на рис.5.1.9, выделим опцию Automated network search (ANS) и перейдем на вкладку Sampling (CNN and ANS) (рис.5.1.14). Производительность нейронной сети измеряется тем, насколько хорошо она обобщается на данные, которые не использовались во время обучения. Проблема обобщения на самом деле является одной из основных проблем при обучении нейронных сетей, как в прочем и других методов машинного обучения. Когда сеть подогнана к обучающим данным так, что воспроизводится даже случайный шум в конкретном наборе данных, сети трудно делать точные прогнозы с использованием новых данных при ее развертывании. Одним из способов решения этой проблемы является разделение данных на два (или три) подмножества: обучающую выборку, тестовую и проверочную (контрольную) выборку.

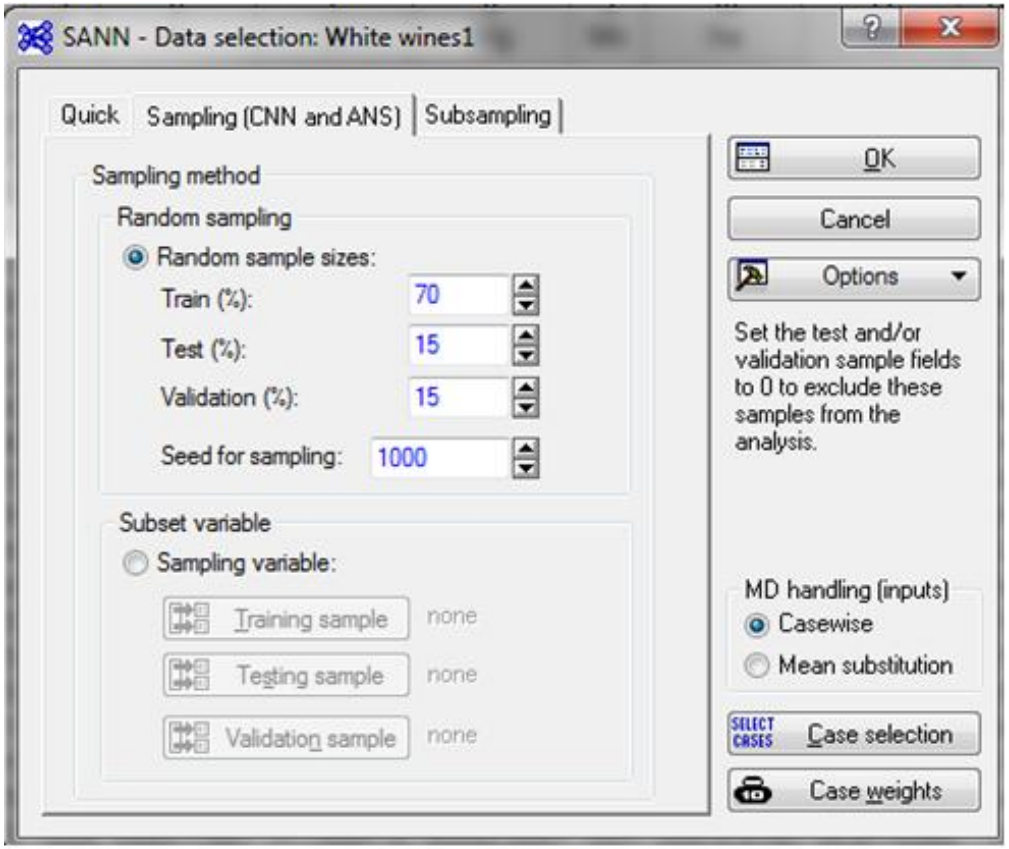

Рис.5.1.14

Затем эти выборки можно использовать соответственно для обучения сети, проверки (тестирования) ее производительности во время обучения и выполнения финальных проверочных тестов, чтобы определить, насколько хорошо сеть прогнозирует «новые» данные, которые не использовались ни для обучения модели, ни для проверки ее производительности при обучении. В SANN присвоение наблюдений подмножествам может выполняться случайным образом при помощи опций в рамке Random sampling, или на основе специальной переменной выбора подмножеств в наборе данных (Identifer) при помощи опций рамки Subset variable.

В рамке Random sampling по умолчанию определены в процентном соотношении объемы обучающей выборки (Train%) – 70%, тестовой (Test%) – 15%, контрольной (Validation%) – 15%. Распределение исходных данных на указанные выборки осуществляется при помощи датчика случайных чисел, в поле Seed for sampling задается начальное значение датчика случайных чисел – 1000. Если пользователь планирует самостоятельно определить все 3 выборки, то в исходных данных как было отмечено, должна быть определена переменная идентификатор, в рамке Subset variable следует выделить опцию Sampling variable и при помощи кодов указать к какой одной из 3 выборок принадлежат наблюдения (объекты) – обучающей, тестовой, или контрольной.

Щелкнем по кнопке OK. Появится диалоговое окно SANN - Automated Network Search (ANS) – автоматический поиск сети на вкладке Quick (рис.5.1.15).

В рамке Network types пользователь может указать тип сети, которую предполагается построить – MLP или RBF.

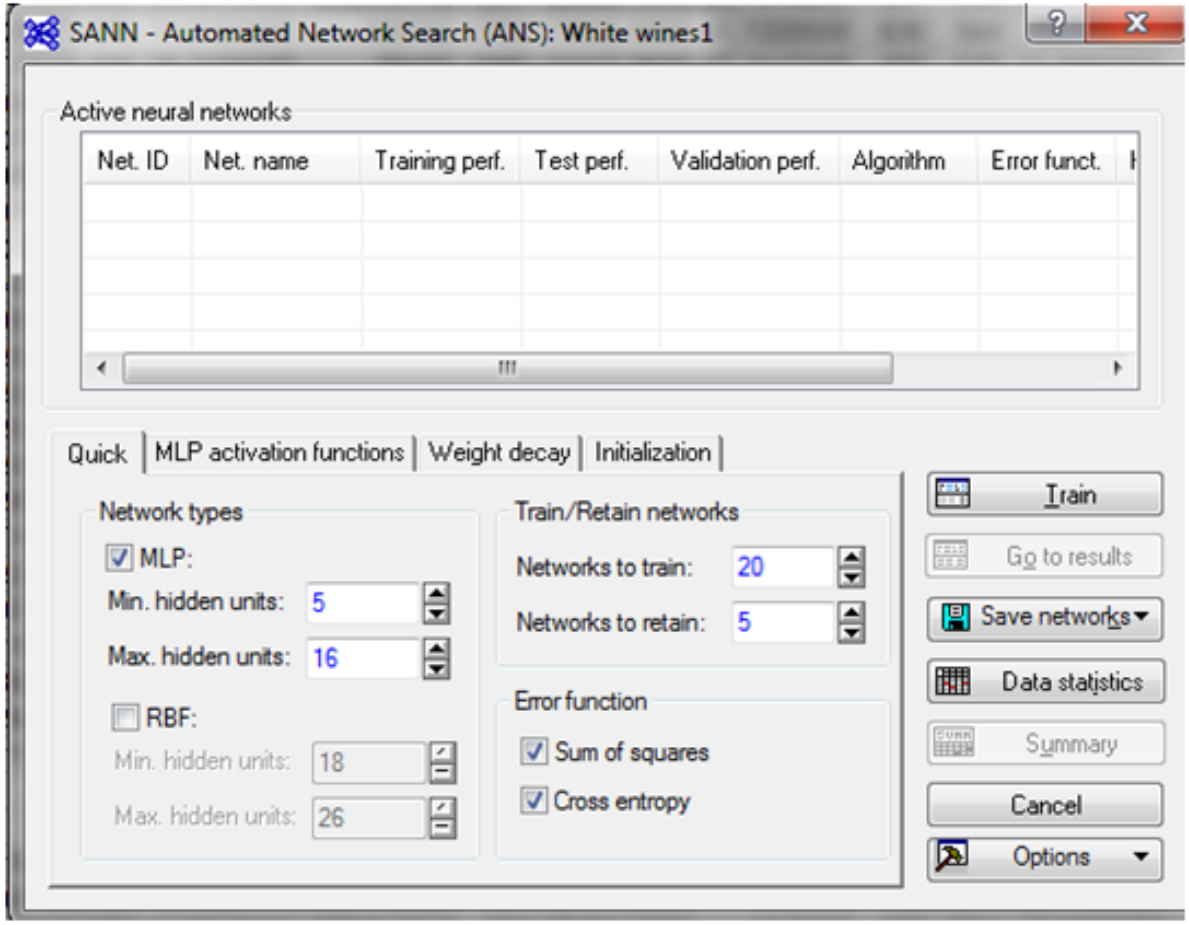

Рис.5.1.15

Для каждого выбранного типа предусмотрены диапазоны сложности моделей нейронных сетей – минимальное и максимальное количество скрытых слоев (Min. and Max. hidden units), которые будут опробованы ANS. Точное указание количества скрытых слоев, т.е. Min. = Max. может быть полезным, если у пользователя имеются веские основания считать известным их оптимальное количество. В этом случае пользователь позволяет методу ANS сконцентрировать свои алгоритмы поиска на других параметрах сетей, например, таких как функции активации. Чем больше количество скрытых слоев в модели нейронной сети, тем сильнее модель, т.е. тем более способна сеть моделировать сложные отношения между входными данными и зависимыми переменными.

В целом, увеличение количества скрытых слоев увеличивает мощность нейронной сети, т.е. она может моделировать более сложную базовую функцию. Но при этом сеть становится больше, ее труднее обучать, она медленнее в работе и более склонна к чрезмерным нагрузкам. Уменьшение количества скрытых слоев дает обратный эффект.

Если установить флажок на MLP, будет включен поиск многоуровневой сети персептронов (Multilayer Perceptron Networks), являющейся наиболее распространенной формой сети. Она требует итеративного обучения, которое может быть довольно медленным для большого количества скрытых слоев и наборов данных, но сети при этом компактны, выполняются быстро после обучения и в большинстве задач дают лучшие результаты, чем другие типы сетей.

Если установить флажок на RBF, будет включено построение сетей радиальных базисных функций. Сети RBF используют радиальные базисные функции как функции активации. Выходом сети является линейная комбинация радиальных базисных функций входов и параметров нейрона. Сети RBF обычно еще медленнее и больше, чем многослойный персептрон, и часто имеют относительно низкую производительность, но иногда при идентичных функциях активации в сети, они обучаются очень быстро. Они также обычно менее эффективны, чем многослойные персептроны, если большое количество входных переменных, так как они более чувствительны к включению ненужных входных данных.

В рамке Train/Retain networks (обучить/сохранить сети) предусмотрены параметры для того, чтобы указать, сколько сетей должно быть обучено (Networks to train) и сколько сетей должно быть сохранено (Network to retain) ANS. Чем больше число обученных сетей, тем более детальным будет поиск, выполняемый ANS. Рекомендуется установить для этого параметра как можно большее значение в зависимости от скорости вашего оборудования и ресурсов. Сохранены для тестирования и включения в текущий набор будут сети с наименьшей ошибкой регрессии (при решении задачи регрессии) и наибольшей степенью классификации (при решении задачи классификации).

В рамке Error function (функция ошибки) указывается функция ошибки, которая будет использоваться при обучении сети:

– Sum of squares (сумма квадратов) предполагает генерирование сетей с использованием функции ошибок в виде суммы квадратов. Эта функция ошибок является одной из наиболее часто используемых при обучении нейронных сетей и доступна в SANN для сетей типа MLP и RBF, как в задачах регрессии, так и в задачах классификации;

– Cross entropy (перекрестная энтропия) предполагает генерирование сетей с использованием перекрестной энтропии.

Если на вкладке Quick выбраны сети MLP, то последующая вкладка будет называться MLP activation functions (рис.5.1.16). На этой вкладке приведен перечень функций активации, которые могут быть включены в автоматический сетевой поиск для внутренних (input-hidden) и выходных (hidden-output) скрытых слоев. Функций активации и их графики приведены на рис.5.1.2 – 5.1.7. Если выбраны сети RBF, то названная вкладка будет отсутствовать, так как для этих сетей в SANN функцией активации является функция Гаусса.

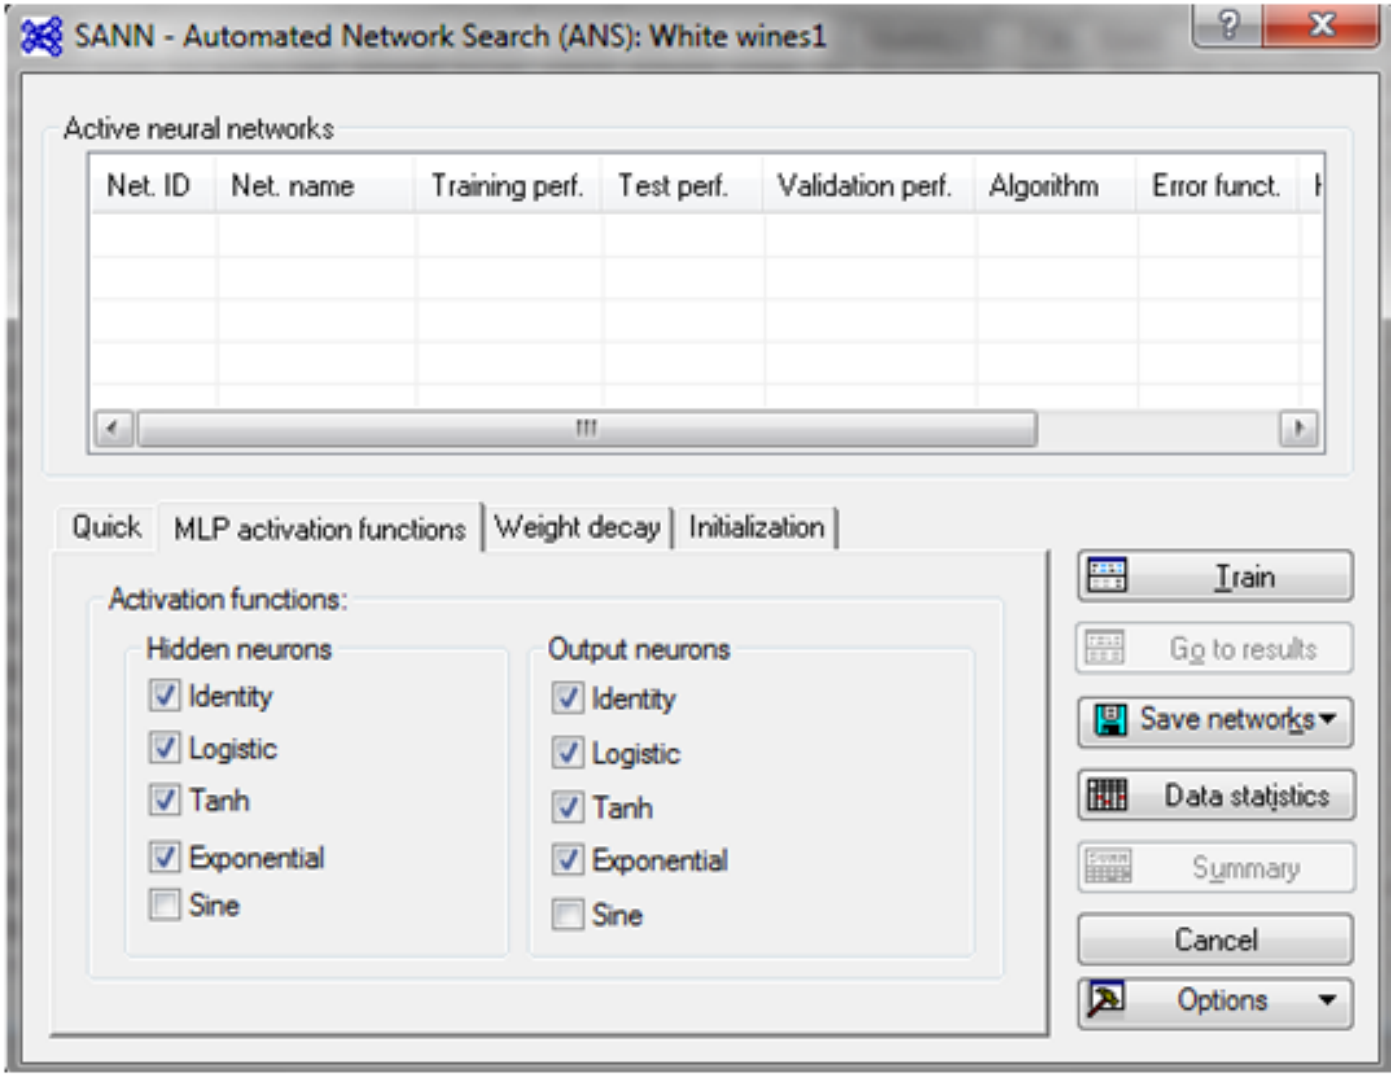
SANN - Automated Network Search (ANS): White wines1
Active neural networks
Net. ID
Net. name
Training perf.
Test perf.
Validation perf.
Algorithm
Error funct.
Quick
MLP activation functions
Weight decay
Initialization
Activation functions:
Hidden neurons
Identity
Logistic
Tanh
Exponential
Sine
Output neurons
Identity
Logistic
Tanh
Exponential
Sine
Train
Go to results
Save networks
Data statistics
Summary
Cancel
Options

Рис.5.1.16

Перейдем на вкладку Weight decay (Затухание – уменьшение веса) (рис.5.1.17), чтобы указать использование регуляризации уменьшения весов. Эта опция инициирует подбор меньших весов, что обеспечивает уменьшение чрезмерной подгонки (переобученности модели), тем самым потенциально улучшая характеристики сети для практического применения.

Снижение веса работает путем изменения функции ошибок сети, чтобы штрафовать за большие веса – результатом является функция ошибок, которая способствует уменьшению производительности сети и весов.

Если установлен флажок на Use weight decay (hidden layer) (Используйте уменьшение веса (скрытый слой)), то будет применена регуляризация для уменьшения весов скрытого слоя. Эта опция недоступна для сетей RBF.

Если установлен флажок на Use weight decay (output layer) – используйте уменьшение веса (выходной слой), то будет применена регуляризация для уменьшения весов выходного слоя. В обоих случаях пользователь может самостоятельно указать диапазон уменьшения весов.

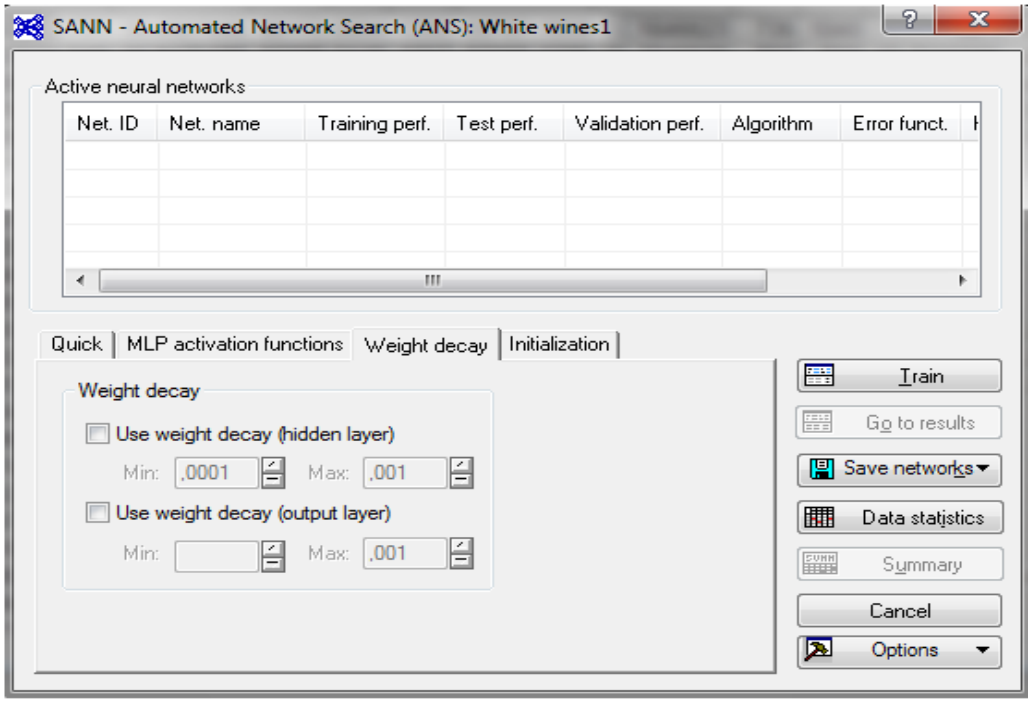

Рис.5.1.17

На вкладке Initialization (Инициализация) (рис.5.1.18), доступны параметры инициализации сети. В рамке Seed control for network initialization, при помощи флажка на Use fixed seed фиксируется начальное значение для случайной генерации начальных весов сети.

Если флажок не устанавливать, то SANN может использовать системное время, чтобы предоставить алгоритму начальное значение. В последнем случае никакие два анализа не будут одинаковыми, что является рекомендуемым вариантом при разработке сетей. Так как построение сети носит учебный характер, чтобы была возможность повторного воссоздания построенных сетей, установим флажок на Use fixed seed.

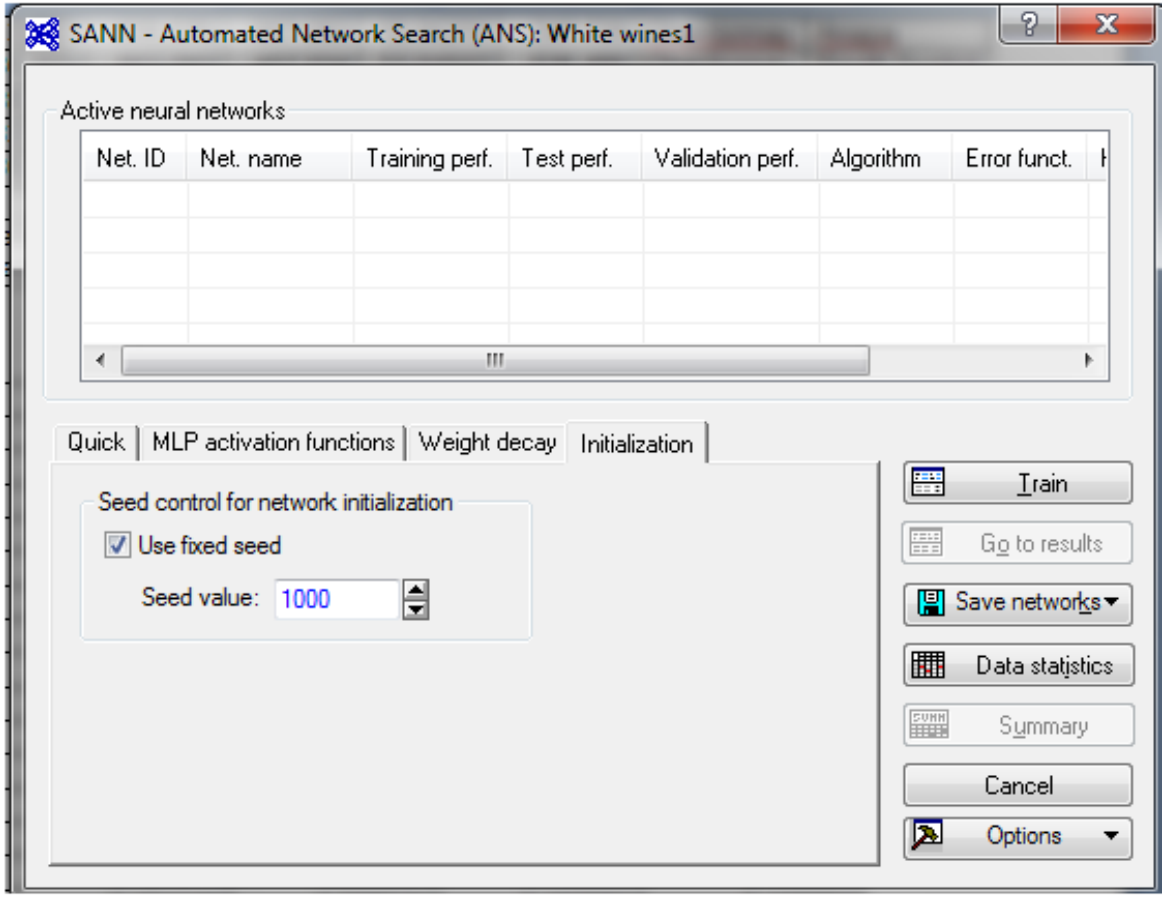

Рис.5.1.18

Если щелкнуть по кнопке Train (обучение), программа автоматически подберет настройки сетей – количество внутренних слоев, функции активации, алгоритм обучения и др., функции ошибок, обучит 20 сетей. Из обученных сетей программа выберет 5 наилучших многоуровневых сетей (ансамбль) персептронов – MLP, названия которых с указанием параметров будут записаны в рамке Active neural networks окна результатов (SANN – Results) (рис.5.1.19).

Следует заметить, что есть определенные отличия с окном результатов, построенным русифицированной версией Statistica 13.3.1 Ru – контрольная выборка названа текстовой и наоборот, текстовая названа контрольной, отличается состав 5 выбранных сетей в поле Active neural networks.

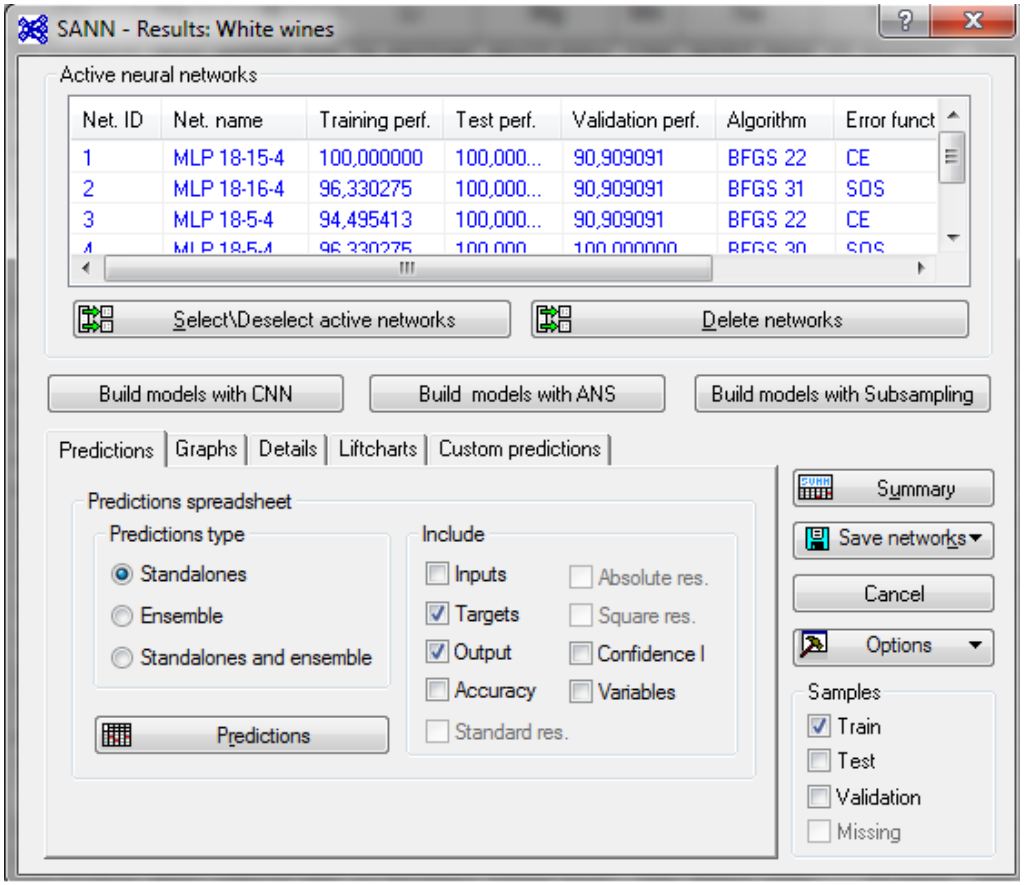

Рис.5.1.19

Первая цифра после типа нейронной сети MLP обозначает число входов – у всех сетей 18 входов. Эта величина определяется как сумма количества независимых непрерывных предикторов – 15 и количества значений категориальной независимой переменной Sort – 3.

Вторая цифра обозначает количество промежуточных (скрытых) слоев.

Третья цифра – количество выходов – 4 по числу регионов.

В столбцах Training perf., Test perf., Validation perf. указаны производительности сетей, т.е. доли (%) правильной классификации. Напомним, что наиболее важным из этих 3 показателей является доля верной классификации на проверочной выборке (Validation perf.).

В столбце Algorithm отображено название итерационного алгоритма численной оптимизации весов – BFGS с числом итераций. Алгоритм назван в честь его создателей: Broyden, Fletcher, Goldfarb, Shanno. В столбце Error funct. указан вид функции ошибки, которая использовалась при обучении сети. Напомним, что ее выбор декларирован на рис.5.1.15 в рамке Error function. В построенных сетях была использована по выбору программы одна из предусмотренных в методе функций ошибки SOS – Sum of squares (сумма квадратов) или CE – Cross entropy (перекрестная энтропия).

В столбце Hidden act. и Output act. приведены выбранные программой функции активации нейронов в промежуточных слоях и на выходе нейронной сети, ранее обозначенные в рамке Activation functions на рис.5.1.16.

Таблица 5.1. Итоги автоматического построения нейронных сетей

Summary of active networks (White wines1)								
Index	Net. name	Training perf.	Test perf.	Validation perf.	Training algorithm	Error function	Hidden activation	Output activation
1	MLP 18-15-4	100,0000	100,0000	90,9091	BFGS 22	Entropy	Logistic	Softmax
2	MLP 18-16-4	96,3303	100,0000	90,9091	BFGS 31	SOS	Exponential	Tanh
3	MLP 18-5-4	94,4954	100,0000	90,9091	BFGS 22	Entropy	Tanh	Softmax
4	MLP 18-5-4	96,3303	100,0000	100,0000	BFGS 30	SOS	Tanh	Tanh
5	MLP 18-13-4	91,7431	95,4545	95,4545	BFGS 17	SOS	Identity	Identity

Если нажать на кнопку Summary (Итоги) на вкладке Details (Итоги анализа), программа построит таблицу описанных выше результатов (табл.5.1) и приведенных в рамке Active neural networks рис.5.1.19. Наилучший результат у сети 4, так как точность прогноза на проверочной выборке достигла максимально возможного значения – 100%, на обучающей выборке точность 96,33%. Под производительностью сети понимается доля правильных классификаций в %.

Диалоговое окно результатов SANN – Results по умолчанию открывается на вкладке Predictions – Предсказанные (рис.5.1.19). Рамка Predictions spreadsheet (таблица прогнозов) определяет типы прогнозов и параметры для формирования таблицы прогнозов.

В рамке Predictions type предлагается выбор основных типов прогнозов – Standalones (автономные), Ensemble (ансамблем), Standalones and ensemble – смешанные. Таблица прогнозов будет построена отдельной сетью, или ансамблем сетей, отображенных, или высвеченных в рамке Active neural networks при помощи кнопки Select/Delete active networks (если надо исключить из рассмотрения сеть, то следует воспользоваться альтернативной кнопкой Delete networks).

Если в рамке Predictions spreadsheet выделена опция Standalones, то программа отобразит результаты прогнозов каждой из нейронных сетей. Если выделена опция Ensemble, таблица будет построена ансамблем сетей из рамки Active neural networks. Если выделена опция Standalones and ensemble, то будут построены прогнозы, как отдельными сетями, так и ансамблем сетей. Опции Ensemble и Standalones and ensemble будут активны, если в рамке Active neural networks отображено более одной сети.

В рамке Include (включить) указывается дополнительная, доступная в зависти от типа анализа и типа сети информация в электронную таблицу прогнозов:

– Inputs (входы) включает входные переменные;

– Targets (цели) включает целевые (зависимые) переменные;

– Output (выход) включает фактические прогнозы;

– Residuals (остатки) для анализа регрессионного типа включает остатки;

– Standard res (стандартные остатки) включает стандартизованные остатки в электронную таблицу прогнозов (наблюдаемое – прогнозное) / стандартное отклонение ошибки прогноза; применяется только к анализу регрессионного типа.

– Absolute res (абсолютный остаток) включает абсолютное значение остатка; применяется только к анализу регрессионного типа.

– Square res (квадрат остатков) включает квадрат остаточного значения; применяется только к анализу регрессионного типа.

– Confidence (доверительный уровень) включает доверительную вероятность прогноза; применяется только к анализу типа классификации.

– Variables включает произвольный выбор переменных из набора данных.

Если нажать на кнопку Predictions, когда этот флажок установлен, отобразится диалоговое окно выбора переменных, в котором можно выбрать переменные для включения в таблицу.

В рамке Predictions spreadsheet выделим опцию Ensemble, в рамке Samples в нижнем правом углу таблицы обозначим опции Train, Test, Validation, в рамке Include установим флажок на Confidenca, все остальные установки примем по умолчанию и воспользуемся кнопкой Predictions – программа построит таблицу, в которой будут отображены все 153 образца вин.

Из-за ограниченности формата страницы в табл.5.2 приведены первые 20 образцов. В столбце Sample указана принадлежность образцов к обучающей, тестовой, контрольной выборке. В столбце Region Target программа отобразила исходный регион производства винограда, а в столбце Region – Output Ensemble регион, принадлежность к которому определена ансамблем из 5 нейронных сетей.

Если прогноз ошибочный, программа выделит его красным цветом. В столбце Region – Confidence levels указаны вероятности принадлежности образцов вин к прогнозируемому региону. Просмотр всей таблицы покажет, что ошибочно классифицированы только 2 образца – 66 и 67 из Таманской зоны, оба принадлежат к контрольной выборке. Вероятности их ошибочной принадлежности к Черноморской зоне соответственно равны 0,443 и 0,433.

Таблица 5.2. Результаты прогноза ансамбля сетей

Case name	Predictions spreadsheet for Region (White wines1) Samples: Train, Test, Validation			
	Sample	Region Target	Region - Output Ensemble	Region - Confidence levels
1	Train	Taman	Taman	0,670923
2	Test	Taman	Taman	0,659342
3	Train	Taman	Taman	0,656644
4	Train	Taman	Taman	0,671496
5	Test	Taman	Taman	0,678905
6	Train	Taman	Taman	0,662656
7	Train	Taman	Taman	0,664553
8	Validation	Taman	Taman	0,669450
9	Train	Taman	Taman	0,655650
10	Train	Taman	Taman	0,649427
11	Train	Taman	Taman	0,657304
12	Train	Taman	Taman	0,652463
13	Train	Taman	Taman	0,664549
14	Train	Taman	Taman	0,659711
15	Train	Taman	Taman	0,701438
16	Train	Taman	Taman	0,687466
17	Test	Taman	Taman	0,697272
18	Train	Taman	Taman	0,692883
19	Train	Taman	Taman	0,699445
20	Train	Taman	Taman	0,692528

Если выбрать сеть 4, то программа укажет другие образцы вин с ошибочной классификацией – 41, 42, 46 в обучающей выборке. Первые 2 принадлежащие к Южно-предгорной зоне, ошибочно отнесены к Черноморской зоне, а третий, принадлежащий к Черноморской зоне, ошибочно отнесен к Южно-предгорной зоне. Ну, и наконец, если в поле Sample определены не все выборки, то прогнозы будут показаны, только для образцов из выделенных выборок.

Если нажать на кнопку Cancel, программа вернется в диалоговое окно ANS на рис.5.1.19, но уже с заполненной в рамке Active neural networks информацией по первым 5 построенным сетям. Если вновь нажать на кнопку Train, программа добавит в рамку информацию еще по 5 обученным и построенным сетям с номерами от 6 до 10.

Кнопки Build models with CNN, Build models with ANS, Build models with Subsampling (рис.5.1.19) переводят программу соответственно в диалоги на рис.5.1.11, 5.1.15, 5.1.12, где пользователю будут предоставлены возможности построить новые нейросетевые модели с прогностическими свойствами, превосходящие ранее созданные модели методами CNN, ANS, Subsampling.

На вкладке Graphs предусмотрены опции для построения различных графиков – гистограмм, 2D- диаграмм рассеяния, 3D-графиков поверхностей (рис.5.1.21). Если установлен флажок на Case names, то на 2D- и 3D-графиках программа укажет названия объектов, в нашем случае – номера образцов вин. Очевидно, что наибольший интерес графические возможности модуля представляют при решении задач регрессии.

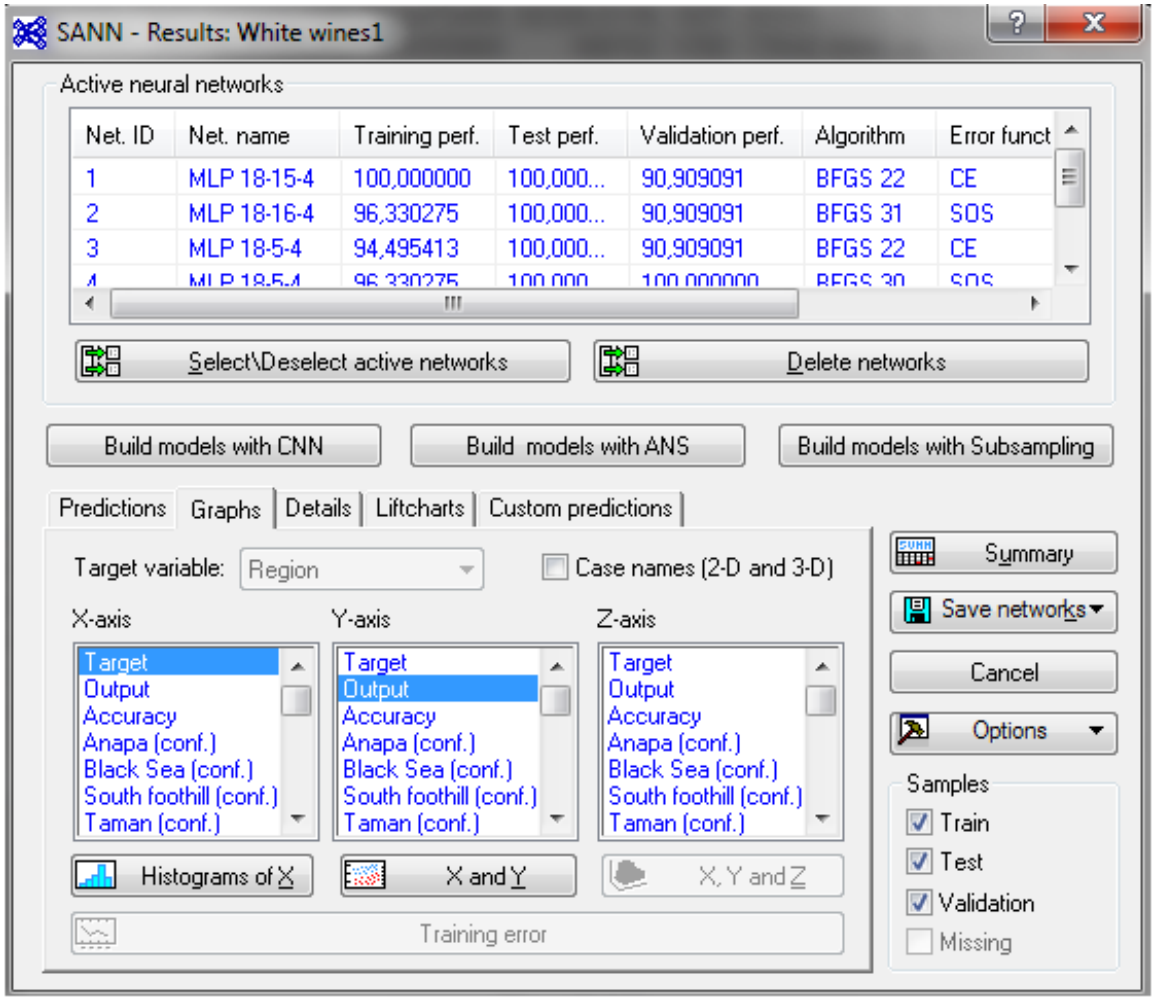

Рис.5.1.21

Вернемся в окно на рис.5.1.19 и выберем сеть MLP 18-5-4. На вкладке Details – подробности (рис.5.1.22) предоставлены опции для ознакомления пользователя с основными параметрами построенных нейронных сетей.

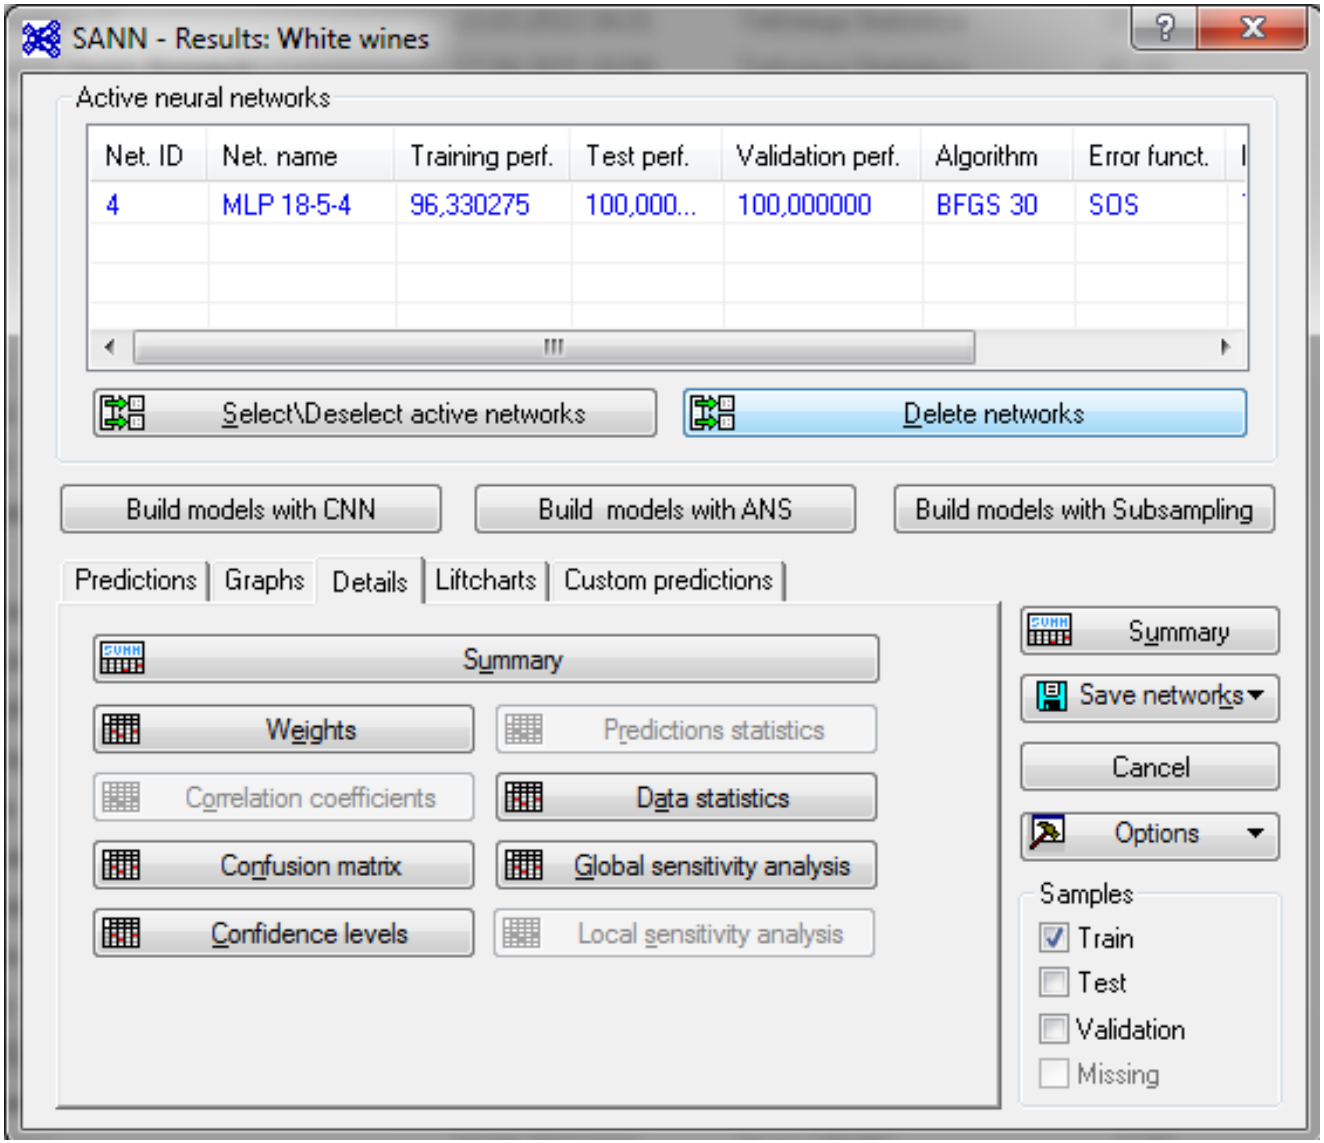

Рис.5.1.22

Кнопка Weights (веса) предназначена для отображения весов нейронов промежуточных (скрытых) слоев нейронной сети для каждой модели в рамке активных нейронных сетей (active neural networks). Чтобы сократить объемы таблицы при помощи кнопки Select/Delete active networks выберем сеть под номером 4 и нажмем на кнопку Weights.

В табл.5.3 приведены первые 20 строчек из общего количества (119) весов. В первом столбце будут указаны обозначения нейронов скрытого слоя, в том числе привязанных к независимым переменным (предикторам модели) на входе и зависимым (категориальным) на выходе, во втором столбце указаны сами веса: 18·5=90+5(входное смещение)+5·4(на выходе)+4(скрытых смещения на выходе)=119

Таблица 5.3. Таблица весов нейронов

Weight ID	Network weights (White wines1)	
	Connections 4.MLP 18-5-4	Weight values 4.MLP 18-5-4
1	Al --> hidden neuron 1	-3,00870
2	Ba --> hidden neuron 1	-0,72390
3	Ca --> hidden neuron 1	1,26159
4	Cu --> hidden neuron 1	1,75730
5	Fe --> hidden neuron 1	-1,64029
6	K --> hidden neuron 1	-0,38750
7	Li --> hidden neuron 1	3,58807
8	Mg --> hidden neuron 1	2,12726
9	Mn --> hidden neuron 1	0,31093
10	Na --> hidden neuron 1	1,89660
11	Ni --> hidden neuron 1	-0,27985
12	Rb --> hidden neuron 1	-0,51878
13	Sr --> hidden neuron 1	-0,75391
14	Ti --> hidden neuron 1	-1,86027
15	Zn --> hidden neuron 1	-0,28560
16	Sort(Chardonnay) --> hidden neuron 1	0,11458
17	Sort(Muscat) --> hidden neuron 1	-0,43220
18	Sort(Riesling) --> hidden neuron 1	-0,56382
19	Al --> hidden neuron 2	-2,10927
20	Ba --> hidden neuron 2	1,83426

Кнопка Correlation coefficients инициирует создание таблицы коэффициентов корреляции зависимых переменных для обучающей, тестовой и контрольной выборки только для анализа временных рядов и регрессии.

Если щелкнуть по кнопке Confusion matrix (матрица несовпадений), то в соответствие с установками в рамке Sample для обучающей, тестовой и контрольной выборки появятся матрицы с результатами классификации по классам, заданным зависимой категориальной переменной – в нашем случае, это регионы произрастания винограда. Названия строк соответствуют предсказанным классам, названия столбцов – исходным. Так, из табл.5.4 следует, что в обучающей выборке:

– 13 образцов Анапской зоны, 19 образцов Южно-предгорной зоны и 22 образца Черноморской зоны нейронной сетью правильно классифицированы;

– по 1 образцу Черноморской зоны ошибочно отнесено к Южно-предгорной и Анапской зоне;

– 2 образца Южно-предгорной зоны ошибочно отнесено к Черноморской зоне.

Таблица 5.4. Результаты классификации для обучающей выборки

Predicted category	Region (Confusion matrix) (White wines1) Samples: Train			
	Region-Anapa	Region-Black Sea	Region-South foothill	Region-Taman
4.MLP 18-5-4-Anapa	13	0	0	0
4.MLP 18-5-4-Black Sea	0	22	2	0
4.MLP 18-5-4-South foothill	0	1	19	0
4.MLP 18-5-4-Taman	0	1	0	51

В табл.5.5 отображены абсолютные и относительные (%) частоты правильной (Correct) и неправильной (Incorrect) классификации по каждому региону для обучающей выборки. Таблица5.5. Итоги классификации на обучающей выборке

Таблица5.5. Итоги классификации на обучающей выборке

	Region (Classification summary) (White wines) Samples: Train					
		Region-Anapa	Region-Black Sea	Region-South foothill	Region-Taman	Region-All
4.MLP 18-5-4	Total	13,0000	24,00000	21,00000	51,0000	109,0000
	Correct	13,0000	22,00000	19,00000	51,0000	105,0000
	Incorrect	0,0000	2,00000	2,00000	0,0000	4,0000
	Correct (%)	100,0000	91,66667	90,47619	100,0000	96,3303
	Incorrect (%)	0,0000	8,33333	9,52381	0,0000	3,6697

В табл.5.6 – 5.7 приведены аналогичные результаты для тестовой выборки, из которых следует, что для этих выборок все образцы нейронной сетью верно идентифицированы.

Таблица 5.6. Результаты классификации на тестовой выборке

Predicted category	Region (Confusion matrix) (White wines) Samples: Test			
	Region-Anapa	Region-Black Sea	Region-South foothill	Region-Taman
4.MLP 18-5-4-Anapa	2	0	0	0
4.MLP 18-5-4-Black Sea	0	5	0	0
4.MLP 18-5-4-South foothill	0	0	3	0
4.MLP 18-5-4-Taman	0	0	0	12

Таблица5.7. Итоги классификации на тестовой выборке

	Region (Classification summary) (White wines) Samples: Test					
		Region-Anapa	Region-Black Sea	Region-South foothill	Region-Taman	Region-All
4.MLP 18-5-4	Total	2,0000	5,0000	3,0000	12,0000	22,0000
	Correct	2,0000	5,0000	3,0000	12,0000	22,0000
	Incorrect	0,0000	0,0000	0,0000	0,0000	0,0000
	Correct (%)	100,0000	100,0000	100,0000	100,0000	100,0000
	Incorrect (%)	0,0000	0,0000	0,0000	0,0000	0,0000

В табл.5.8 – 5.9 приведены аналогичные результаты для проверочной выборки, из которых следует, что для этих выборок все образцы нейронной сетью верно идентифицированы.

Таблица 5.8. Результаты классификации на проверочной выборке

Predicted category	Region (Confusion matrix) (White wines) Samples: Validation			
	Region-Anapa	Region-Black Sea	Region-South foothill	Region-Taman
4.MLP 18-5-4-Anapa	3	0	0	0
4.MLP 18-5-4-Black Sea	0	3	0	0
4.MLP 18-5-4-South foothill	0	0	6	0
4.MLP 18-5-4-Taman	0	0	0	10

Таблица5.9. Итоги классификации на проверочной выборке

	Region (Classification summary) (White wines) Samples: Validation					
		Region-Anapa	Region-Black Sea	Region-South foothill	Region-Taman	Region-All
4.MLP 18-5-4	Total	3,0000	3,0000	6,0000	10,0000	22,0000
	Correct	3,0000	3,0000	6,0000	10,0000	22,0000
	Incorrect	0,0000	0,0000	0,0000	0,0000	0,0000
	Correct (%)	100,0000	100,0000	100,0000	100,0000	100,0000
	Incorrect (%)	0,0000	0,0000	0,0000	0,0000	0,0000

Кнопка Predictions statistics (статистика прогнозов) инициирует построение таблицы, содержащей минимальные и максимальные значения прогнозов, остатков и стандартизированных остатков для всех моделей из рамки активных нейронных сетей. Эти статистические данные доступны для каждой выборки – обучающей, тестовой и контрольной. Опция доступна только для регрессионного анализа и анализа временных рядов (регрессии).

Если щелкнуть по кнопке Data statistics, программа построит таблицу, содержащую средние значения, стандартные отклонения, минимальные и максимальные значения для каждой непрерывной независимой переменной в анализе по всем 3 выборкам – обучающей, тестовой, контрольной и всего набора данных. В табл.5.10 приведен фрагмент таблицы для первых 5 металлов.

Таблица 5.10. Основные статистики непрерывных предикторов

Samples	Data statistics (White wines1)				
	Al Input	Ba Input	Ca Input	Cu Input	Fe Input
Minimum (Train)	167,827	41,2531	19744,3	3,627	468,480
Maximum (Train)	8284,661	433,9024	111076,6	5005,634	8973,992
Mean (Train)	1320,636	127,6173	71022,8	220,034	3495,173
Standard deviation (Train)	1134,540	57,8235	18560,6	530,569	2351,266
Minimum (Test)	375,659	44,4996	19410,3	6,826	680,688
Maximum (Test)	8734,680	290,4624	105352,9	5059,155	8831,635
Mean (Test)	1598,372	131,9753	72086,4	468,987	3851,033
Standard deviation (Test)	1726,983	70,0197	20827,1	1084,988	2501,117
Minimum (Validation)	332,357	55,2664	23060,9	20,590	681,840
Maximum (Validation)	2454,651	459,0864	90662,8	4908,451	7721,667
Mean (Validation)	1144,091	148,7850	64502,4	393,108	3830,428
Standard deviation (Validation)	324,516	58,3013	19664,1	333,483	1926,692
Minimum (Missing)					
Maximum (Missing)					
Mean (Missing)					
Std (Missing)					
Minimum (Overall)	167,827	41,2531	19410,3	3,627	468,480
Maximum (Overall)	8734,680	459,0864	111076,6	5059,155	8973,992
Mean (Overall)	1335,186	131,2876	70238,1	280,718	3594,549
Standard deviation (Overall)	1183,976	68,9966	19189,1	720,824	2308,741

При нажатии на кнопку Confidence levels (уровни достоверности), программа отобразит вероятности принадлежности каждого объекта к классам, определяемым откликом, в нашем случае – образцов вин к регионам, где был выращен виноград. Таблицы строятся для выборок, отмеченных пользователем в рамке Sample. Процедура доступна только для задач классификации. В первых 16 столбцах содержится информация по значениям предикторов для каждого образца, в остальных столбцах последовательно отображены регион прогноза (Region Target), исходный регион (Region – Output), а также вероятности принадлежности к каждому из прогнозируемых регионов.

В табл.5.11 приведена часть перечисленной информации для обучающей выборки, содержащей столбцы с вероятностями принадлежности к регионам, а также строки с 31 по 50 и строку 149, среди которых 4 образца с ошибочной классификацией (выделены жирным курсивом). Образец принадлежит к тому региону, для которого вероятность больше. Сумма приведенных вероятностей для каждой строки равна 1. Так, например, образец 31 классифицирован правильно как образец, принадлежащий к Анапской зоне, так как вероятность, равная 0,463 наибольшая в строке 31. Образцы 41, 42, принадлежащие к Южно-предгорной зоне, ошибочно отнесены к Черноморской зоне, так как вероятности, равные 0,357 и 0,337 также принимают наибольшие значения. По этой же причине ошибочно классифицированы образцы 46 и 149.

Таблица 5.11. Вероятности принадлежности образцов вин к регионам

Case name		Confidence levels (White wines1) Samples: Train, 4 MLP 18–5 –-4				
	Region Target	Region – Output	Region-Anapa	Region-Black Sea	Region-South foothill	Region-Taman
31	Anapa	Anapa	0,463018	0,161648	0,181821	0,193512
32	Anapa	Anapa	0,462922	0,157429	0,186007	0,193642
34	Anapa	Anapa	0,465695	0,156264	0,183815	0,194226
35	Anapa	Anapa	0,471766	0,155183	0,179600	0,193451
36	Anapa	Anapa	0,462729	0,159796	0,185911	0,191564
37	Anapa	Anapa	0,464702	0,149036	0,191681	0,194582
39	South foothill	South foothill	0,235929	0,261474	0,353793	0,148805
41	**South foothill**	**Black Sea**	**0,210246**	**0,356790**	**0,273387**	**0,159576**
42	**South foothill**	**Black Sea**	**0,216211**	**0,337441**	**0,282061**	**0,164287**
43	Black Sea	Black Sea	0,189464	0,463410	0,185720	0,161406
45	Black Sea	Black Sea	0,176525	0,481498	0,180182	0,161795
46	**Black Sea**	**South foothill**	**0,193329**	**0,278371**	**0,299399**	**0,228902**
47	Black Sea	Black Sea	0,179491	0,300731	0,291198	0,228580
48	Black Sea	Black Sea	0,170970	0,355027	0,269432	0,204571
50	Taman	Taman	0,148116	0,324136	0,159674	0,368074
...	...	...	...	...	...	...
149	**Black Sea**	**Taman**	**0,164022**	**0,305494**	**0,192473**	**0,338011**

Процедура Global sensitivity analysis (анализ Глобальной чувствительности) показывает результаты общего анализа чувствительности предикторных переменных для каждой модели в рамке активных нейронных сетей для обучающих, тестовых и контрольных выборок, отмеченных в рамке Sample. Анализ чувствительности оценивает важность входных переменных в построенных моделях классификации. В табл.5.12-5.14 приведены фрагменты таблиц для сети MLP 18-5-4 по первым 8 входным (предикторным) переменным, упорядоченным в таблице по степени убывания их важности.

Как видно из таблиц степень важности металлов в модели нейронной сети №4 в различных выборках коррелированна. Это означает, что металлы занимающее лидирующее место по одной выборке, занимают лидирующее место и по двум другим выборкам, соответственно металлы аутсайдеры по одной выборке, будут занимать последние позиции по важности и в 2 других выборках.

Процедура Local sensitivity analysis (анализ локальной чувствительности) показывает, насколько чувствительны выходные данные нейронной сети к заданной области входных предикторных переменных. Эта процедура доступна только для регрессионного анализа.

Таблица 5.12. Анализ чувствительности для обучающей выборки

Networks	Sensitivity analysis (White wines1) Samples: Train							
	Sr	Li	Fe	Sort	Al	Ti	Na	Ba
4.MLP 18-5-4	2,505302	2,454279	2,362730	2,039651	1,686603	1,567885	1,524720	1,438037

Таблица 5.13. Анализ чувствительности для тестовой выборки

Networks	Sensitivity analysis (White wines1) Samples: Test							
	Li	Sr	Fe	Mg	Sort	Na	Al	Ba
4.MLP 18-5-4	2,527432	2,422321	1,957519	1,847359	1,693870	1,636497	1,564158	1,370278

Таблица 5.14. Анализ чувствительности для контрольной выборки

Networks	Sensitivity analysis (White wines1) Samples: Validation							
	Sr	Li	Mg	Fe	Al	Ti	Sort	Na
4.MLP 18-5-4	2,268503	1,843621	1,823928	1,807072	1,588831	1,561263	1,450107	1,387136

На вкладке Lift Charts (рис.5.1.23) для моделей классификации предоставлен доступ к параметрам построения диаграмм прироста (Gains chart). Диаграммы можно строить для всех выборок, которые будут обозначены в рамке Sample. В рамке Category можно указать группу (класс) объектов категориальной зависимой переменной, в том числе и все категории (All). Диаграммы используются для оценки и сравнения полезности модели и роли объектов различных категорий классификации при прогнозировании классов отклика. Другими словами исследуется как изменение объема выборок (тестовой, обучающей, контрольной и всех исходных данных) различных классов влияет на прогностические свойства модели. Ранее, мы рассматривали построение таких диаграмм в §2.4. Для иллюстрации возможностей вкладки ограничимся выбором обучающей выборки и Анапской зоны.

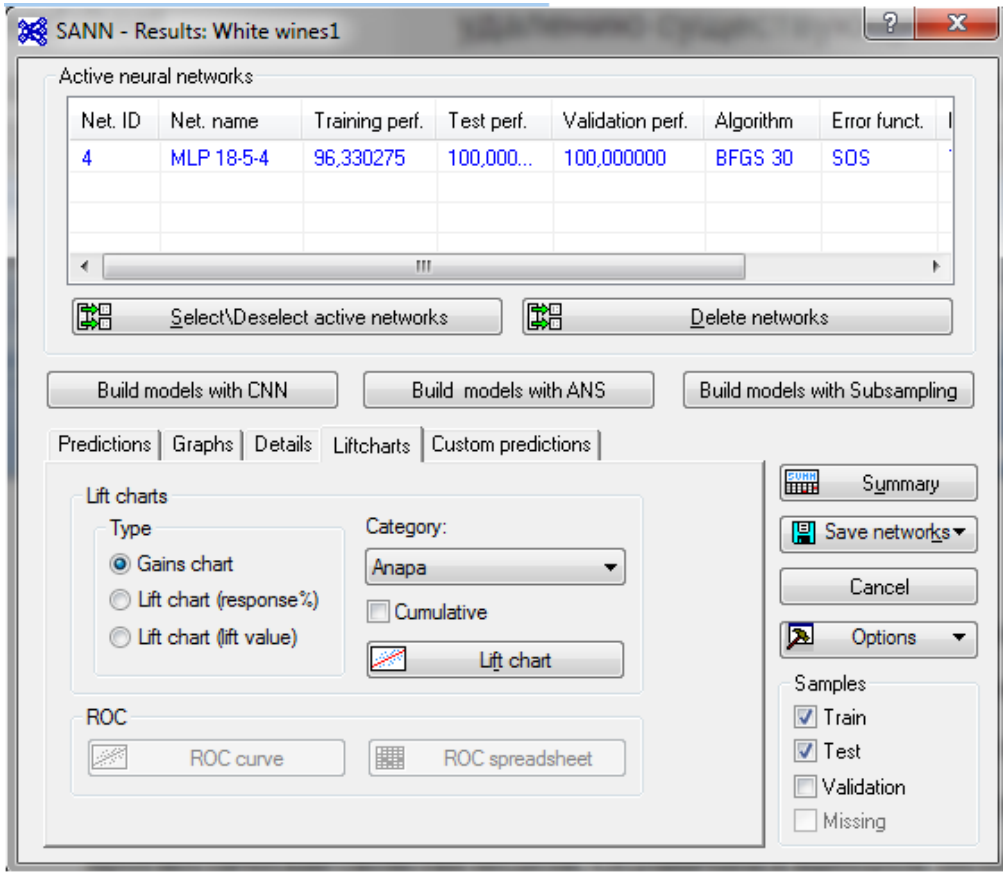

Рис.5.1.23

Если в рамке Type выбрать опцию Gains chart (диаграмма прироста), в рамке Category установить флажок на Cumulative, то программа построит график прироста, на котором показан процент наблюдений (ось OY), правильно отнесенных к выбранной категории при взятии первых k процентов (ось OX) наблюдений, отсортированных по убыванию вероятностей классификации. Изображенный на рис.5.1.24 график прироста показывает, что если, например, включить в обучающую выборку примерно 10% отсортированных по вероятности образцов вин Анапской зоны, то нейронная сеть №4 правильно классифицирует примерно 85% всех образцов вин этой категории. Если включить 20% и более, то нейронной сетью правильно будет классифицировано уже 100% вин этой категории. На этом графике базовая случайная классификация изображена прямой линией от нижнего левого угла до верхнего правого угла, которая может служить в качестве сравнения для оценки полезности соответствующих моделей классификации.

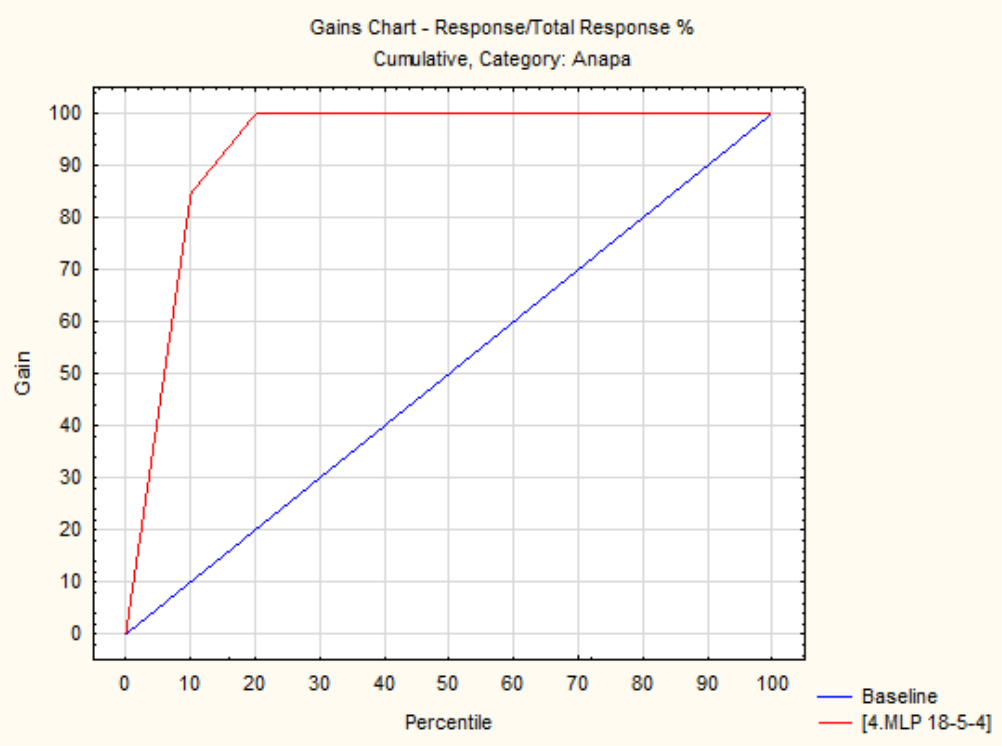

Рис.5.1.24

Если не устанавливать флажок на Cumulative, то график покажет изменение прогностической точности модели в зависимости от взятой доли (%) наблюдений, расположенных по убыванию вероятностей их классификации.

Так, из графика на рис.5.1.25 следует, что если включить в обучающую выборку первые 10% образцов вин из обучающей выборки, упорядоченных по убыванию вероятностей, то нейронная сеть правильно классифицирует 85% всех образцов вин Анапской зоны. Если в обучающую выборку включить вторые 10% – от 10% до 20%, то нейронная сеть правильно классифицирует 15% всех образцов вин Анапской зоны. Если в обучающую выборку включить от 20% до 30%, то доля верно классифицированных вин Анапской зоны составит 0%. Базовая линия проходит параллельно оси OX через значение ординаты 10%.

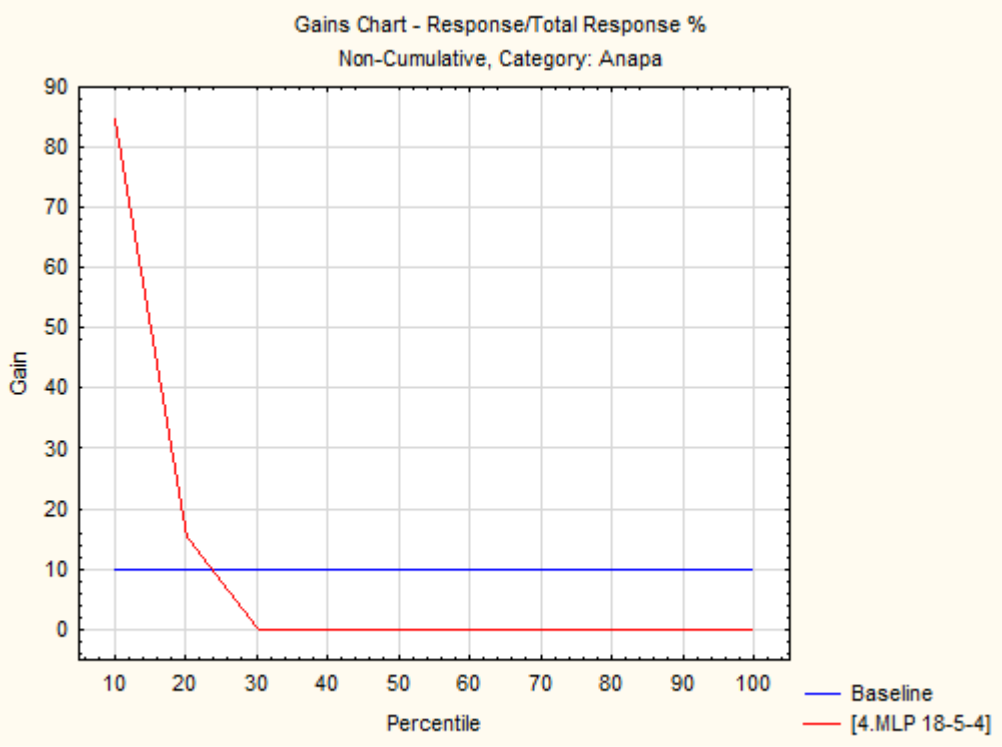

Рис.5.1.25

Если выбрать опцию Lift chart (lift value) программа построит диаграмму прироста, где вертикальная ось OY масштабируется числом кратным к объему выборки. Например, диаграмма на рис.5.1.26 показывает, что, взяв в обучающую выборку первые 40 процентов отсортированных по вероятности – это примерно 13·0,4 ≈ 5 образцов из 13 Анапской зоны (см.табл.5.4, 5.5), количество образцов отнесенных моделью к Анапской зоне, будет примерно в 2,5 раза больше 5, т.е. примерно 13 образцов. Если взять 50% – это примерно 6 образцов, то количество образцов отнесенных моделью к Анапской зоне, будет в 2 раза больше 6, т.е. примерно 12 образцов. Если взять все 100%, т.е. 13 образцов, то количество образцов отнесенных моделью к Анапской зоне, будет примерно 13 образцов.

Если выбрать опцию Lift chart (response %), то программа построит график (рис.5.1.27) аналогичный предыдущему с той лишь разницей, что по оси OY будут отложены доли в %.

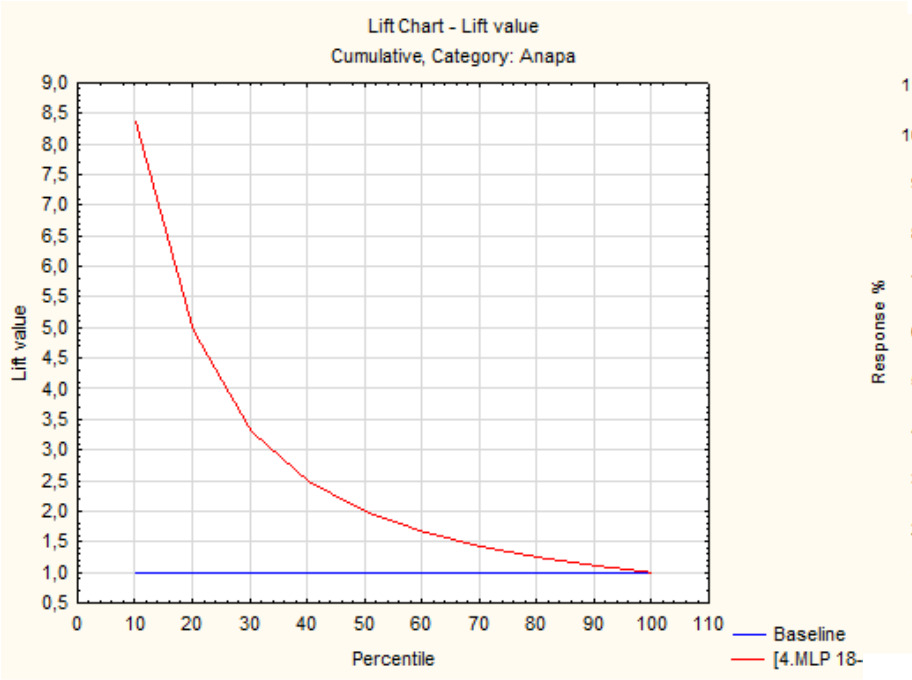

Рис.5.1.26

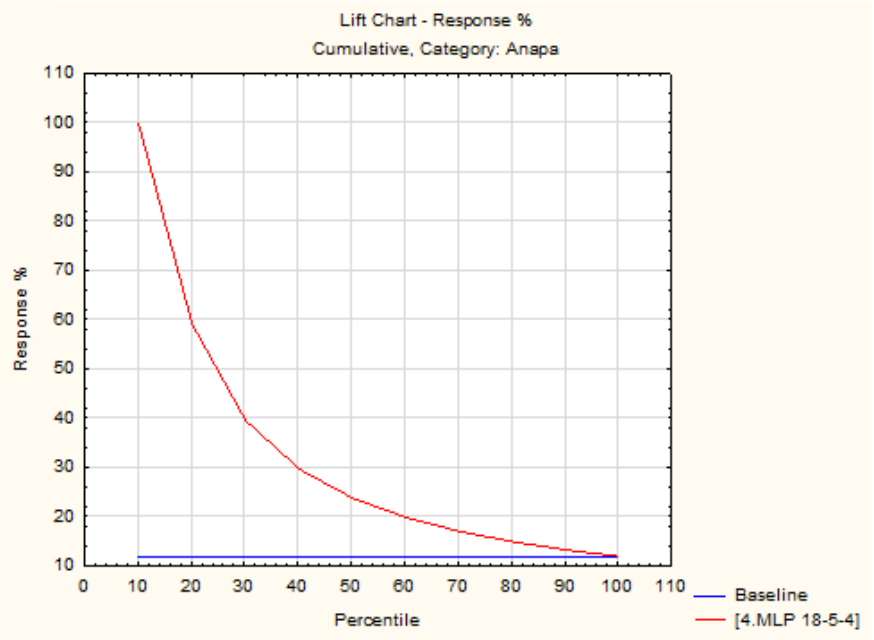

Рис.5.1.27

Очевидно, что графики данной вкладки полезны для оценки и сравнения вклада объектов классификации в прогностические свойства нейронной сети в зависимости от принадлежности к классу отклика и выборки – обучающей, тестовой, контрольной.

При помощи опций на вкладке Custom predictions (рис.5.1.28) посредством нейронных сетей из списка Active neural networks для наблюдений, которых нет в исходной выборке, можно делать прогнозы для любого типа задач, включая регрессию, классификацию, временные ряды и кластерный анализ (рис.5.1.8). Перед тем как делать прогнозы, в поле Number of cases to predict (количество случаев для прогнозирования) необходимо указать количество предполагаемых прогнозов. По умолчанию указано количество, равное 1, максимально возможное значение, предусмотренное разработчиками программы – 100.

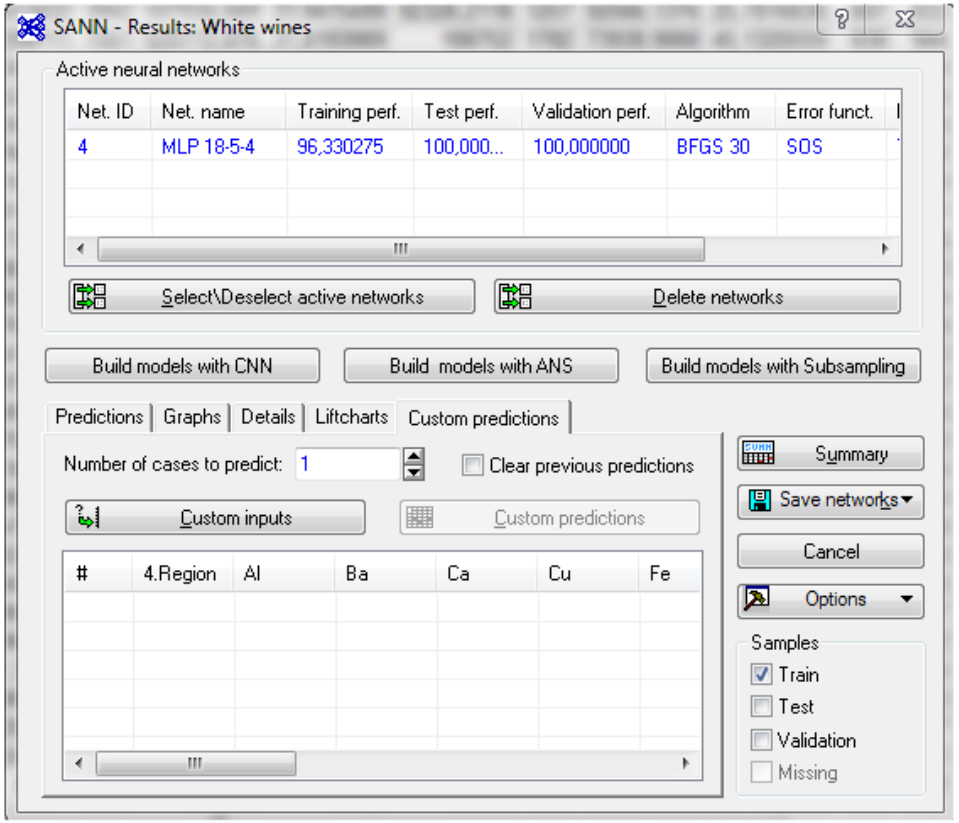

Рис.5.1.28

Для ввода данных прогноза следует нажать на кнопку Custom inputs и, в открывшееся окно ввести значения предикторных переменных, например, как это сделано на рис.5.1.29 и рис.5.1.30 (продолжение), далее щелкнуть по ОК.

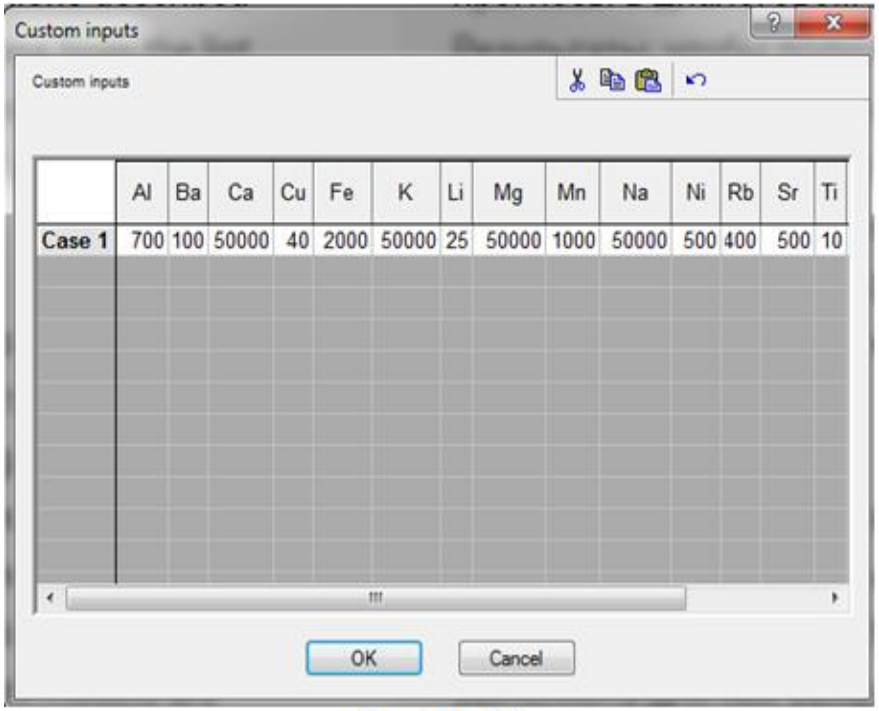

	Al	Ba	Ca	Cu	Fe	K	Li	Mg	Mn	Na	Ni	Rb	Sr	Ti
Case 1	700	100	50000	40	2000	50000	25	50000	1000	50000	500	400	500	10

Рис.5.1.29

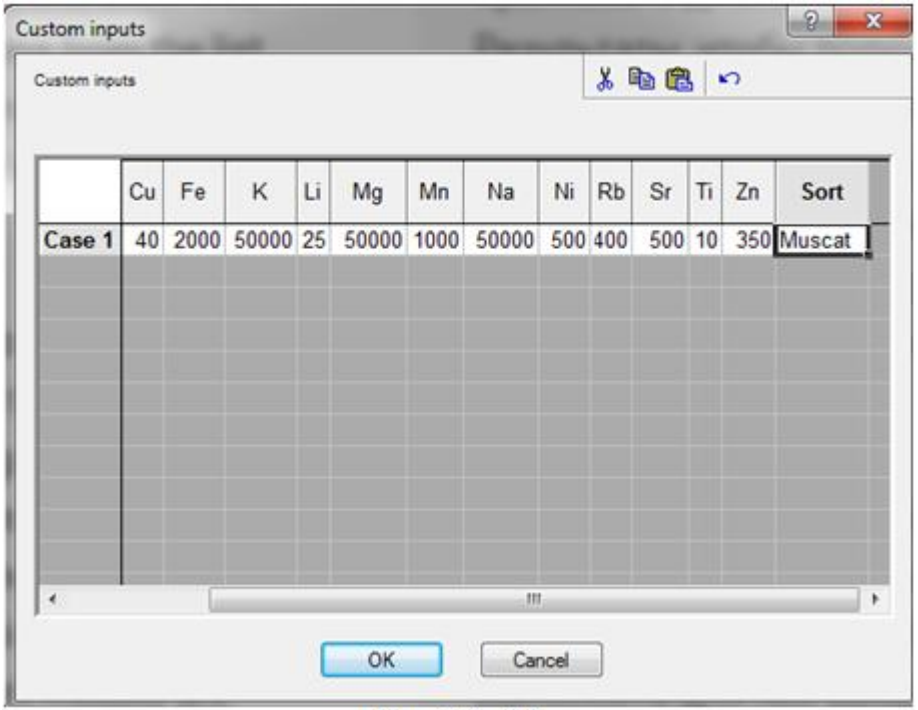

	Cu	Fe	K	Li	Mg	Mn	Na	Ni	Rb	Sr	Ti	Zn	Sort
Case 1	40	2000	50000	25	50000	1000	50000	500	400	500	10	350	Muscat

Рис.5.1.30

В поле в нижней части диалога автоматически будут вписаны значения предикторных переменных и результат идентификации региона – Taman (рис.5.1.31).

Табличный результат прогноза можно увидеть, если воспользоваться кнопкой Custom predictions (табл.5.15) – в соответствии с введенными концентрациями металлов и сорта винограда нейронная сеть №4 идентифицировала регион произрастания винограда как Таманскую зону (рис.5.1.26).

При необходимости удалить предыдущие прогнозы из поля в нижней части диалога, пользователю следует установить флажок на опцию Clear previous predictions (очистить предыдущие прогнозы).

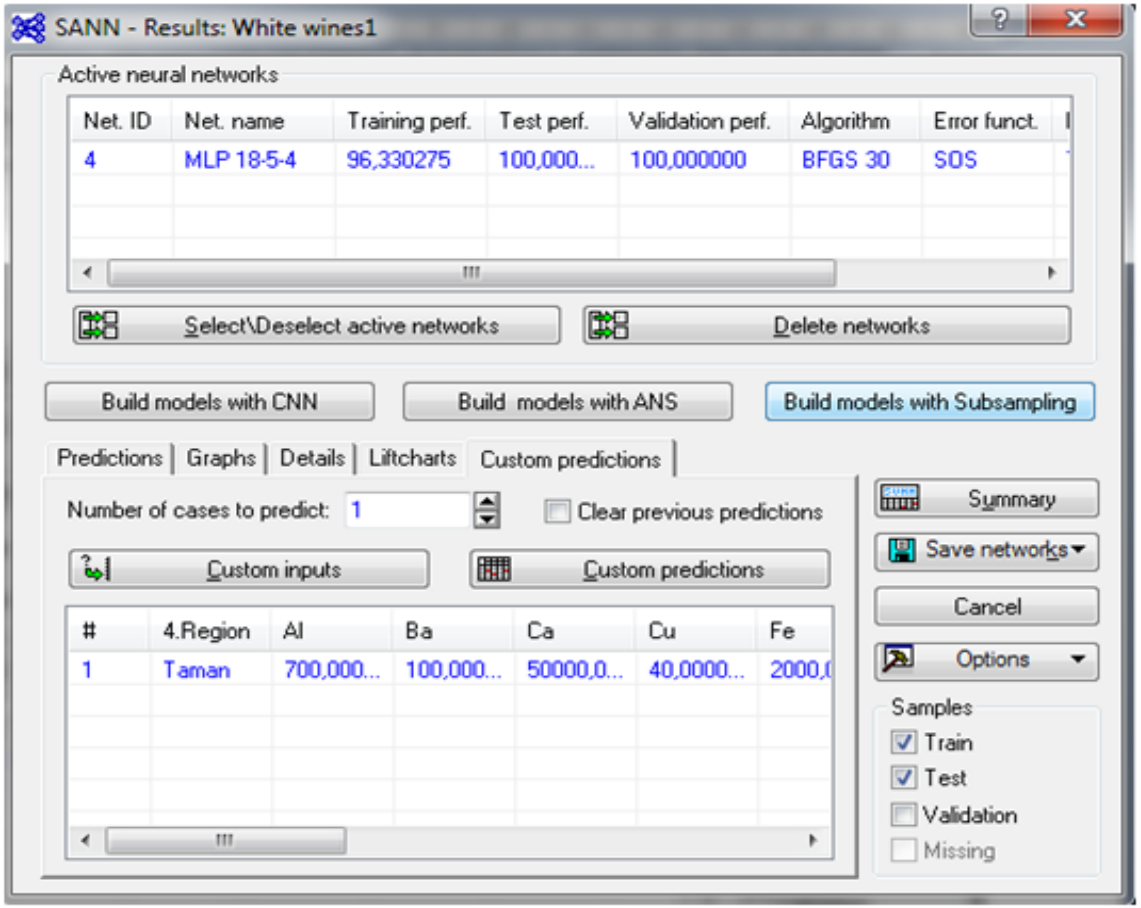

Рис.5.1.31

Таблица 5.15

Cases	Custom predictions spreadsheet (White wines1)								
	4.Region_(t)	Al	Ba	Ca	Cu	Fe	K	Li	Mg
1	Taman	700,0000	100,0000	50000,00	40,00000	2000,000	50000,00	25,00000	50000,00

Продолжение таблицы 5.15

Cases	Custom predictions spreadsheet (White wines1)							
	Mn	Na	Ni	Rb	Sr	Ti	Zn	Sort
1	1000,000	50000,00	500,0000	400,0000	500,0000	10,00000	350,0000	Muscat