Лекция 9

ЧАСТОТНЫЙ АНАЛИЗ.

Таблицы частот.

Таблицы частот, или одновходовые таблицы, представляют собой простейший метод анализа **категориальных** (номинальных) и **непрерывных** переменных. Часто их используют как одну из процедур разведочного анализа, чтобы просмотреть, каким образом различные группы объектов распределены в выборке, или как распределены значения непрерывных переменных. Например, в социологических опросах таблицы частот могут отображать число мужчин и женщин, выразивших симпатию тому или иному политическому деятелю, число респондентов из определенных этнических групп, голосовавших за того или иного кандидата, стоимость автомобилей за определенный период времени и т.д. В медицинских исследованиях табулируют пациентов с определенными симптомами, в маркетинговых исследованиях – покупательский спрос на товары разного типа у разных категорий населения, в медицине – физиологические и медицинские показатели больных.

Чтобы открыть диалоговое окно **Frequency tables** (таблицы частот), надо из стартовой панели **Basic Statistics/Tables** выбрать команду **Frequency tables** (рис.5.1). Это диалоговое окно предлагает множество настроек, позволяющих изменять вид и группировку в таблицах частот, а также проверять нормальность распределения, в том числе и графическими способами.

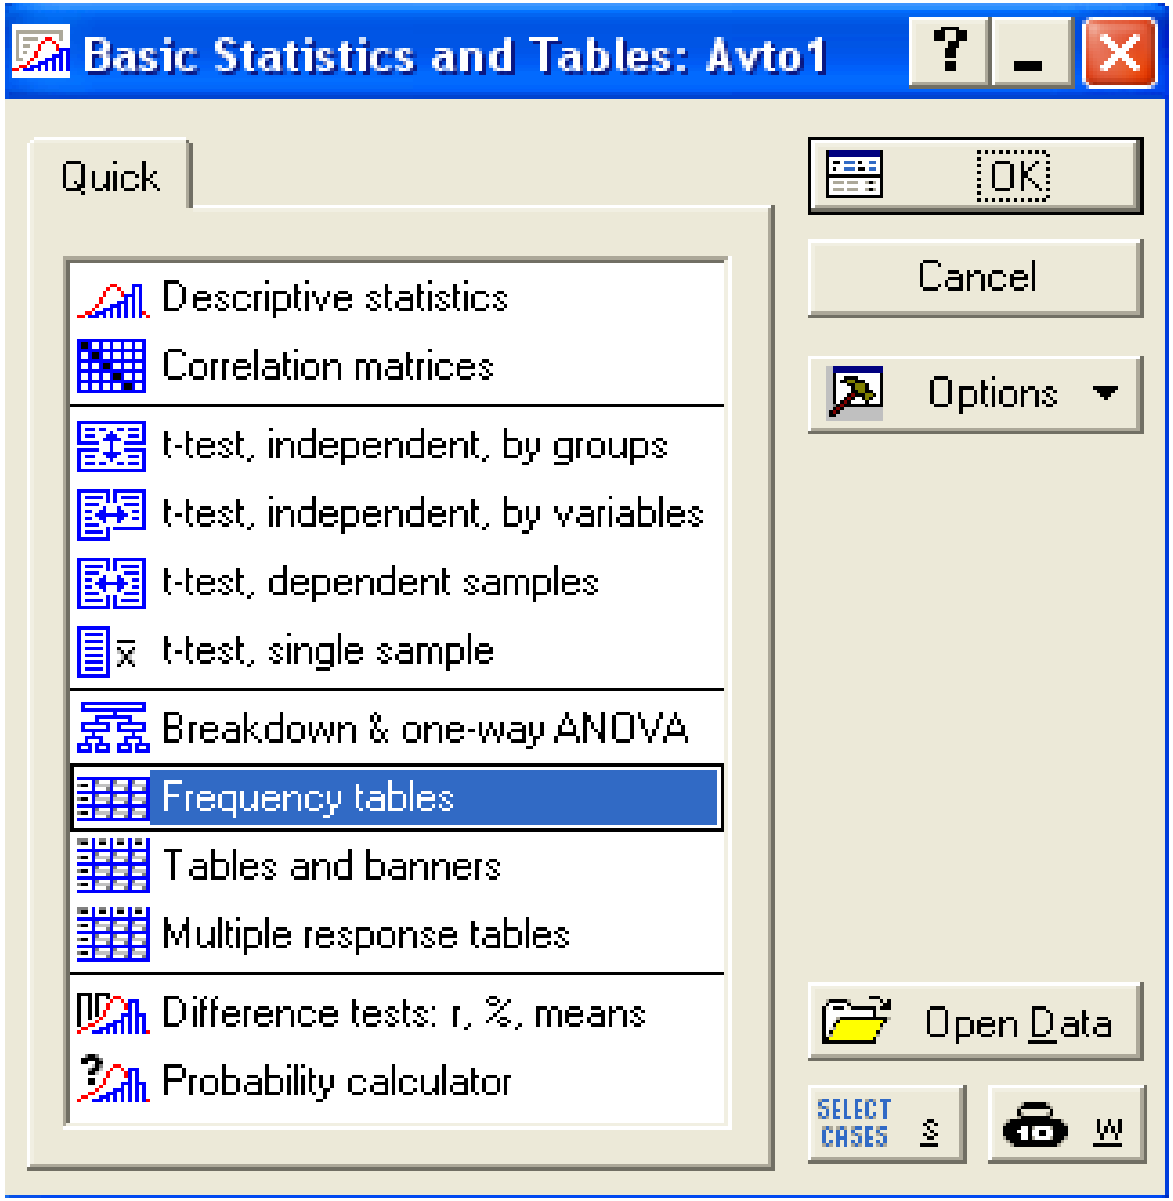
Basic Statistics and Tables: Avto1
Quick
Descriptive statistics
Correlation matrices
t-test, independent, by groups
t-test, independent, by variables
t-test, dependent samples
t-test, single sample
Breakdown & one-way ANOVA
Frequency tables
Tables and banners
Multiple response tables
Difference tests: r, %, means
Probability calculator
OK
Cancel
Options
Open Data
SELECT CASES
S
W

Рис.5.1

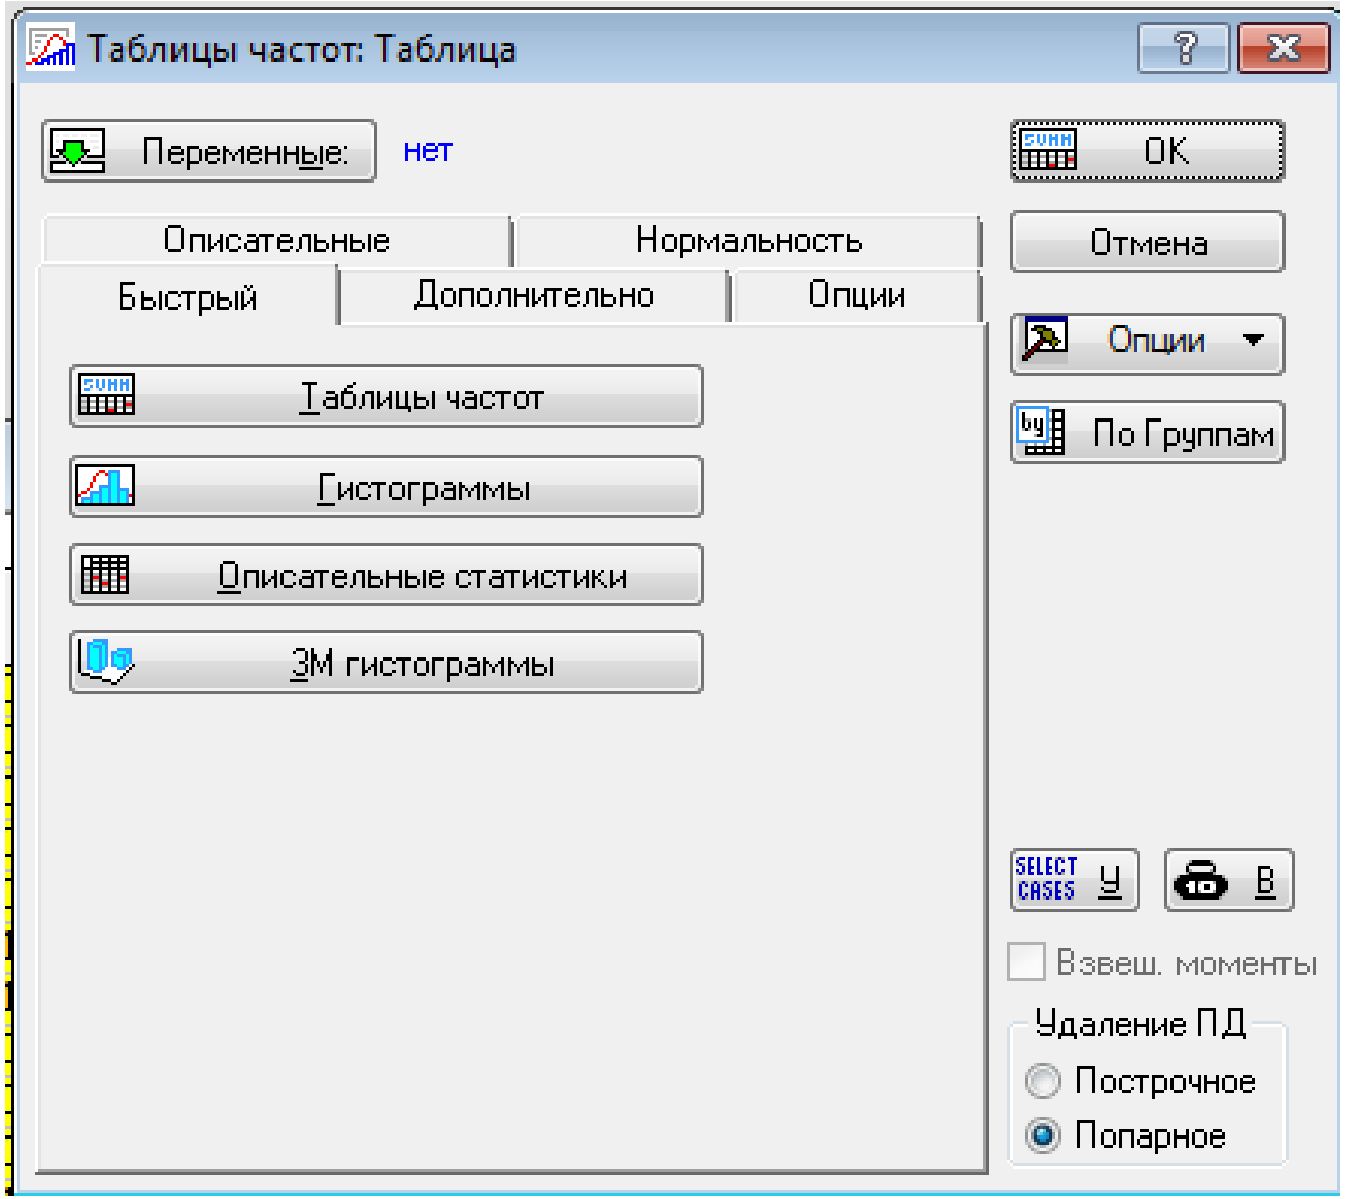
Таблицы частот: Таблица
Переменные:
нет
OK
Описательные
Нормальность
Отмена
Быстрый
Дополнительно
Опции
Опции
Таблицы частот
По Группам
Гистограммы
Описательные статистики
3М гистограммы
SELECT CASES
У
В
Взвеш. моменты
Удаление ПД
Построчное
Попарное

Рассмотрим функциональное назначение некоторых кнопок на вкладке **Quick.**

Variables. Открывается диалоговое окно выбора одного списка переменных для анализа.

Summary: Frequency tables. Открываются итоговые таблицы частот для выбранных переменных.

Histograms. Программа строит последовательность гистограмм для выбранных переменных. Одна гистограмма – для одной переменной**.**

Descriptive Statistics. Программа строит таблицу результатов с описательными статистиками для выбранных переменных.

3D histograms, bivariate distributions. Программа строит каскад трехмерных гистограмм для пар выбранных переменных, один график — на каждую пару. После нажатия этой кнопки программа попросит пользователя выбрать два набора переменных (из списка выбранных ранее с помощью кнопки **Variables**). Гистограммы будут построены для каждой пары переменных, из разных списков.

Рассмотрим возможности вкладки **Advanced** (рис.5.2). Установки опций под общим названием **Categorization methods for tables & graphs** (методы категоризации для таблиц и графиков) определяют, как будут сгруппированы или табулированы выбранные переменные в таблицах частот и гистограммах, как обрабатываются наблюдения при вычислении.

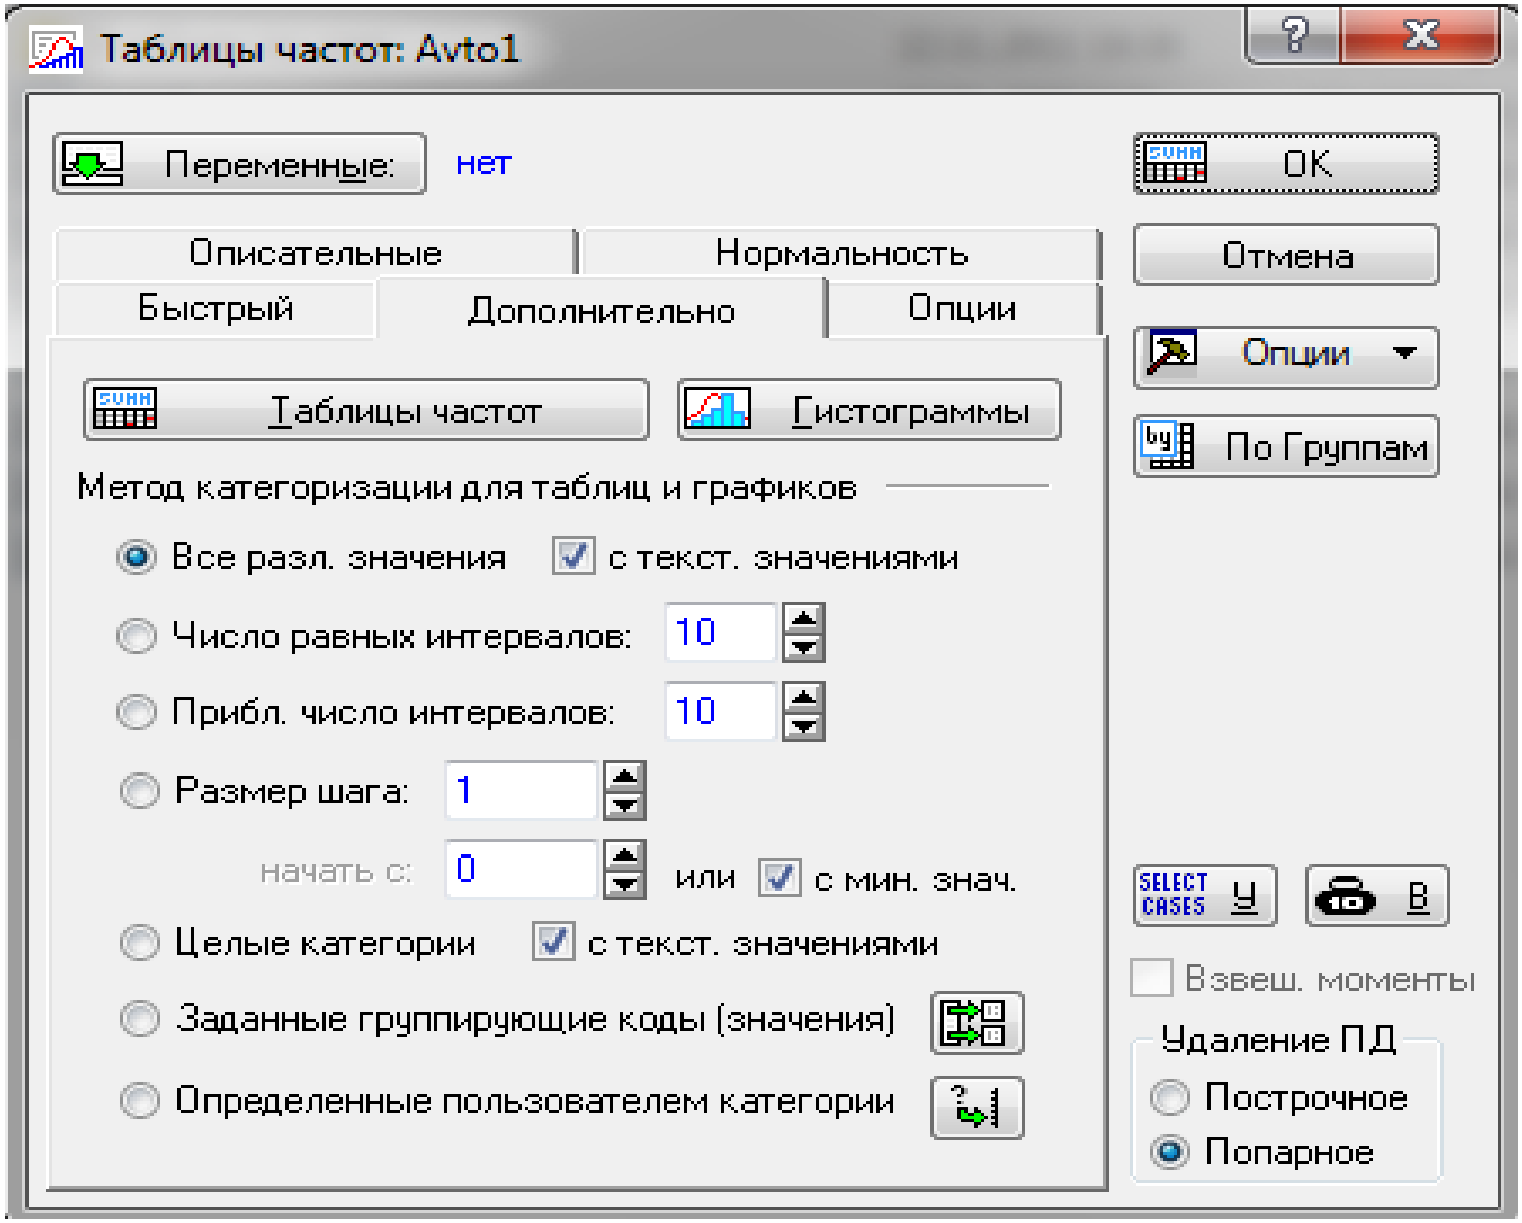
Таблицы частот: Avto1
Переменные:
нет
OK
Описательные
Нормальность
Отмена
Быстрый
Дополнительно
Опции
Опции
Таблицы частот
Гистограммы
По Группам
Метод категоризации для таблиц и графиков
Все разл. значения
с текст. значениями
Число равных интервалов:
10
Прибл. число интервалов:
10
Размер шага:
1
начать с:
0
или
с мин. знач.
Целые категории
с текст. значениями
Заданные группирующие коды (значения)
Определенные пользователем категории
SELECT CASES
Взвеш. моменты
Удаление ПД
Построчное
Попарное

Рис. 5.2

Если установить флажок на *All distinct values* (все различные значения), то таблицы частот будут строиться с учетом всех различных значений анализируемых переменных, включая непрерывные и категориальные переменные.

Если установить флажок на *With text labels* (с текстовыми значениями), то таблицы частот будут строиться с учетом всех различных текстовых значений выбранных переменных, т.е. для категориальных переменных будут отображены названия групп, в противном случае будут отображены числовые коды. Для непрерывных с флажком и без будут приведены их значения.

Если установить флажок на *No of exact intervals* (число равных интервалов), то диапазон значений каждой переменной будет разделен на указанное число интервалов. Если установить флажок на *«Neat» intervals; approximate no* (приблизительное число интервалов; приближенное число), то программа построит приближенные интервалы и выберет приближенный размер шага так, что последняя десятичная цифра будет 0 или 5 (например, 10,5, 11,0, 11,5 и т.д.). Такие интервалы легче интерпретировать, чем интервалы, содержащие много десятичных знаков (например, 10,12423, 10,13533 и т.д.).

Если установить флажок на *Step size* (размер шага), то программа задает ширину интервала категоризации в таблицах частот и гистограммах.

Если установить флажок на *At minimum* (начать с минимального значения), то группировка начинается с минимального значения переменной (первый интервал группировки включает это значение). В противном случае левая граница первого интервала группировки задается пользователем в соответствующем поле.

Если установить флажок на *Integer categories* (целые категории), то будут определены частоты для целых значений, все нецелые значения переменных будут проигнорированы программой.

Если установить флажок на *With text labels* (с текстовыми значениями), то категории при выборе *Frequency tables* и *Histogram* будут помечены текстовыми значениями (например, *Japan*, *Europe*), а не целыми значениями (например, 1, 2), которые доступны в текущем файле данных.

Если установить флажок на *Specific grouping codes(values)* (заданные группирующие коды (значения)), то пользователь с помощью расположенной рядом с флажком кнопки может указать значения **категориальной** переменной для которой надо строить таблицы частот/гистограммы. Опция нужна, если строим таблицу частот или гистограмму не для всех значений категориальной переменной.

Если установить флажок на *User-specified categories* (определенные пользователем категории), то логическими условиями можно отнести наблюдения к определенным категориям (до 256) в таблице частот. Логические условия могут быть сложными и включать различные переменные файла данных, а также наблюдения. Гистограммы при этом не строятся, а таблицы частот показывают сколько наблюдений попало в заданные категории и сколько наблюдений не выбрано. Например, если выделим эту опцию и щелкнем по кнопке, то откроется окно (см. рис.), запишем условия выбора, щелкнем по ОК и вернувшись в исходное окно нажмем на кнопку *Таблицы частот* или ОК. Появится таблица (см. рис.)

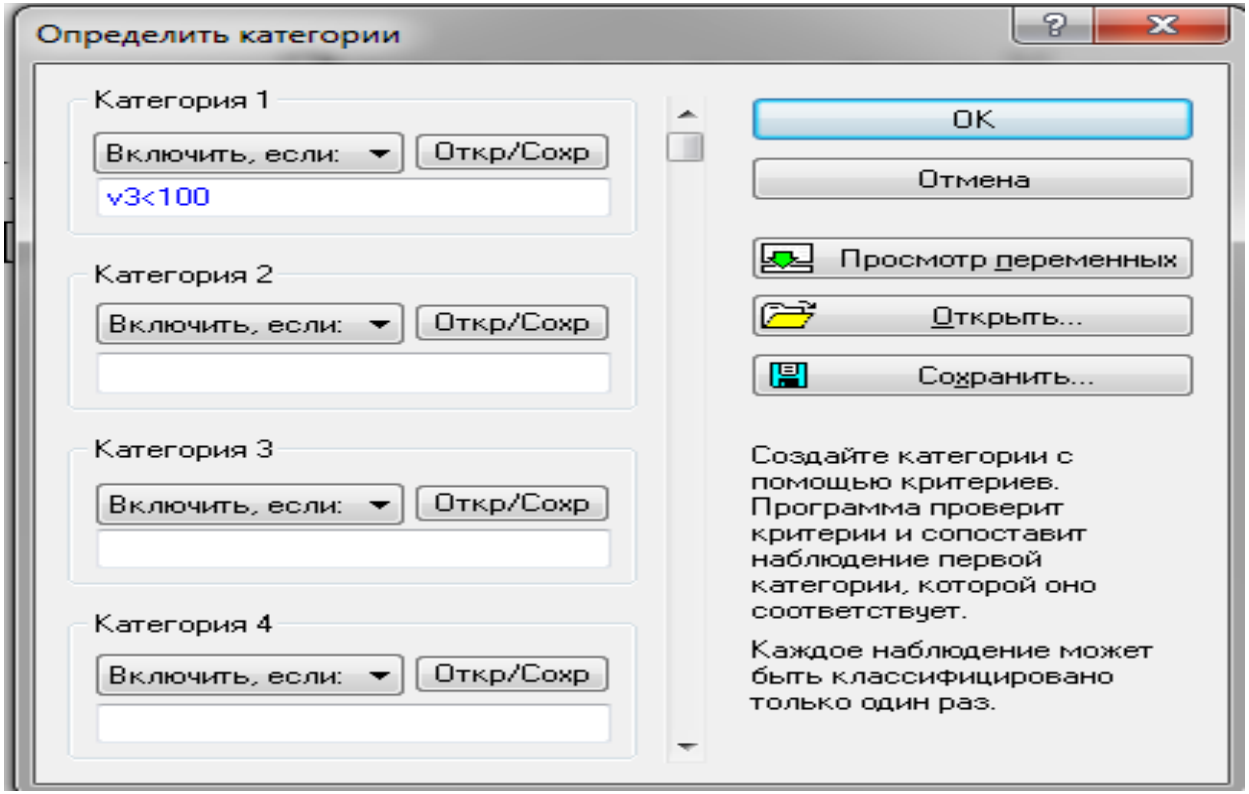

Группа	Таблица частот: Таблица частот для категорий пользователя (Avto1)			
	Частота	Кумул. Частота	Процент	Кумул. Процент
Вкюч. v3<100	9	9	60,00000	60,0000
Не выбраны	6	15	40,00000	100,0000

Рассмотрим построение и анализ таблиц частот для файла **Auto1** (рис.5.3), выберем для анализа переменную пробег1**.**

	Пробег до кап.рем., после кап. рем.				
	1 Произв.	2 Тип.топл.	3 Пробег1	4 Пробег2	5 Пробег3
Opel Astra	Europe	P	65	240	230
Skoda Fabia 1,2	Europe	P	70	250	220
Mitsubishi Pinin	Japan	G+P	110	300	280
Skoda Ambiente 1,6	Europe	P	60	230	230
Nissan Almera 1,5	Japan	G+P	90	280	260
Nissan Maxima 2,0 QX	Japan	G+P	100	300	280
Audi A4 2.0 MultiTronic	Europe	P	80	250	230
Nissan Maxima 3,0 SE	Japan	P	110	310	310
Mitsubishi Pajero III	Japan	G+P	95	320	280
Toyota Corolla	Japan	G+P	100	300	300
Toyota Carina	Japan	D	110	310	300
VW Passat1,8 T	Europe	D	70	275	250
VW Bora 1,6	Europe	D	80	260	230
Subaru Legacy	Japan	D	105	315	350
VW Golf 1,6	Europe	D	75	250	240

Рис. 5.3

Произведем установки в соответствии с рис.5.2, выбрав переменную *Пробег 1* получим гистограмму, изображенную на рис. 5.4. У нас в таблице 10 различных значений *Пробега 1*, программа вычислила их частоты и построила гистограмму и таблицу частот

Группа	Таблица частот: Пробег1 (Avto1)			
	Частота	Кумул. Частота	Процент	Кумул. Процент
60	1	1	6,66667	6,6667
65	1	2	6,66667	13,3333
70	2	4	13,33333	26,6667
75	1	5	6,66667	33,3333
80	2	7	13,33333	46,6667
90	1	8	6,66667	53,3333
95	1	9	6,66667	60,0000
100	2	11	13,33333	73,3333
105	1	12	6,66667	80,0000
110	3	15	20,00000	100,0000
Пропущ.	0	15	0,00000	100,0000

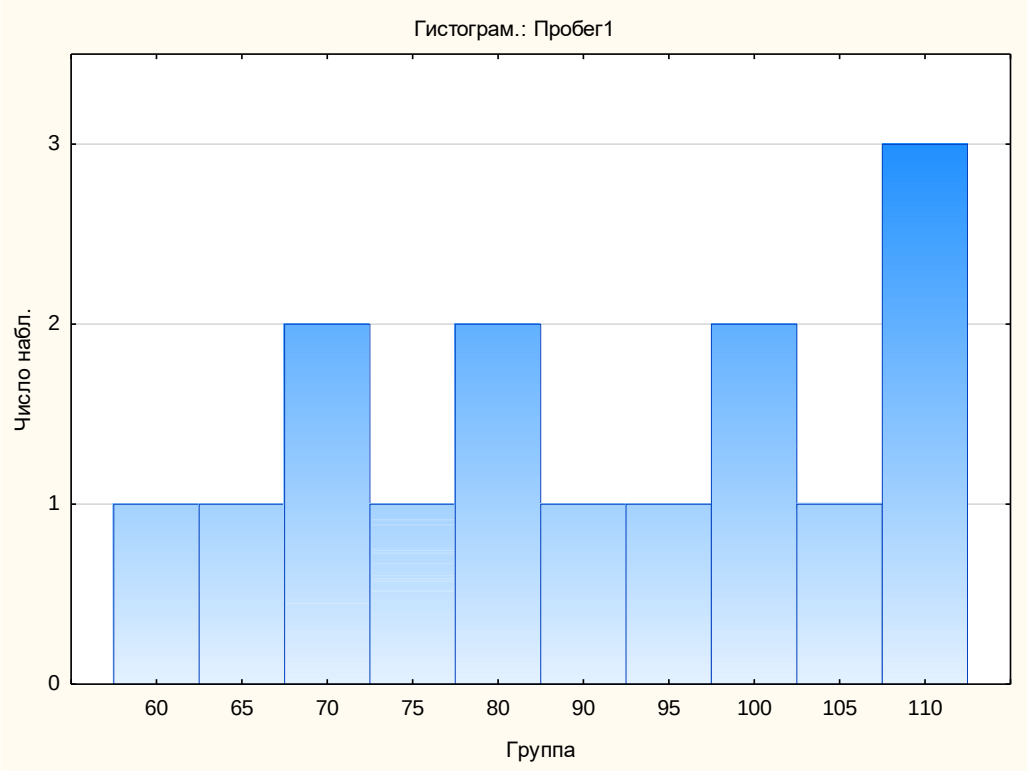

Рис. 5.4

Выделим опцию *Число равных интервалов =10 на рис.5.2*

От ... До	Таблица частот: Пробег1 (Avto1)			
	Частота	Кумул. Частота	Процент	Кумул. Процент
57,22222<x<=62,77778	1	1	6,66667	6,6667
62,77778<x<=68,33333	1	2	6,66667	13,3333
68,33333<x<=73,88889	2	4	13,33333	26,6667
73,88889<x<=79,44444	1	5	6,66667	33,3333
79,44444<x<=85,00000	2	7	13,33333	46,6667
85,00000<x<=90,55556	1	8	6,66667	53,3333
90,55556<x<=96,11111	1	9	6,66667	60,0000
96,11111<x<=101,6667	2	11	13,33333	73,3333
101,6667<x<=107,2222	1	12	6,66667	80,0000
107,2222<x<=112,7778	3	15	20,00000	100,0000
Пропуш	0	15	0,00000	100,0000

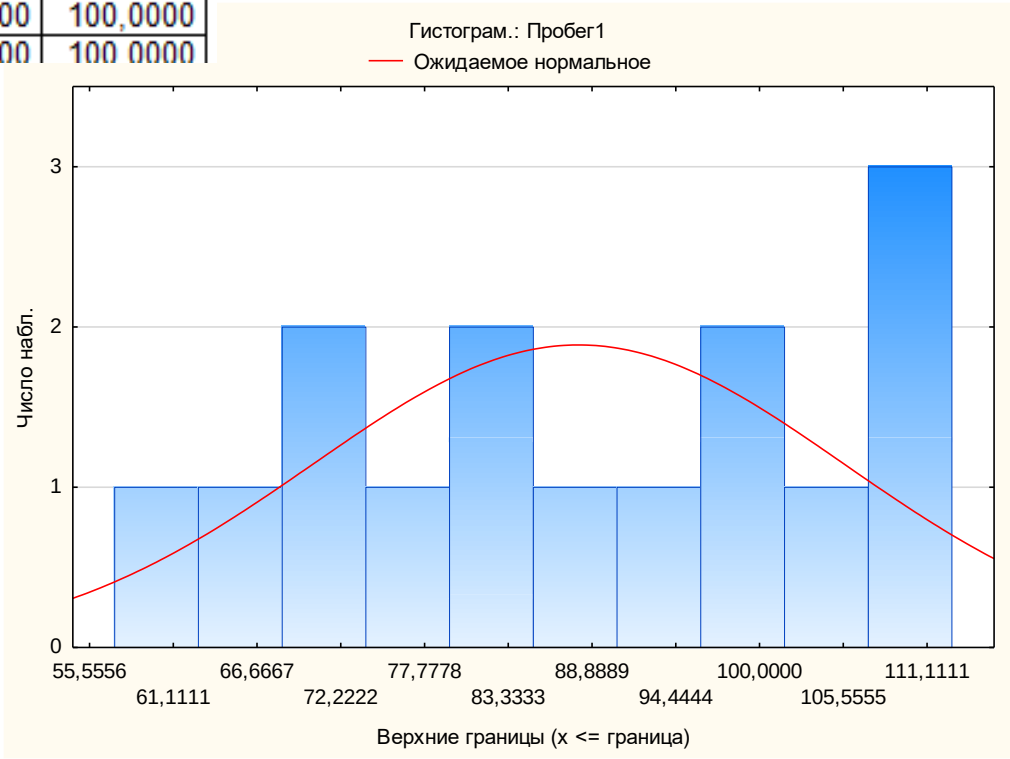

Если выделить опцию *«Neat» intervals; approximate no*, то получим новую гистограмму и таблицу с целыми концами интервалов (рис.5.5).

От ... До	Таблица частот: Пробег1 (Avto1)			
	Частота	Кумул. Частота	Процент	Кумул. Процент
50,00000<x<=60,00000	1	1	6,66667	6,6667
60,00000<x<=70,00000	3	4	20,00000	26,6667
70,00000<x<=80,00000	3	7	20,00000	46,6667
80,00000<x<=90,00000	1	8	6,66667	53,3333
90,00000<x<=100,0000	3	11	20,00000	73,3333
100,0000<x<=110,0000	4	15	26,66667	100,0000
110,0000<x<=120,0000	0	15	0,00000	100,0000
120,0000<x<=130,0000	0	15	0,00000	100,0000
Пропущ.	0	15	0,00000	100,0000

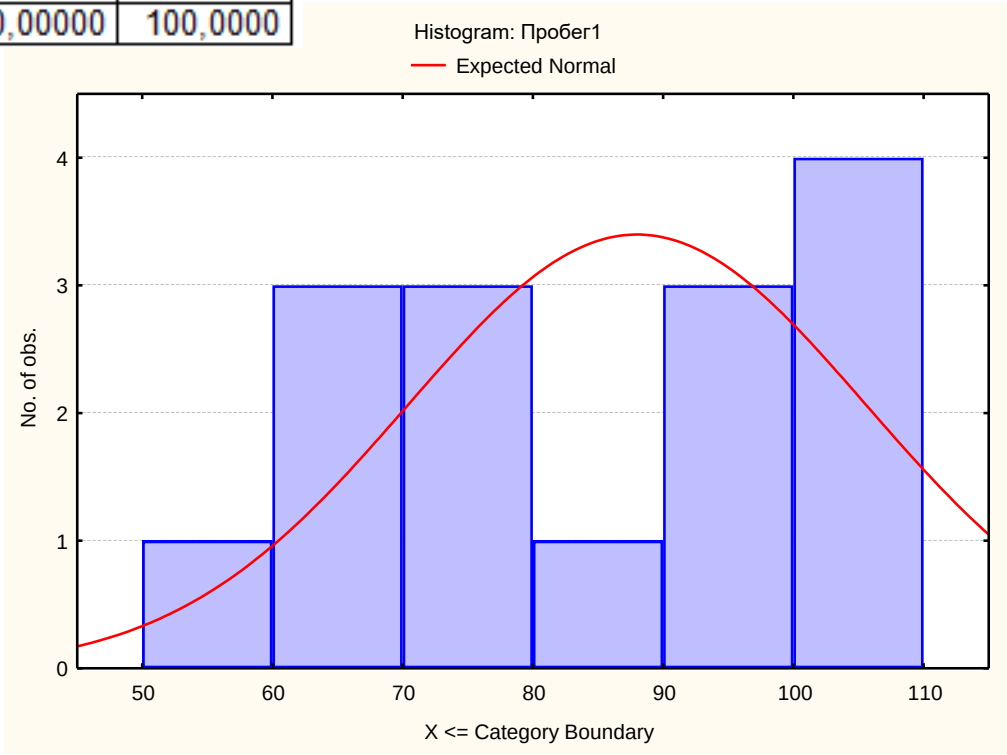

Рис. 5.5

Если выбрать для анализа переменные *Произв.* и *Тип.топлива*, то получим соответственно таблицы частот и гистограмму, изображенную на рис. 5.6-5.8.

Категория	Таблица частот: Произв. (Auto)			
	Частота	Кумул. частота	Процент	Кумул. процент
Japan	8	8	53,33333	53,3333
Europe	7	15	46,66667	100,0000
Пропущ.	0	15	0,00000	100,0000

Рис. 5.6

Категория	Таблица частот: Тип.топл. (Auto)			
	Частота	Кумул. частота	Процент	Кумул. процент
P	5	5	33,33333	33,3333
D	5	10	33,33333	66,6667
G+P	5	15	33,33333	100,0000
Пропущ.	0	15	0,00000	100,0000

Рис. 5.7

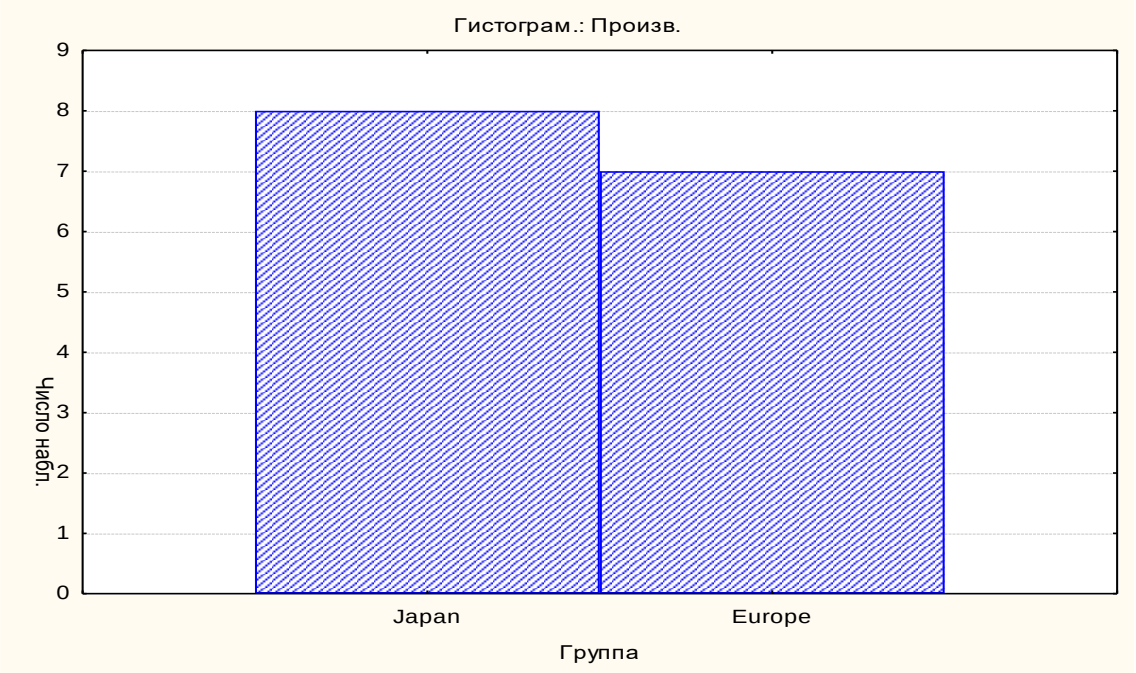

Рис. 5.8

Вкладка **Normality** предназначена для проверки соответствия закона распределения нормальному.

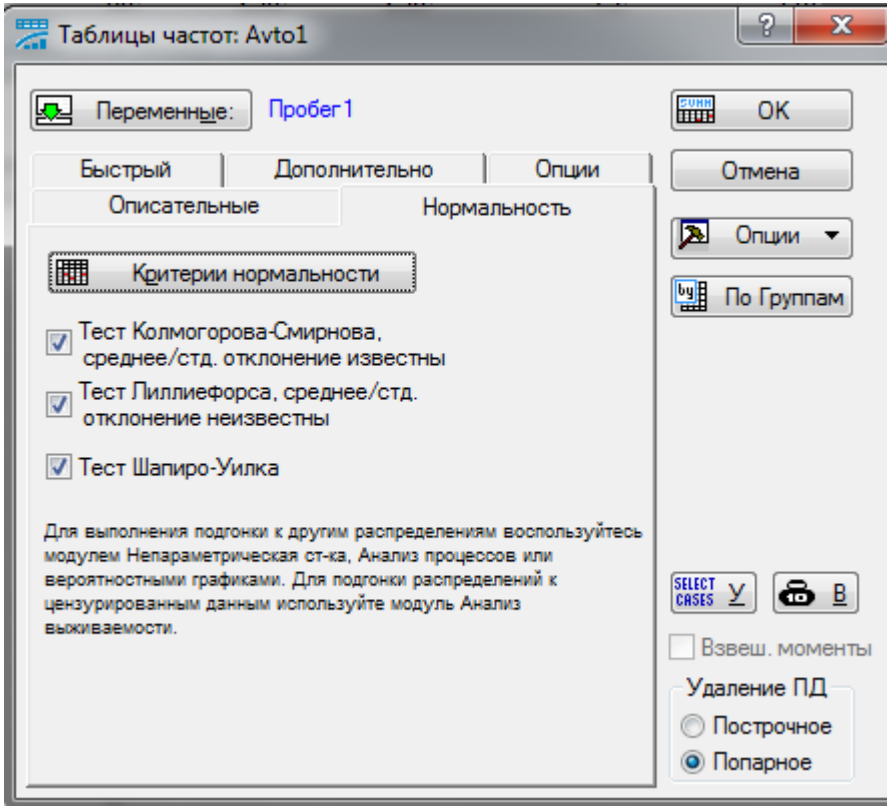

Переменная	Критерии нормальности (Avto1)					
	N	макс.D	К.-С. p	Лиллиеф. p	W	p
Пробег1	15	0,152240	p > .20	p > .20	0,913833	0,155031

В соответствии с выделенными критериями, так как p>0.05, распределение **соответствует нормальному закону**

Вкладка **Descriptive** предназначена для анализа основных статистик исследуемых переменных.

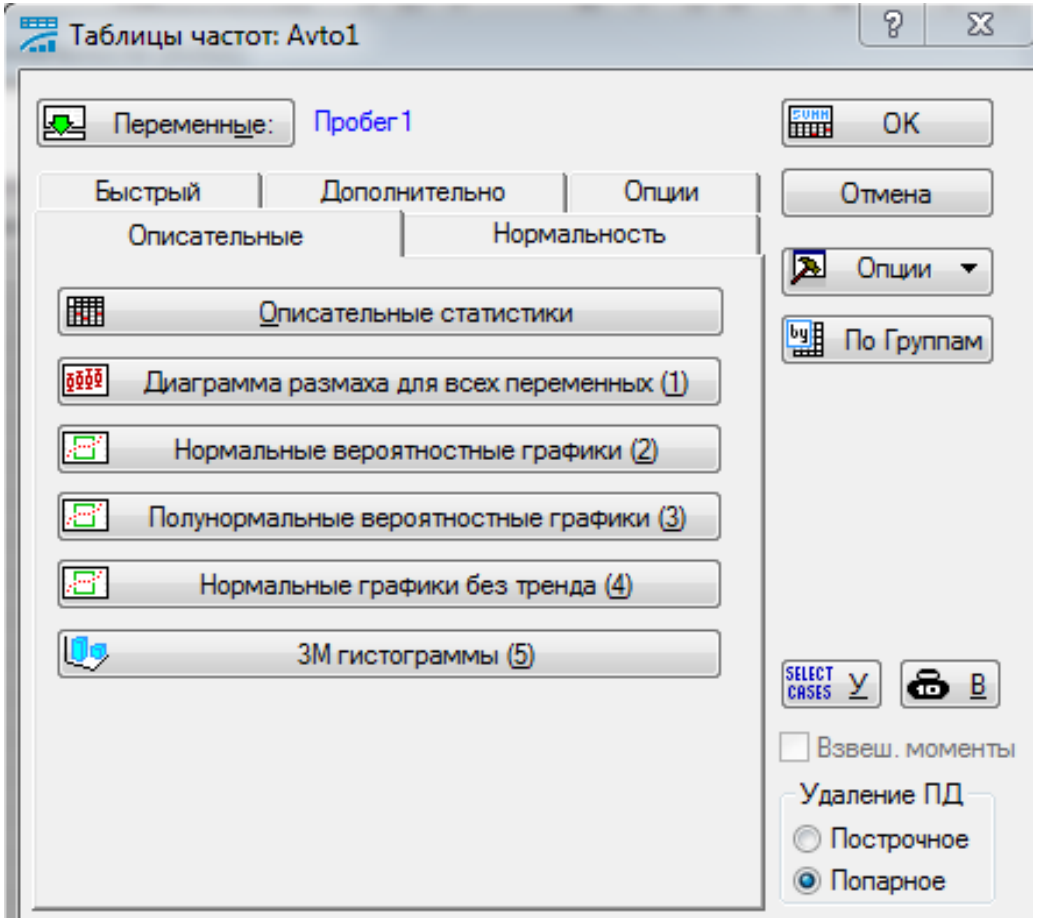

Таблицы кросстабуляции и таблицы флагов и заголовков.

Кросстабуляция (сопряжение) – процесс объединения двух (или нескольких) таблиц частот так, что каждая ячейка (клетка) в построенной таблице представляется единственной комбинацией значений или уровней табулированных переменных. Таким образом, кросстабуляция позволяет совместить частоты появления наблюдений на разных уровнях рассматриваемых факторов. Исследуя эти частоты, можно определить характер, или структуру взаимосвязи между табулированными переменными. Обычно табулируются категориальные переменные или переменные с относительно небольшим числом значений. Если надо табулировать непрерывную переменную (например, доход), то вначале ее следует перекодировать, разбив диапазон изменения на небольшое число интервалов (например, доход: низкий, средний, высокий). Если табулируем 2 номинальные переменные, то можно при помощи статистик оценить степень их взаимосвязи.

При помощи таблиц сопряженности можно оценить степень взаимосвязи между двумя категориальными переменными и исследовать структуру взаимосвязи!

Для построения таблиц кросстабуляции надо из стартовой панели **Basic Statistics/Tables** выбрать процедуру **Tables and banners** (рис.5.1). В стартовом окне выбираем вкладку *Сопряженности*

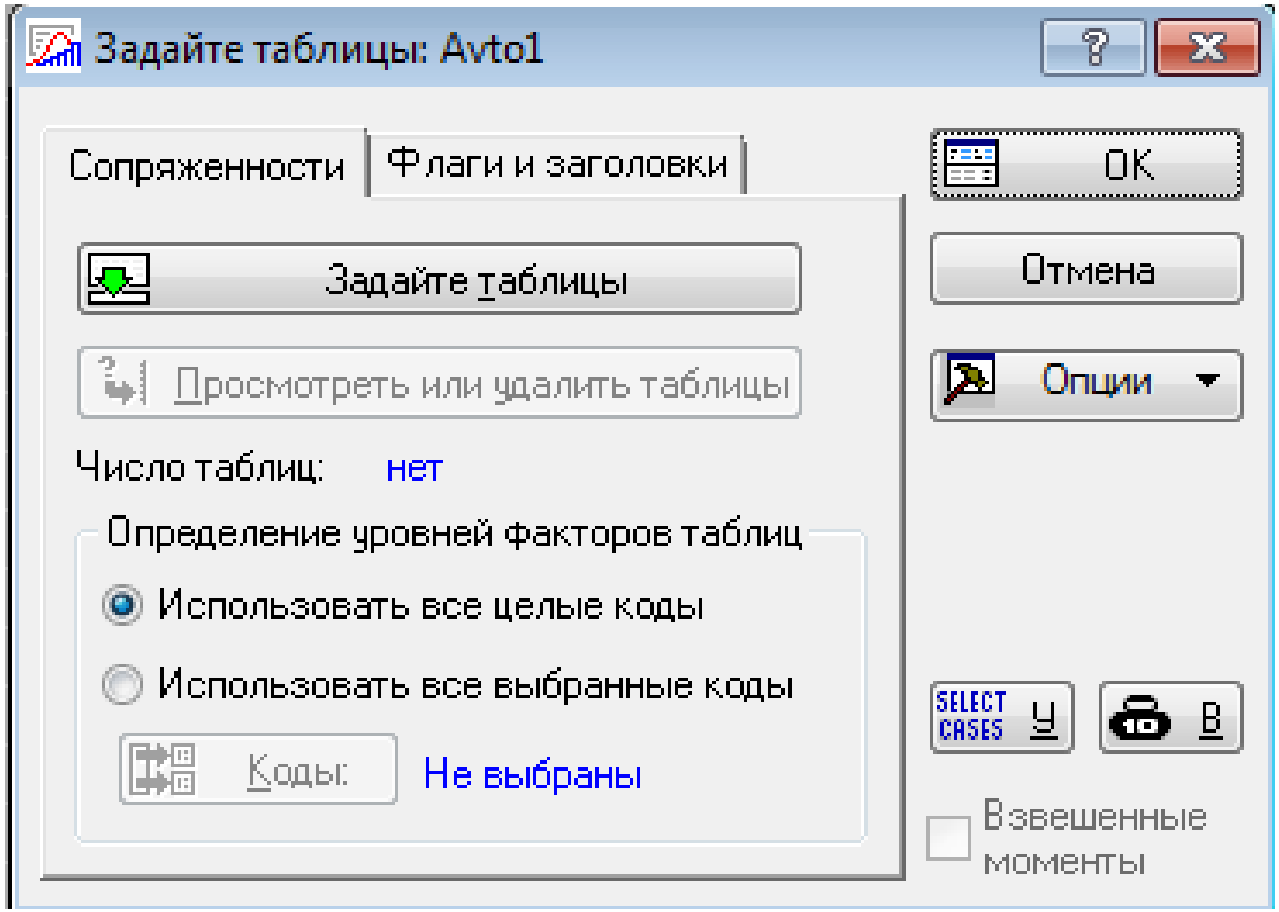

Далее при помощи кнопки Задайте таблицы в открывшемся окне указываем названия категориальных переменных, которые предполагается табулировать.

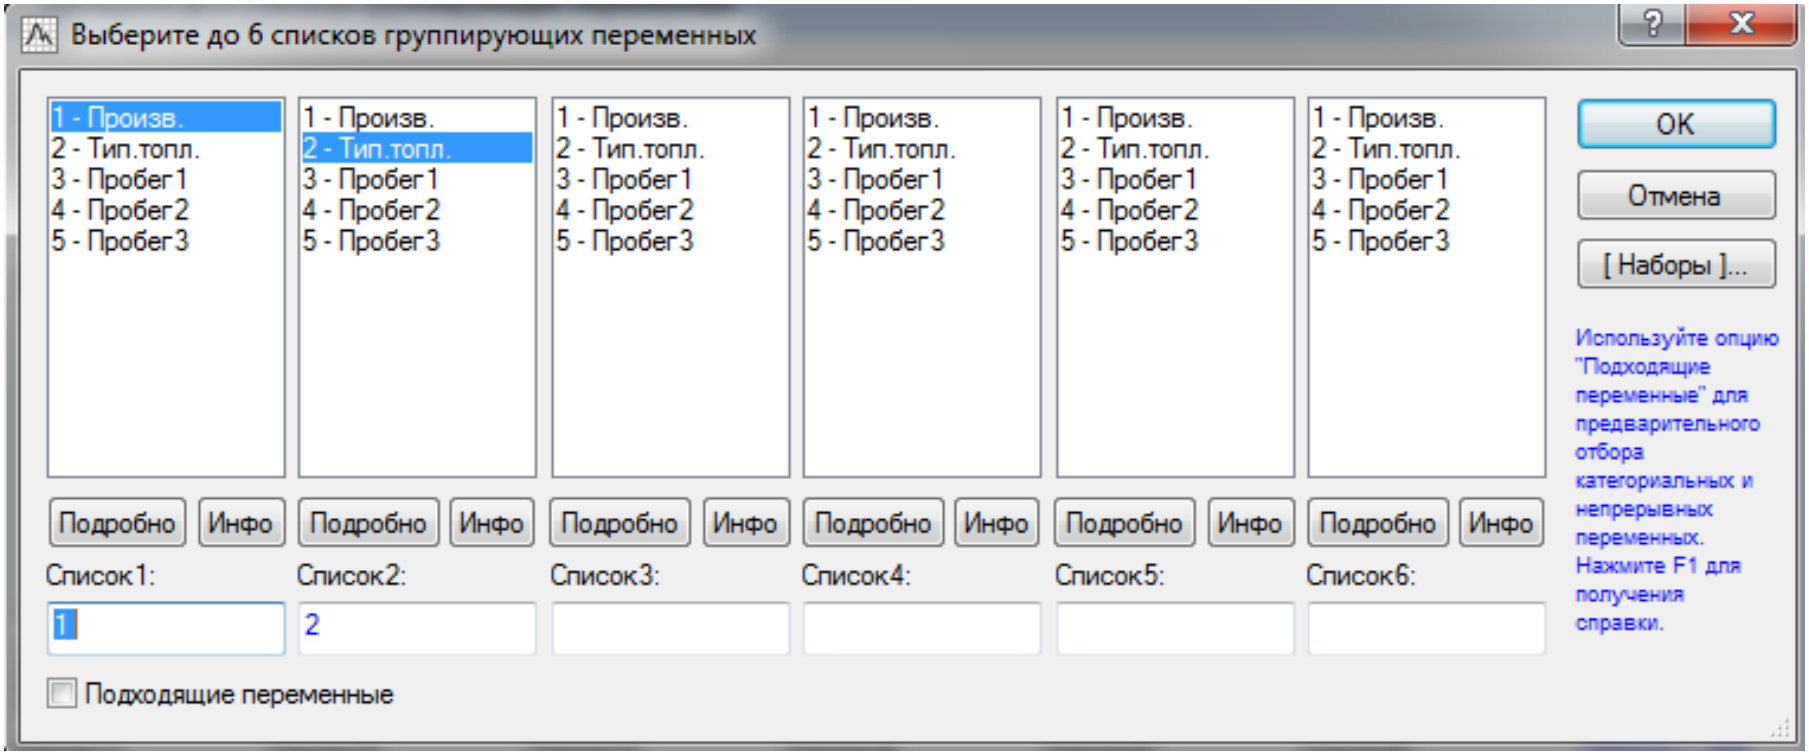
Выберите до 6 списков группирующих переменных
1 - Произв.
2 - Тип.топл.
3 - Пробег1
4 - Пробег2
5 - Пробег3
Подробно
Инфо
Список1:
Список2:
Список3:
Список4:
Список5:
Список6:
1
2
Подходящие переменные
OK
Отмена
[Наборы]...
Используйте опцию "Подходящие переменные" для предварительного отбора категориальных и непрерывных переменных. Нажмите F1 для получения справки.

Рассмотрим функциональные назначения кнопок вкладки **Advanced** (рис. 5.9).

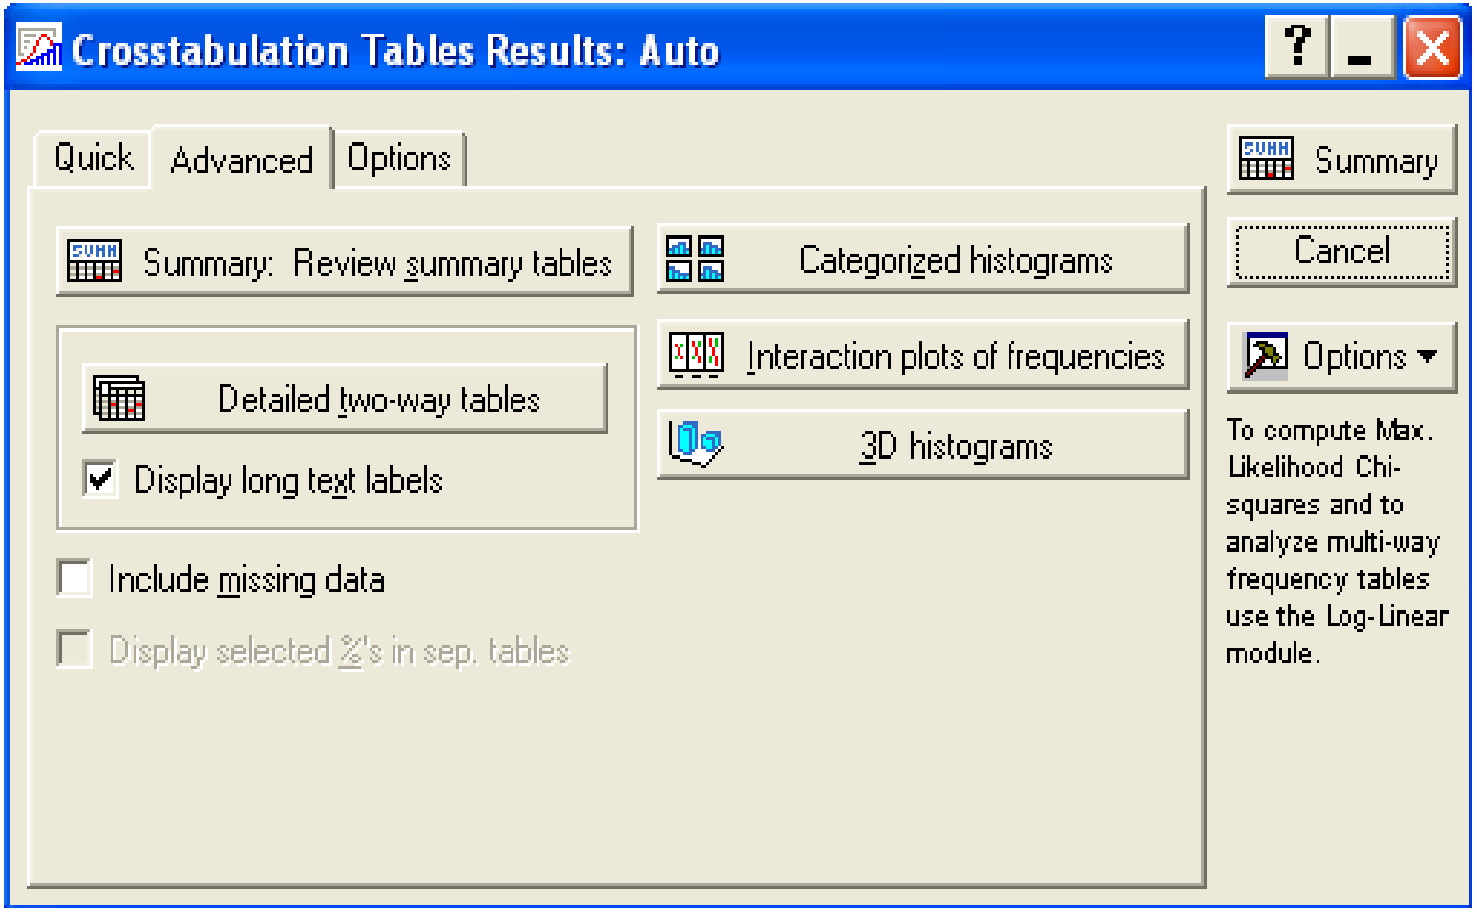

Рис. 5.9

Summary: Review Summary table (просмотреть итоговые таблицы). Программа строит итоговую таблицу для многовходовых таблиц сопряженности. Если выбрано более 2 категориальных переменных, то программа построит 1 таблицу сопряжения для всех переменных, так называемую многовходовую таблицу сопряженности. Если выбрано 2 категориальных переменных, то программа построит двухвходовую таблицу сопряженности

Detailed two-way tables (подробные двухвходовые таблицы). Программа строит таблицы результатов для двухвходовых таблиц. Если табулируется более 2 категориальных переменных, например 3, то программа построит 3 двухвходовые таблицы парно сопрягая все 3 переменные. Если выбрано 2 категориальных переменных, то построенная таблица совпадет с таблицей построенной при помощи кнопки **Summary: Review Summary table**.

Categorized histograms (категорированные гистограммы). Программа строит гистограммы частот для каждой из категориальных переменных

Interaction plots of frequencies (графики взаимодействий частот). Программа на одном графике построит линейные графики взаимодействия частот. Количество линейных графиков равно числу категориальных переменных.

3D histograms. Программа построит *3D* гистограммы для каждой двухвходовой таблицы.

Итоговая таблица частот (Avto1) Частоты выделенных ячеек > 10 (Маргинальные суммы не отмечены)				
Произв.	Тип.топл. P	Тип.топл. D	Тип.топл. G+P	Всего по стр.
Japan	1	2	5	8
Evropa	4	3	0	7
Всего	5	5	5	15

Произв.	2-входовая итоговая: наблюдаемые частоты (Avto1) Частоты выделенных ячеек > 10			
	Тип.топл. P	Тип.топл. D	Тип.топл. G+P	Всего по стр.
Japan	1	2	5	8
Evropa	4	3	0	7
Всего	5	5	5	15

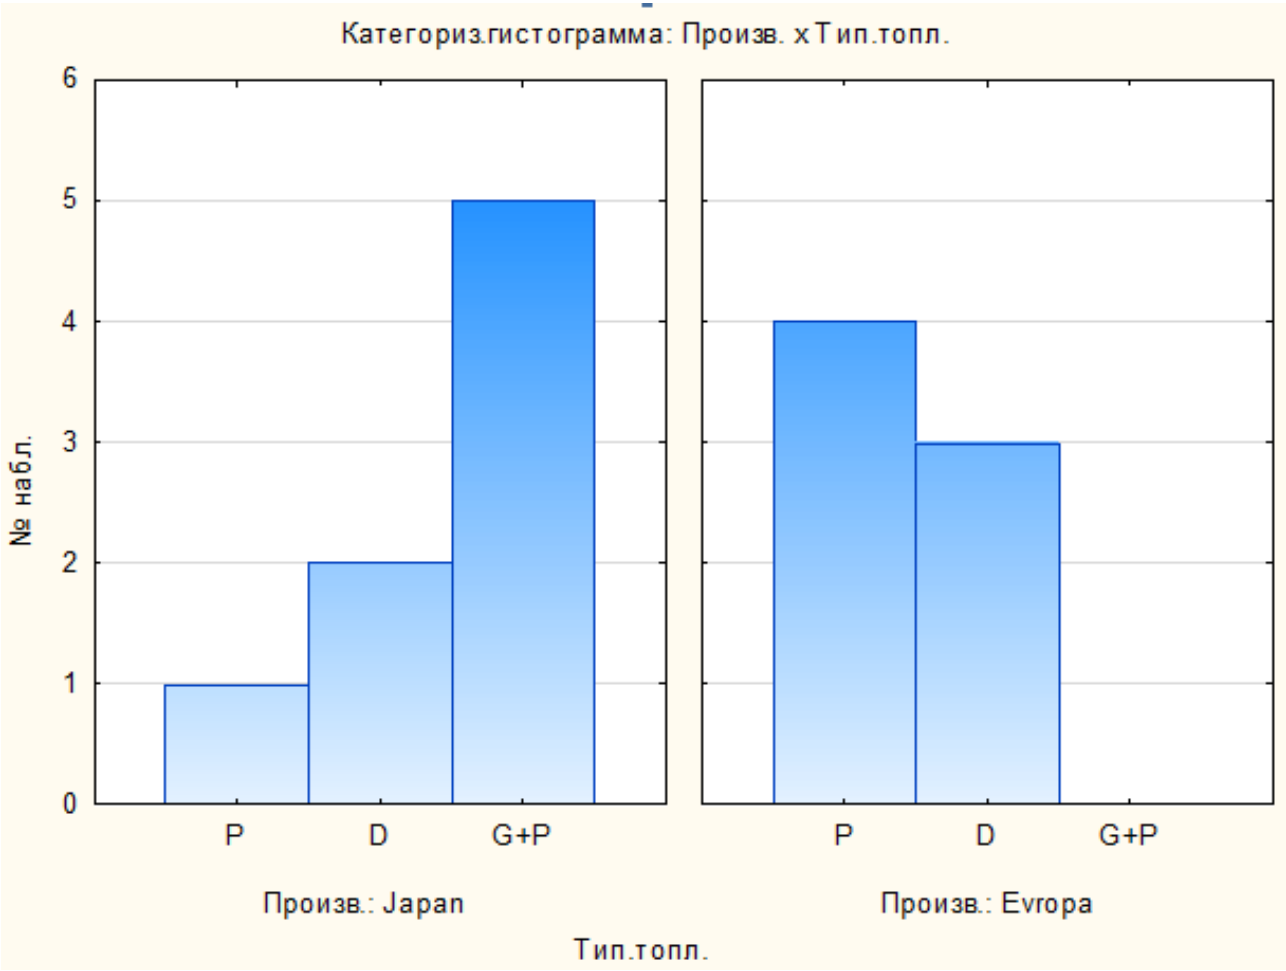

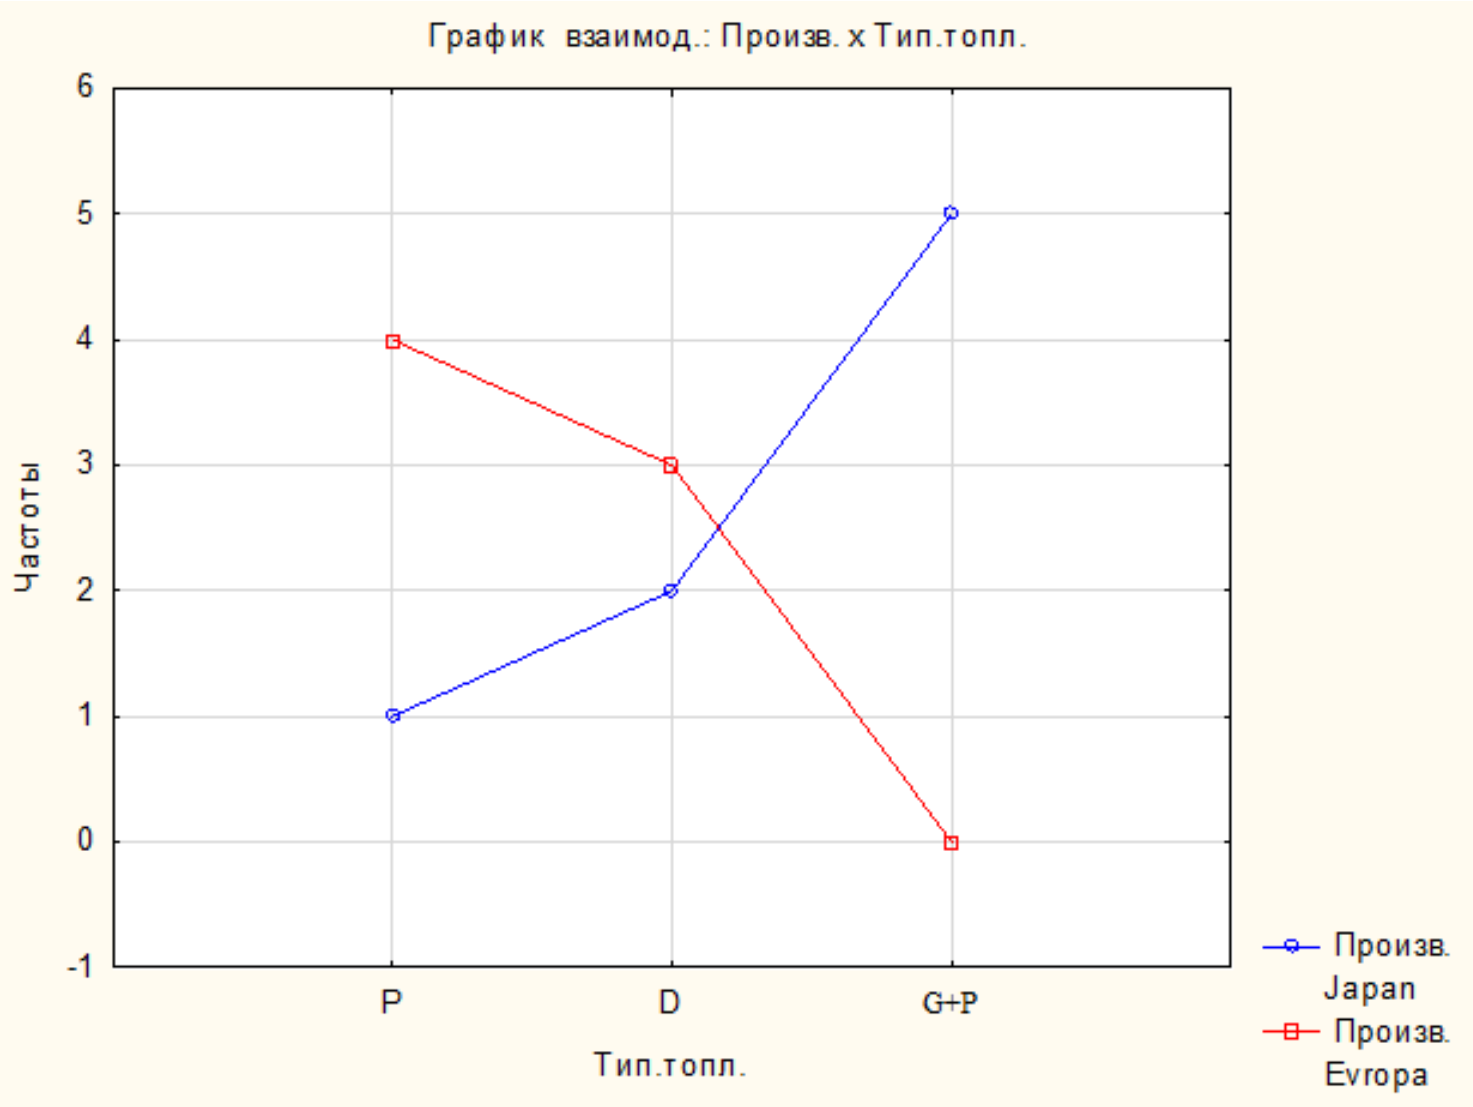
График взаимод.: Произв. x Тип.топл.
6
5
4
3
2
1
0
-1
Частоты
P
D
G+P
Тип.топл.
Произв. Japan
Произв. Evropa

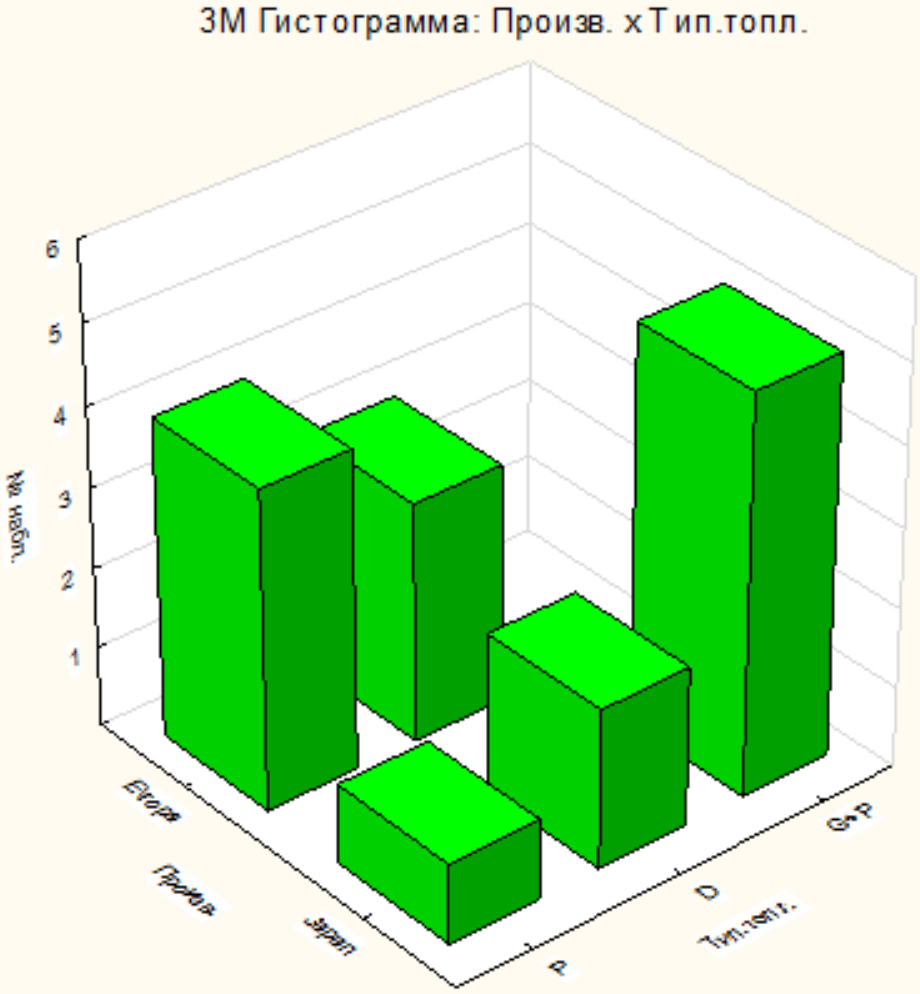
3M Гистограмма: Произв. x Тип.топл.
6
5
4
3
2
1
№ набл.
Европа
Америка
Азия
P
D
G+P
Тип.топл.

Рассмотрим вкладку **Options** (рис. 5.10).

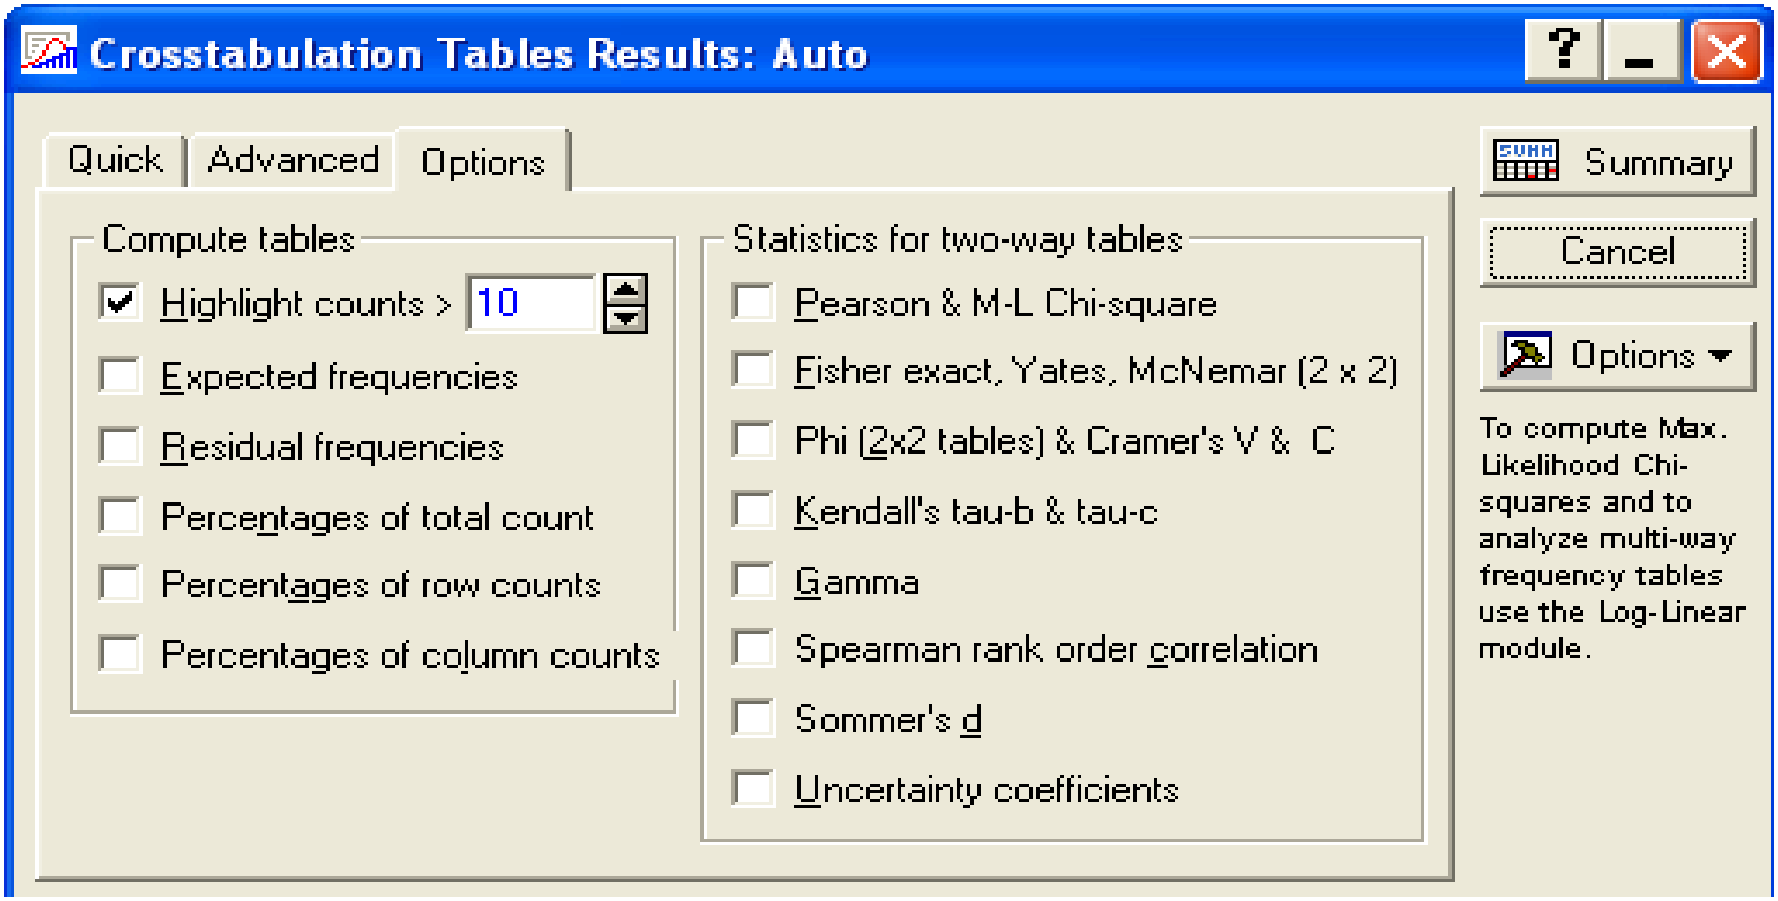

Рис. 5.10

Expected frequencies (ожидаемые частоты). Для всех двухвходовых таблиц будут вычислены ожидаемые частоты в предположении независимости всех факторов (переменных) в таблице.

Residual frequencies (остаточные частоты). Для всех двухвходовых таблиц и итоговой таблицы будут вычислены остаточные частоты – наблюдаемые частоты минус ожидаемые частоты.

Percentages of total count (проценты от общего числа). Программа вычислит проценты для каждой ячейки в **Summary tables**, **Detailed two-way tables** и в **Stub-and-banner table**. Проценты вычисляются от общего числа наблюдений в таблице. Если не установлен флажок на *Display selected %'s in sep. tables*, то проценты будут выведены в тех же таблицах, что и частоты.

Percentages of row counts (проценты по строке). Программа определит проценты относительно общего количества наблюдений в соответствующей строке текущей таблицы, для каждой ячейки в **Summary tables**, **Detailed two-way tables** и **в Stub-and-banner table.** Если не установлен флажок на *Display selected %'s in sep. tables*, то проценты будут выведены в тех же таблицах, что и частоты.

Percentages of column counts (проценты по столбцу). Аналогично предыдущему, только применительно к столбцам таблиц.

На рис. 5.11 приведены частоты, ожидаемые частоты и их разности для переменной *Произв.* файла **Auto1.**

Произв.	2-входовая итоговая: наблюдаемые частоты (Avto1) Частоты выделенных ячеек > 10			
	Тип топл. P	Тип топл. D	Тип топл. G+P	Всего по стр.
Japan	1	2	5	8
Evropa	4	3	0	7
Всего	5	5	5	15

Произв.	2-входовая итоговая: Ожидаемые частоты (Avto1) Частоты выделенных ячеек > 10			
	Тип топл. P	Тип топл. D	Тип топл. G+P	Всего по стр.
Japan	2,666667	2,666667	2,666667	8,00000
Evropa	2,333333	2,333333	2,333333	7,00000
Всего	5,000000	5,000000	5,000000	15,00000

Произв.	2-входовая итоговая: Наблюдаемые минус ожидаемые частоты (Avto1) Частоты выделенных ячеек > 10			
	Тип топл. P	Тип топл. D	Тип топл. G+P	Всего по стр.
Japan	-1,66667	-0,666667	2,33333	0,00
Evropa	1,66667	0,666667	-2,33333	0,00
Всего	0,00000	0,000000	0,00000	0,00

Рис. 5.11

В рамке **Statistics for two-way tables** (статистики для двухвходовых таблиц) приведены основные статистики двухвходовых таблиц, которые позволяют оценить **степень взаимосвязи между двумя категориальными переменными.**

Pearson Chi-square (критерий χ^2 Пирсона). Это наиболее простой критерий проверки значимости связи между двумя категоризованными переменными. Критерий Пирсона основан на том, что в двухвходовой таблице ожидаемые частоты при гипотезе «между переменными нет зависимости» можно вычислить непосредственно. Величина статистики χ^2 и ее уровень значимости зависят от общего числа наблюдений и количества ячеек в таблице. В соответствии с принципами статистики относительно малые отклонения наблюдаемых частот от ожидаемых будут доказывать значимость связи, если число наблюдений велико. Имеется только одно существенное ограничение использования критерия (кроме очевидного предположения о случайном выборе наблюдений), которое состоит в том, что ожидаемые частоты не должны быть очень малы. Это связано с тем, что критерий χ^2 по своей природе проверяет вероятности в каждой ячейке, и если ожидаемые частоты в ячейках становятся малыми, например меньше 5, то эти вероятности нельзя оценить с достаточной точностью с помощью имеющихся частот.

M-L Chi-square (максимум правдоподобия χ^2) предназначен для проверки той же самой гипотезы относительно связей в таблицах сопряженности, что и критерий χ^2 Пирсона. Однако его вычисление основано на методе максимального правдоподобия. На практике эта статистика очень близка по величине к обычной статистике χ^2 Пирсона. *Yates* (поправка Йетса). Аппроксимация статистики χ^2 для таблиц 2 x 2 с малым числом наблюдений в ячейках может быть улучшена уменьшением абсолютного значения разностей между ожидаемыми и наблюдаемыми частотами на величину 0,5 перед возведением в квадрат (так называемая поправка Йетса). Поправка Йетса, делающая оценку более умеренной, обычно применяется в тех случаях, когда таблицы содержат только малые частоты, например, когда некоторые ожидаемые частоты становятся меньше 10.

Fisher exact (точный критерий Фишера). Этот критерий применим только для таблиц 2 x 2. Критерий Фишера вычисляет точную вероятность появления наблюдаемых частот при нулевой гипотезе (отсутствие связи между табулированными переменными). В таблице результатов приводятся как односторонние, так и двусторонние уровни критерия.

McNemar (2x2) (критерий Макнемара). Данный критерий применим, когда частоты в таблице 2 х 2 представляют зависимые выборки. Например, наблюдения одних и тех же индивидуумов до и после эксперимента. В частности, можно подсчитать число студентов, имеющих минимальные успехи по математике в начале и в конце семестра, или предпочтения одних и тех же респондентов до и после рекламы. Процедура вычисляет два значения критерия: *A/D* и *B/C*. Первый проверяет гипотезу о том, что частоты в ячейках *A* и *D* (верхняя левая, нижняя правая) одинаковы, второй – гипотезу о равенстве частот в ячейках *B* и *C* (верхняя правая, нижняя левая).

Phi (2x2 tables) & Cramer's V & C (коэффициент Фи). Коэффициент представляет собой меру связи между двумя переменными в таблице 2 х 2. Его значения изменяются от 0 (нет зависимости между переменными) до 1 (абсолютная зависимость между двумя факторами в таблице).

Spearman rank order correlation (*R* Спирмена). Статистику *R* Спирмена можно интерпретировать так же, как и корреляцию Пирсона, в терминах объясненной доли дисперсии (имея, однако, в виду, что статистика Спирмена вычислена по рангам). Предполагается, что переменные измерены как минимум в порядковой шкале.

Kendall's tau-b & tau-c (Тау Кендалла). Статистика Тау Кендалла эквивалентна статистике *R* Спирмена при выполнении некоторых основных предположений. Также эквивалентны их мощности. Однако обычно значения *R* Спирмена и Тау Кендалла различны, потому что они отличаются как своей внутренней логикой, так и способом вычисления. Обычно вычисляются два варианта статистики. Эти статистики различаются только способом обработки совпадающих рангов. В большинстве случаев их значения довольно похожи. Если возникают различия, то, по-видимому, самый безопасный способ – рассматривать наименьшее из двух значений.

Sommer's d (коэффициент *d* Соммера: $d(X|Y)$, $d(Y|X)$). Статистика *d* Соммера представляет собой несимметричную меру связи между двумя переменными. Эта статистика близка к статистике Тау Кендалла.

Gamma (гамма-статистика). Если в данных имеется много совпадающих значений, эта статистика предпочтительнее *R* Спирмена или Тау Кендалла. С точки зрения основных предположений она эквивалентна статистике *R* Спирмена или тау Кендалла. Причем ее интерпретация и вычисление более похожи на статистику Тау Кендалла, чем на статистику *R* Спирмена.

Uncertainty coefficients $S(X|Y)$ *и* $S(Y|X)$ (коэффициенты неопределенности). Эти коэффициенты измеряют информационную связь между факторами (строками и столбцами таблицы). Статистики измеряют количество информации в переменной *Y* относительно переменной *X* или в переменной *X* относительно переменной *Y*.

Рассмотрим построение и анализ таблиц сопряженности для файла **Auto1.**

После осуществления последовательности действий, описанных в начале данного раздела, если выделить имена переменных для анализа: в списке *1 – Произв.*, в списке *2 – Тип. Топл;* на вкладке **Options** установить флажки на *Percentages of column counts*, *Highlight counts*, *Percentages of row counts* и на все опции рамки **Statistics for two-way tables**, то программа построит всевозможные подмножества (сопряжения) из значений (кодов) указанных переменных и произведет подсчет частот элементов выборки (членов группы) при соответствующих значениях переменных.

Статистики двухвходовой таблицы (рис. 5.12) и проценты по строкам (рис. 5.13) и столбцам итоговой таблицы позволят **оценить взаимосвязь** между категориальными переменными *Производ.* и *Тип. Топл.* и **исследовать характер взаимосвязи**.

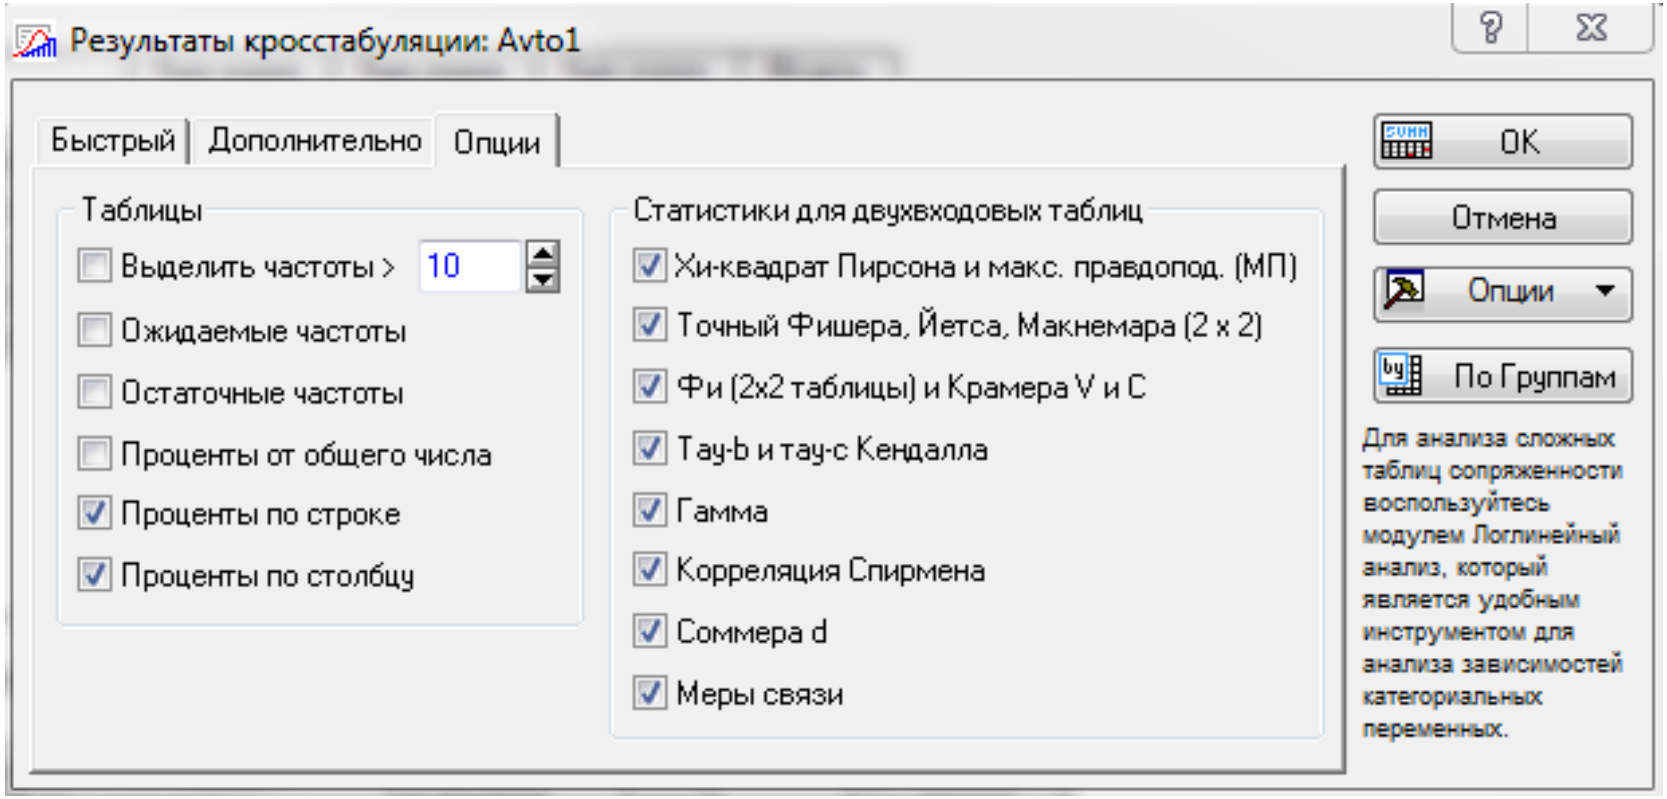
Результаты кросстабуляции: Avto1
Быстрый
Дополнительно
Опции
Таблицы
Выделить частоты >
10
Ожидаемые частоты
Остаточные частоты
Проценты от общего числа
Проценты по строке
Проценты по столбцу
Статистики для двухвходовых таблиц
Хи-квадрат Пирсона и макс. правдопод. (МП)
Точный Фишера, Йетса, Макнемара (2 x 2)
Фи (2x2 таблицы) и Крамера V и C
Tau-b и tau-c Кендалла
Гамма
Корреляция Спирмена
Соммера d
Меры связи
OK
Отмена
Опции
По Группам
Для анализа сложных таблиц сопряженности воспользуйтесь модулем Логлинейный анализ, который является удобным инструментом для анализа зависимостей категориальных переменных.

Statistic	Statistics: Произв.(2) x Тип.топл.(3)		
	Chi-square	df	p
Pearson Chi-square	6,964286	df=2	p=,03075
M-L Chi-square	8,993558	df=2	p=,01115
Phi	,6813852		
Contingency coefficient	,5630925		
Cramer's V	,6813852		
Kendall's tau b & c	b=-,617213	c=-,711111	
Sommers D(X|Y), D(Y|X)	X|Y=-,5333	Y|X=-,7142	
Gamma	-,869565		
Spearman Rank R	-,654654	t=-3,122	p=,00809
Uncertainty coefficient	X=,4338908	Y=,2728763	X|Y=,33504

Рис. 5.12

Из таблицы **Statistics:** следует, что между страной производителя автомобилей и типом топлива существует статистически значимая взаимосвязь – уровни значимости *p* критериев *Pearson & M-L Chi-square* меньше 0,05. Из значений остальных статистик следует, что связь между переменными **умеренная или сильная** (гамма-статистика больше 0,75), отрицательного знака, интерпретация которого затруднительна и связана с кодировкой категориальных переменных.

Чтобы понять смысл зависимости обратимся к процентам по строкам и столбцам (рис.5.13). Для японских автомобилей процент машин с типом топлива *P* минимальный (12,5%), с типом топлива *G+P*– максимальный (62,5%). Для европейских автомобилей, наоборот – с типом топлива *P* процент машин максимальный (57,14%), с типом топлива *G+P*– минимальный (0%).

Проценты по столбцам показывают, что на автомобили с топливом *P* приходится 20% японских и 80% европейских машин, на автомобили с топливом *G+P* приходится 100% японских и 0% европейских автомобилей. Таким образом, зависимость между страной производителя и типом топлива автомобилей проявляется в том, что на европейские машины предпочитают устанавливать двигатели на бензине, а на японские – со смешанным топливом: бензин – газ.

	2-Way Summary Table: Observed Frequenc Marked cells have counts > 10			
Произв.	Тип.топл. P	Тип.топл. D	Тип.топл. G+P	Row Totals
Japan	1	2	5	8
Column %	20,00%	40,00%	100,00%	
Row %	12,50%	25,00%	62,50%	
Evropa	4	3	0	7
Column %	80,00%	60,00%	0,00%	
Row %	57,14%	42,86%	0,00%	
Totals	5	5	5	15

Рис. 5.13

Если данные агрегированные, т.е. частоты вычислены и таблица 2 ×2, то для оценки взаимосвязи можно воспользоваться соответствующей процедурой в непараметрической статистике. Например, таблица имеет вид

Произв.	2-входовая итоговая: наблюдаемые частоты (Avto1) Частоты выделенных ячеек > 10		
	Тип.топл. P	Тип.топл. D	Всего по стр.
Japan	1	2	3
Evropa	4	3	7
Всего	5	5	10

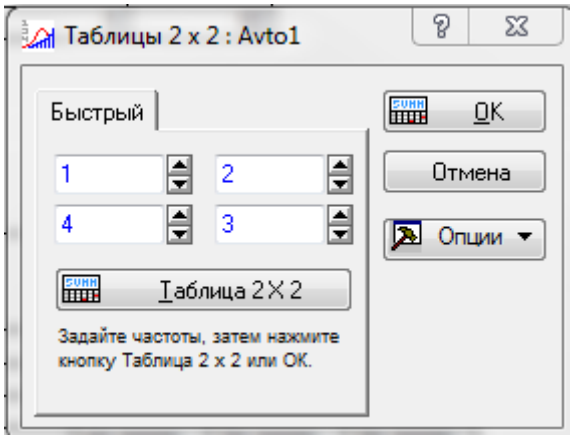

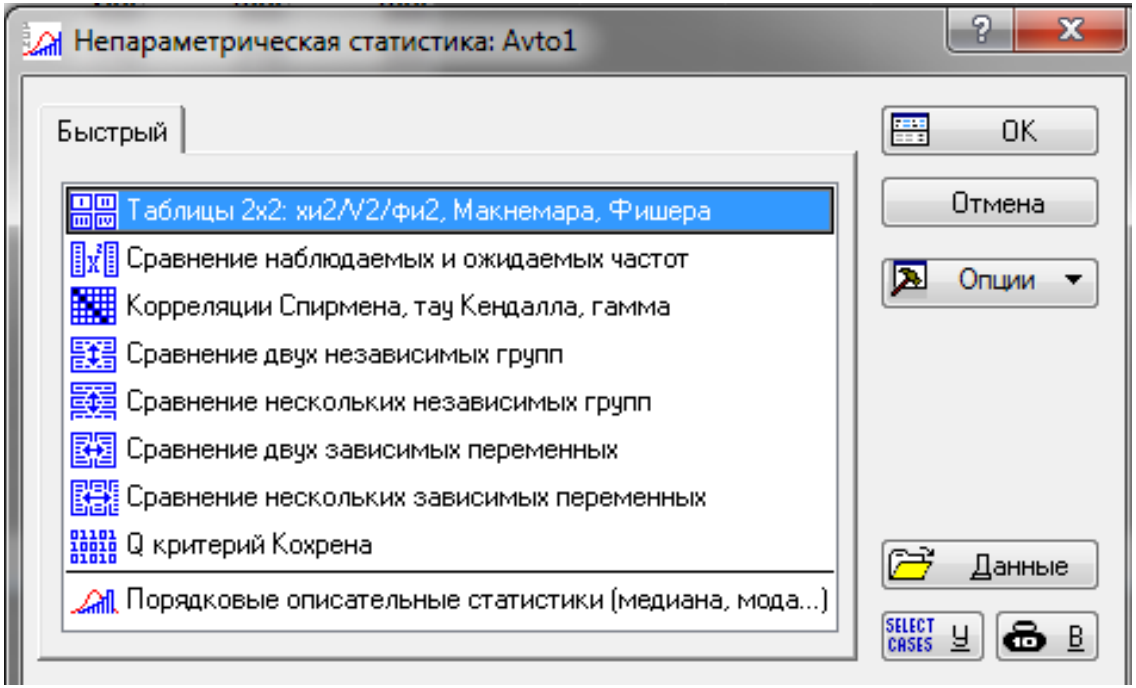

	Таблица 2x2 (Avto1)		
	Столб. 1	Столб. 2	Сумма строки
Частоты, строка 1	1	2	3
Процент от общего	10,000%	20,000%	30,000%
Частоты, строка 2	4	3	7
Процент от общего	40,000%	30,000%	70,000%
Сумма по столбцам	5	5	10
Процент от общего	50,000%	50,000%	
Хи-квадрат (ст.св.=1)	,48	p= ,4902	
V-квадрат (ст.св.=1)	,43	p= ,5127	
С поправкой Йетса	0,00	p=1,0000	
Фи коэффициент	,04762		
Фишера p, односторонний		p= ,5000	
двусторонний		p=1,0000	
Макнемара Хи-квадрат (A/D)	,25	p= ,6171	
Хи-квадрат (B/C)	,17	p= ,6831	

Во 2, 4, 6 строках приведены проценты от общего числа 10, в последующих 3 строках уровни значимости критериев Хи-квадрат, V-квадрат, С поправкой Йетса, которые оценивают статистическую значимость взаимосвязи между строками и столбцами таблицы, т.е. производителями и типом топлива. Как видно взаимосвязь статистически незначима, так как все уровни значимости p больше, чем 0,05. Статистика (коэффициент) Фи приняла значение 0,0476, близкое к 0, что говорит о слабой взаимосвязи, либо ее отсутствии.

Многомерные отклики.

Переменные типа многомерных откликов возникают в ситуациях, когда исследователя интересуют не только «простые» частоты событий, но и некоторые (часто неструктурированные) качественные свойства событий. Типичным примером является опрос общественного мнения, где вопросы, по крайней мере, частично, имеют так называемые открытые концы (не подразумевает однозначного ответа), и респондент делает выбор из неограниченного списка ответов. Природу многомерных переменных лучше всего рассмотреть на примере.

Пример основан на данных опроса студентов относительно степени проявления интереса к дисциплинам. Каждый из пятнадцати студентов должен был составить список, включающий пять наиболее интересных дисциплин. Дисциплины располагаются в порядке убывания интереса к ним. Результаты опроса приведены в файле данных **FPM,** изображенном на рис. 5.15.

	1 1-место	2 2-е место	3 3-е место	4 4-место	5 5-е место
1	умф	мат.ан.	диф.ур.	теор.вер.	архит.эвм
2	архит.эвм	физ-ра	медицина	ксе	умф
3	умф	архит.эвм	скт	диф.ур.	мат.ан.
4	скт	диф.ур.	числ.мет.	архит.эвм	excel
5	теор.вер.	умф	мат.ан.	функ.ан.	диф.ур.
6	функ.ан.	умф	скт	excel	архит.эвм
7	дискр.прог.	функ.ан.	архит.эвм	скт	теор.вер.
8	умф	архит.эвм	дискр.прог.	скт	теор.вер.
9	скт	архит.эвм	числ.мет.	дискр.прог.	теор.вер.
10	умф	архит.эвм	диф.ур.	функ.ан.	дискр.прог.
11	функ.ан.	скт	умф	теор.вер.	диф.ур.
12	умф	медицина	excel	скт	теор.вер.
13	скт	архит.эвм	теор.вер.	дискр.прог.	дискр.прог.
14	теор.вер.	теор.вер.	дискр.прог.	скт	excel
15	скт	архит.эвм	теор.вер.	дискр.прог.	excel

Рис. 5.15

Из стартовой панели модуля **Basic Statistics/Tables** выберем команду **Multiple response tables** (таблицы многомерных откликов). В диалоговом окне **Multiple response tables** (рис. 5.16) зададим переменные, например: *1-е место*; *2-е место*.

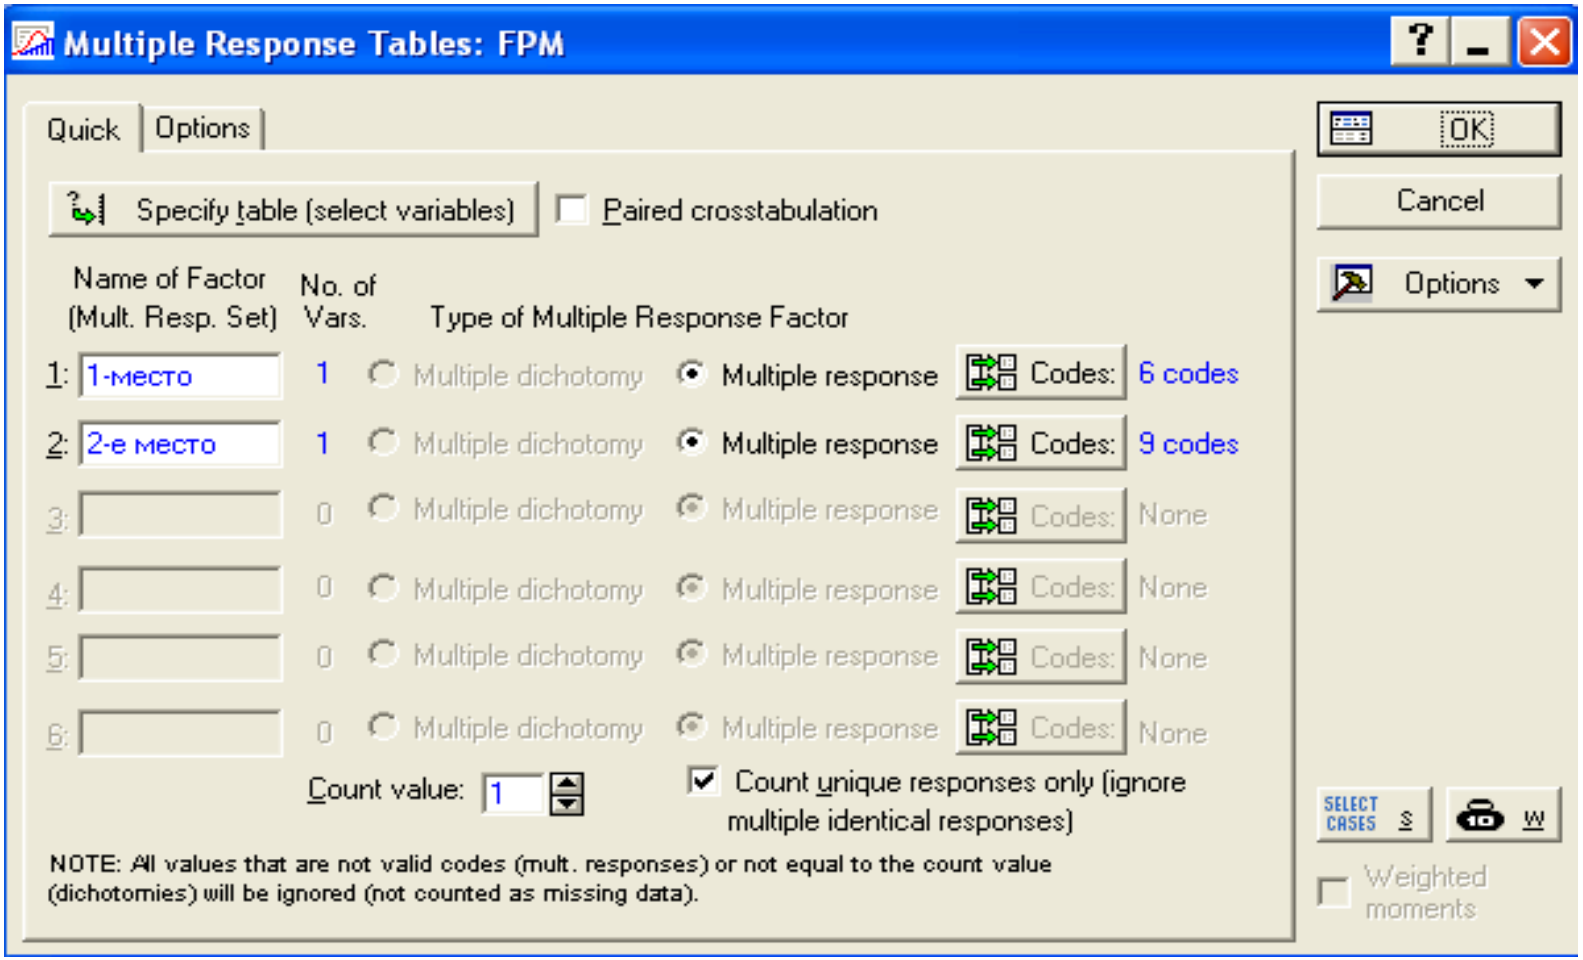

Рис. 5.16

После чего необходимо указать коды – имена дисциплин, которые есть в столбце данной переменной. Программа построит таблицу многомерных откликов. На рис. 5.17 приведен фрагмент таблицы.

Summary Table for all Multiple Response Items (FPM) Totals/percentages based on number of responses Multiple identical responses were ignored						
N=15 1-место	2-е место мат.ан.	2-е место архит.эвм	2-е место скт	2-е место функ.ан.	2-е место физ-ра	2-е место диф.ур.
архит.эвм	0	0	0	0	1	0
скт	0	3	0	0	0	1
дискр.прог.	0	0	0	1	0	0
функ.ан.	0	0	1	0	0	0
умф	1	3	0	0	0	0
теор.вер.	0	0	0	0	0	0
All Grps	1	6	1	1	1	1

Рис. 5.17

В таблице рассмотрены пересечения двух переменных: *1-е место* и *2-е место* и подсчитаны частоты, с которыми пересеченные дисциплины встречаются соответственно на 1-м и 2-м местах в файле исходных данных. Так, например, *архит. эвм* и *физ-ра*, занимающие1-е и 2-е места соответственно, встречаются 1 раз; *скт*. и *архит. эвм* встречаются 3 раза; *функ. ан*.. и *скт* – 1 раз и т. д. По аналогии можно построить пересечения 3, 4, 5 и 6 чисел переменных.

Провести анализ исходных данных многомерных откликов можно также при помощи **Frequency table** (таблицы частот). Например, можно построить таблицу (рис. 5.18), в которой будет приведено распределение частот дисциплин, занявших 1-е место. Из таблицы видно, что пять респондентов (33%) отдали предпочтение *умф*, четыре респондента (26%) – *скт*., два – *функ*. *ан*. и т. д.

N=15 Category	Frequencies (Identical resp. w Variable: 1-место (Simple Grouping Variable)		
	Count	Prcnt.of Responses	Prcnt.of Cases
архит.эвм	1	6,67	6,67
скт	4	26,67	26,67
дискр.прог.	1	6,67	6,67
функ.ан.	2	13,33	13,33
умф	5	33,33	33,33
теор.вер.	2	13,33	13,33
Totals	15	100,00	100,00

Рис. 5.18

Если построить аналогичные таблицы частот для дисциплин, занявших соответственно второе место, третье и т.д., и выделить дисциплины, которым соответствует наибольшая частота, то получим последовательность предпочтений дисциплин студентами: *умф*, *архит. эвм*, *скт*, *дискр. пр.*, *теор. вер*.